

MACDCGAN 的发电机轴承故障诊断方法

曹洁^{1,2}, 尹浩楠¹, 王进花^{1,2}

(1. 兰州理工大学 电气工程与信息工程学院, 兰州 730050; 2. 甘肃省制造信息工程研究中心, 兰州 730050)

摘要: 在实际工况中, 发电机中传感器采集到的故障样本数据有限, 使用基于深度学习的方法进行故障诊断存在过拟合问题导致模型泛化能力较差以及诊断精度不高。为了解决这个问题, 采用样本扩充的思路, 提出了一种改进的辅助分类器条件深度卷积生成对抗网络 (MACDCGAN) 的故障诊断方法。通过对采集的一维时序信号进行小波变换增强特征, 构建简化结构参数的条件深度卷积生成对抗网络模型生成样本, 并在模型中采用 Wasserstein 距离优化损失函数解决训练过程中存在模式崩塌和梯度消失的缺点; 通过添加一个独立的分类器来改进分类模型的兼容性, 并在分类器中引入学习率衰减算法增加模型稳定性。试验结果表明, 该方法可以有效地提高故障诊断的精度, 并且验证了所提模型具有良好的泛化性能。

关键词: 发电机; 特征提取; 生成对抗网络 (GAN); 卷积神经网络 (CNN); 故障诊断

中图分类号: TP277

文献标志码: A

DOI:10.13465/j.cnki.jvs.2024.11.025

Fault diagnosis of generator bearings based on MACDCGAN

CAO Jie^{1,2}, YIN Haonan¹, WANG Jinhua^{1,2}

(1. College of Electrical & Information Engineering, Lanzhou University of Technology, Lanzhou 730050, China;

2. Gansu Provincial Engineering Research Center for Manufacturing Information, Lanzhou 730050, China)

Abstract: Under actual working conditions, fault sample data collected by sensors in generator are limited, using deep learning-based method for fault diagnosis has overfitting problems to result in poorer model generalization ability and low diagnostic accuracy. Here, to solve these problems, using a sample expansion idea, an improved fault diagnosis method called modified auxiliary classifier conditional deep convolutional generative adversarial network (MACDCGAN) was proposed. Wavelet transform was performed for the collected one-dimensional time series signals to enhance features. A conditional deep convolutional generative adversarial network model for simplifying structural parameters was constructed to generate samples. Wasserstein distance optimization loss function was used in the model to solve shortcomings of pattern collapse and gradient disappearance in training process. An independent classifier was added to improve the compatibility of the classification model, and the learning rate decay algorithm was introduced into the classifier to increase model stability. The experimental results showed that the proposed method MACDCGAN can effectively improve the accuracy of fault diagnosis; its good generalization performance is verified.

Key words: generator; feature extraction; generative adversarial network (GAN); convolutional neural network (CNN); fault diagnosis

发电机作为风力发电机组的核心设备, 对风力发电机组的正常运行起着重要作用^[1]。准确有效地对发电机故障进行诊断, 能够很大程度上降低风机故障造成的经济损失, 保证风机持续稳定的运行^[2]。

近年来随着人工智能的快速发展推动了智能故障诊断技术的研究, 基于深度学习的故障诊断方法受到广泛关注^[3]。深度学习算法可以根据大量的监测数据了解故障特征, 能够快速有效地处理信号并获得可靠的故障诊断结果^[4]。文献[5]结合长短时记忆网络 (long short-term memory, LSTM) 与卷积神经网络 (convolutional neural network, CNN) 解决了在大数据下滚动轴承的智能诊断问题。文献[6]提出一种多速率数据样本的深度学习模型, 无需专业知识即可自动从多速率采样数据中提取特征。文献[7]提出了一种基

基金项目: 国家自然科学基金项目 (62063020; 61763028); 国家重点研发计划项目 (2020YFB1713600); 甘肃省自然科学基金项目 (20JR5RA463)

收稿日期: 2023-05-25 修改稿收到日期: 2023-10-11

第一作者 曹洁 女, 博士, 教授, 1966 年生

通信作者 王进花 女, 博士, 副教授, 1976 年生

于离散小波变换(discrete wavelet transform, DWT)和改进深度置信网络(deep belief networks, DBN)的电机轴承故障诊断模型,实现了在高噪声条件下的故障分类。文献[8]从原始振动信号和声学信号中提取特征以实现更准确、更稳定的轴承故障诊断。上述文献采用时间序列分析和深度学习的方法训练模型进行故障诊断取得了较好的效果,但前提是有充足的样本数据^[9]。为了实现精确的故障诊断,丰富的数据对于现有的基于深度学习的故障诊断方法至关重要。然而,对于风力发电机这类大型设备普遍面临缺乏故障样本数据的情况,深度学习模型往往难以训练。

Goodfellow 在 2014 年提出了一种生成对抗网络(generative adversarial network, GAN)模型^[10],实现了基于少量可用数据生成新数据集的方法。这些生成的数据分布能够接近原始数据,而且能够从原始数据集中提取出不同图像的特征。文献[11]提出了一种分类对抗自动编码器模型,该模型通过对抗性过程训练自动编码器,并对潜在编码空间施加先验分布,实现了滚动轴承的无监督故障诊断。文献[12]提出了一种结合 GAN 和堆叠去噪自编码器(SDAE)的新型故障诊断方法,该方法在小样本情况下有较好的故障诊断性能。文献[13]利用小波变换将轴承振动信号转换为时频域图像,结合 GAN 网络生成图像样本进行故障分类,实现了在数据不平衡条件下的故障诊断。文献[14]提出了一种基于条件生成对抗网络(conditional generative adversarial net, CGAN)和卷积去噪自编码器(convolutional denoising auto encoder, CDAE)的故障诊断模型,在小样本和类不平衡的情况下,实现了滚动轴承良好的故障诊断性能。文献[15]在 GAN 网络模型中添加编码器结构,用于直接提取图像特征,在使用少量带标签数据情况下有更高的分类精度。文献[16]引入了一种深度卷积生成对抗网络(deep convolutional generative adversarial network, DCGAN)模型来生成高分辨率图像,首次在 GAN 网络中引入卷积网络。文献[17]针对永磁电机故障数据不足、故障诊断困难的问题,使用 DCGAN 扩展训练样本,将故障诊断准确率提高了 13.1%,实现了在样本数据不平衡条件下高精度的故障诊断。文献[18]构建了条件深度卷积生成对抗网络模型(conditional deep convolutional generative adversarial network, CDCGAN)于生成图像样本,试验结果表明生成样本的质量以及分类性能方面相比于其它 GAN 网络有了显著的提升。上述文献中对 GAN 网络进行了一系列的改进取得了很好的效果,但还存在部分不足,CDCGAN 提升了模型训练的稳定性以及生成样本的质量,但缺乏一个指标来判断模型训练的程度;深度网络模型训练时往往需要大量参数,样本不足条

件下模型会导致过拟合问题,分类模型通常采用 GAN 网络的判别器,往往导致分类模型的兼容性不足。

针对以上问题,本文提出一种改进的辅助分类器的条件深度卷积生成对抗网络的故障诊断模型。本文采用了一种简化的 CDCGAN 网络模型,并对该模型的损失函数进行优化,构建了单独的分类器进行故障诊断。试验结果表明所提出的方法与其它对比模型相比有着更好的性能。

本文主要贡献如下:考虑到采集一维时序信号存在随机噪声,利用小波变换对数据进行预处理增强特征,结合条件生成对抗网络和深度卷积生成对抗网络构建条件深度卷积生成对抗网络模型,通过试验确定最佳网络模型结构,使用 Wasserstein 距离对损失函数进行优化克服模型训练过程中模式崩塌和梯度消失的问题;通过添加一个独立的分类器来改进分类模型的兼容性,同时在构建的分类模型中引入余弦退火算法,对模型训练过程中的学习率进行有规律的衰减,增加模型训练的稳定性;在风电场采集的风力发电机数据集上验证了该方法的有效性,并在美国凯斯西储大学的轴承数据集进行了不平衡数据集条件下的试验,进一步验证了所提方法的诊断效果,同时证明了本文模型具有良好的泛化性能。

1 小波变换提取时频特征

与一维(1-D)时序信号相比较,图像是二维(2-D)矩阵,可以存储更多的信息,因此可以用来表示更复杂的结构分布。由于卷积神经网络(CNN)的卷积结构对一维输入的诊断效果并不理想,但是对二维数据或更高维数据处理有着良好的效果^[19]。小波变换能够有效地将一维时序信号转换为二维时频域图像样本。因此,本文使用小波变换提取时频特征的能力,从一维原始信号提取时频图像特征。

对于一维振动信号序列 $f(t)$,小波变换表为

$$WT(\alpha, \tau) = \frac{1}{\sqrt{\alpha}} \int_{-\infty}^{\infty} f(t) \cdot \psi\left(\frac{t-\tau}{\alpha}\right) dt = \langle f(t), \psi_{\alpha, \tau}(t) \rangle \quad (1)$$

小波基函数(WBF)表示为

$$\psi_{\alpha, \tau}(t) = |\alpha|^{-1/2} \psi\left(\frac{t-\tau}{\alpha}\right) \quad (2)$$

式中: $\psi(t)$ 为一个小波生成函数; τ 为用于确定对 $f(t)$ 分析后时间中心的时移系数; α 为小波变换过程中的尺度因子,振动信号和小波基函数的内积表示为 $\langle f(t), \psi_{\alpha, \tau}(t) \rangle$ 。

本文选择 Morlet WBF 作为小波基函数, Morlet WBF 是具有平方指数衰减的余弦信号,用于提取脉冲信号的故障特征信息更为合理有效^[20]。图 1 为小波变

换提取一维时序信号时频域特征的过程,将采集的信号采用滑动窗口的方式进行重采样,一个滑动窗口的信号经过小波变换后作为一个时频域图像样本。




图 1 小波变换提取时频域特征

Fig. 1 Wavelet transform to extract time-frequency domain features

2 CDCGAN 的改进方法

本文结合深度卷积生成对抗网络(DCGAN)和条件生成对抗网络(CGAN),将数据标签 C 作为条件引入 DCGAN 的生成器和判别器中,构建条件深度卷积生成对抗网络模型,利用卷积提取特征的能力加上辅助条件指导样本的生成过程,解决传统 GAN 网络模型难以训练以及生成器会选择容易生成的样本导致模型很难去学习样本特征的问题。同时对 CDCGAN 损失函数和网络模型结构进行改进,解决模型训练过程模式崩塌和梯度消失等问题。

2.1 损失函数的改进

相比于其他 GAN 网络,CDCGAN 生成的样本有更好的质量,但模型训练过程中模式崩塌以及梯度消失等问题依然存在。

KL 散度和 JS 散度通常用来测量生成样本和实际样本之间的分布距离。其中 KL 散度的不对称性会导致 loss 下降的方向趋于某一个特定的方向,造成模型训练过程中出现模式崩塌。JS 散度是在 KL 散度基础上的优化,虽然解决了不对称的问题,但当两个分布没有重叠时,JS 散度很可能为 0,此时会导致模型训练过程中梯度消失。

Wasserstein 距离(WD)相比 JS 散度更平滑,当两个分布在高维空间中不重叠时,能够稳定并有效地计算两个分布之间的距离。

WD 距离定义如下。

$$W(p_{r(x)}, p_{g(y)}) = \inf_{\gamma \sim \Pi(p_{r(x)}, p_{g(y)})} E_{(x,y) \sim \gamma} [\|x - y\|] \quad (3)$$

式中: $p_{g(y)}$ 为生成样本 y 的分布;真实样本和生成样本联合概率分布的集合为 $\Pi(p_{r(x)}, p_{g(y)})$; $E_{(x,y) \sim \gamma} [\|x - y\|]$ 为实际样本 x 和生成样本 y 之间的预期距离,在联合分布中,对于这个预期距离取得的最小值就定义为 WD 距离。

WD 距离的定义经过推导可以得到其变换形式

$$W(p_{r(x)}, p_{g(y)}) = \frac{1}{K} \sup_{\|f\| \leq K} (E_{x \sim p_{r(x)}} [f(x)] - E_{y \sim p_{g(y)}} [f(y)]) \quad (4)$$

在实际计算过程中,需要将网络权重参数限制在一定范围内来近似计算 WD 距离,通过在连续函数 $f(x)$ 施加限制条件,即存在一个常数 $K (K \geq 0)$ 满足定义域内任意两个元素 u_1 和 u_2 之间的距离 $|f(u_1) - f(u_2)| \leq K |u_1 - u_2|$,此时 K 为函数 $f(x)$ 的 Lipschitz 常数。

梯度惩罚是满足梯度限制的一种方法。通过向判别器添加额外的损耗项 (gradient penalty, gp),使判别器的梯度被限制为不超过 K 值。

$$L(\text{gp}) = [\|\nabla D(x_e)\|_2 - K]^2 \quad (5)$$

式中, x_e 为通过随机插值采样获得的样本。

$$x_r \sim p_{r(x)}, x_g \sim p_{g(y)}, \varepsilon \sim [0, 1] \quad (6)$$

$$x_e = \varepsilon x_r + (1 - \varepsilon) x_g \quad (7)$$

本文中将 K 的值设置为 1。

其目标函数如下所示

$$\min_G \max_{D \in \mathbb{R}} V(G, D) = E_{x \sim p_{r(x)}} [D(x | c)] - E_{y \sim p_{g(y)}} [D(y | c)] \quad (8)$$

式中, $D \in \mathbb{R}$ 表示鉴别器 D 需要满足 Lipschitz 连续性条件的约束。此外,WD 的目标函数在训练 D 时,需要最大化 $E_{x \sim p_{r(x)}} [D(x | c)] - E_{y \sim p_{g(y)}} [D(y | c)]$ 当训练 G 时,需要最小化 $-E_{y \sim p_{g(y)}} [D(y | c)]$ 。

所提出的 MACDCGAN 模型使用 WD 距离来改进基本 CDCGAN 的损失函数。

改进的判别器的损失函数 L_D

$$L_D = -E_{x \sim p_{r(x)}} [D(x | c)] - E_{y \sim p_{g(y)}} [D(y | c)] + \rho E_{x \sim p_e} [\|\nabla D(x_e)\|_2 - 1]^2 \quad (9)$$

改进的生成器的函数 L_G

$$L_G = -E_{y \sim p_{g(y)}} [D(y | c)] \quad (10)$$

2.2 CDCGAN 模型结构

CDCGAN 模型由生成器模型和判别器模型构成,此处以风力发电机采集的数据为例,一共三种故障类型,传统的 DCGAN 网络采用的是 4 层卷积反卷积架构,为了加快模型的训练速度同时兼顾模型生成样本的质量,本文在生成器采用三层的反卷积架构,判别器采用三层的卷积架构。

2.2.1 生成器模型

其中生成器模型的结构如图 2 左侧所示,数据经过小波变换处理后为 $64 \times 64 \times 1$ 的灰度图像,输入为 100 维随机噪声 Z 和 3 维数据标签 C ,通过两个全连接层进行维度转换成 $(8, 8, 256)$ 的三维张量,之后通过一个步长为 2 的 5×5 的转置卷积核,输出一个 $(16, 16, 128)$ 的三维张量,再经过一个步长为 2 的 3×3 的转置卷积核,输出一个 $(32 \times 32 \times 64)$ 的三维张量,最后

经过转置后得到 $(64 \times 64 \times 1)$ 的张量,获得一张图像样本,为了增强数据标签对样本生成中的指导作用,在模型每一层输入都引入了数据标签,标签维度与每一层输入数据维度保持一致。

2.2.2 判别器模型

CDCGAN 的判别器结构(如图4右侧所示)与生成器恰好相反,输入是 $(64 \times 64 \times 1)$ 的图像样本,经过一个步长为2的 5×5 的卷积核,输出 $(32 \times 32 \times 64)$ 的三维标量,步长为2的 3×3 的卷积核变 $(16 \times 16 \times 128)$ 的三维张量,经过转换后变成 $(8 \times 8 \times 256)$ 的三维张量,对三维张量进行展开,经过两层全连接层,同样地

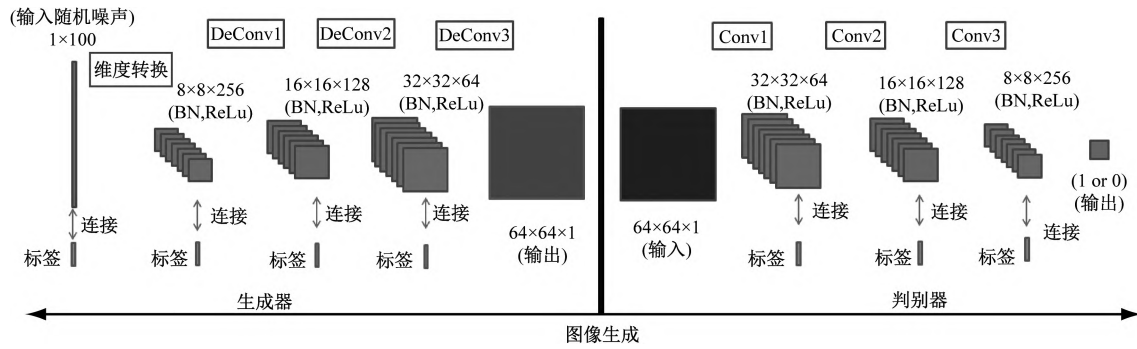


图2 CDCGAN 模型结构图

Fig. 2 CDCGAN model structure diagram

CNN 模型结构如图3所示,由四个卷积层,四个最大池化层和两个全连接层构成,输入图像是 $64 \times 64 \times 1$ 的灰度图像,使用 Softmax 激活函数实现故障分类。

输入为真实样本 x_r 和生成样本 x_g ,第 i 层卷积的输出为 w_i

$$w_i = \text{Lrelu} \left(\sum_{l \in M} p_{i-1}^l \times k_i^l + a_i \right) \quad (11)$$

式中: M 为输入特征向量; p_{i-1} 代表第 $i-1$ 个池化层; k_i 和 a_i 为第 i 层的卷积核和卷积层的偏置。

第 i 层池化层的输出为

$$p_{i,j} = \max w_{i,\lambda} + j \times \mu \quad (12)$$

式中: λ 为池窗口的大小; μ 为下采样因子。

通过卷积层和池化层提取特征后,将获取的特征输入 Softmax 进行故障分类。

$$S(x_i) = \begin{bmatrix} p(y_1 = 1 | x_i; \eta) \\ p(y_2 = 2 | x_i; \eta) \\ \dots \\ p(y_i = m | x_i; \eta) \end{bmatrix} = \frac{1}{\sum_{j=1}^m e^{\eta_j^T x_i}} \begin{bmatrix} e^{\eta_1^T x_i} \\ e^{\eta_2^T x_i} \\ \dots \\ e^{\eta_m^T x_i} \end{bmatrix} \quad (13)$$

式中, η_m 为 Softmax 激活函数的参数。

通过优化损失函数 L_c 可以准确地对不同故障进行分类。

$$L_c = -\frac{1}{N} \left[\sum_{i=1}^N \sum_{j=1}^m 1\{y_i = j\} \lg \frac{\eta_j^T x_i}{\sum_{l=1}^m e^{\eta_l^T x_i}} \right] \quad (14)$$

在判别器模型的每一层中都引入了数据标签。

2.3 CNN 分类模型

为了提高识别和分类之间的兼容性以及实现高效的样本生成,本文构建了一个独立的神经网络作为分类器,该分类器采用二维卷积神经网络(CNN)框架。改进的辅助分类器条件深度卷积生成对抗网络(modified auxiliary classifier conditional deep convolutional generative adversarial network, MACDCGAN)将生成对抗网络中判别器的分类功能分离,并赋予其独立分类器,以改善样本生成的效果。

式中: N 为训练样本总数; $1\{y_i = j\}$ 为预测标签与真实标签相同返回1,否则返回0。




图3 CNN 模型结构

Fig. 3 CNN model structure

2.4 余弦退火算法

深度学习模型开始训练时,由于模型中权重参数随机初始化,若训练初始状态选择的学习率较大,会造成模型训练过程不稳定,通过选择学习率衰减的方式,使学习率在一个训练周期内进行有规律的下降,并在下一个训练周期初始化学率后继续进行衰减,在学习率衰减的条件下,模型能够逐渐趋于稳定。为了使模型收敛效果更佳,本文在卷积神经网络分类模型中引入余弦退火算法对学习率进行衰减。

余弦退火(cosine annealing)算法是一种降低学习率的余弦函数^[21],通过让学习率参数值模仿余弦函数的变化使模型在训练过程中达到更好的收敛效果。

余弦退火算法的表达形式如下

$$\eta_i = \eta_{\min}^i + \frac{1}{2}(\eta_{\max}^i - \eta_{\min}^i) \left(1 + \cos\left(\frac{T_{\text{cur}}}{T_i} \pi\right) \right) \quad (15)$$

式中, η_{\min}^i 和 η_{\max}^i 为学习率的范围; T_{cur} 为已经完成的 epoch 次数; T_i 为试验中的总的 epoch 次数。

3 诊断流程

本文诊断流程如图 4 所示。

Step1: 数据预处理, 利用小波变换提取一维时序信号的时频域特征, 对特征进行增强后转换为时频域的图像样本。

Step2: 将时频域图像样本按一定比例划分训练集和测试集。

Step3: 将训练集样本输入到所构建的改进条件深度卷积生成对抗网络模型中进行训练, 模型训练结束后固定模型参数对数据集进行扩充。

Step4: 根据故障类型构建二维卷积神经网络模型用作分类器, 在模型中引入余弦退火算法提高模型训练过程的稳定性, 将生成样本和训练样本混合训练分类器模型。

Step5: 当分类器模型达到最优后, 固定模型参数, 对测试样本进行故障分类。

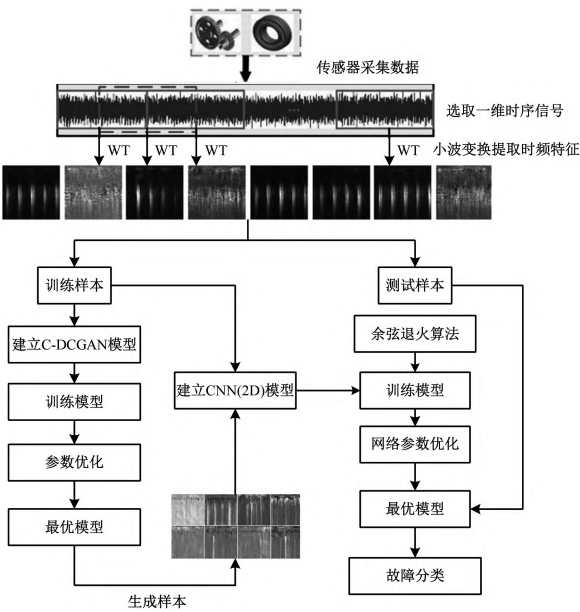


图 4 诊断流程图

Fig. 4 Diagnostic flow chart

4 试验结果与分析

为了评估算法的可行性和所提模型的泛化能力, 本文首先在甘肃酒泉某风电厂采集的风力发电机数据上进行验证, 然后在美国凯斯西储大学 (Case Western Reserve University, CWRU) 滚动轴承数据集进行进一步的试验。试验环境为 `inter (R) Xeon (R) CPUE5-2620v4 @ 2.10 GHz` 处理器, 64 GB 内存 (RAM),

NVIDIA GeForce GTX1080Ti GPU, TensorFlow 平台。

4.1 风力发电机数据试验

首先采用风电场采集的风力发电机的数据对本文提出的模型进行验证, 该数据集包含发电机轴承温度, 发电机转速以及发电机相电流以及采集振动信号等多种数据, 由于本文是对单个传感器采集的数据进行故障识别, 所以每一时刻最多只有一种故障类型, 这里选取采集发电机振动信号进行试验, 一共设置了三种故障类型: ① 发电机正常工作条件下采集的数据; ② 电机转子断条故障, 转子回路电气不平衡从而产生不平衡的气隙电磁力 F_e , 导致发电机转子运行时产生振动 (故障 1); ③ 发生静态偏心时因产生不平衡的拉力造成轴承内圈破裂 (故障 2)。

4.1.1 数据预处理

在本试验中, 通过重采样的方法对原始数据进行分割, 将 512 个数据点作为一个数据样本, 使用步长为 180 的滑动窗口, 经过小波变换提取特征后转化为图像样本, 数据集划分结果如表 1 所示。

表 1 风电发电机数据集划分

Tab. 1 Data set division of wind turbine generator

故障类型	训练集	测试集
正常	60	40
故障 1	60	40
故障 2	60	40

4.1.2 生成样本质量评估

将训练集输入到 CDCGAN 网络模型中进行训练, 学习率为 0.000 2, 每个批次训练的样本数为 64, 图 5 为数据集中前 64 个生成样本随着 Epoch 次数的增加发生的变化, 随着模型对抗训练迭代次数的增加所显示的特征也更加的明显。




图 5 风力发电机数据集生成样本

Fig. 5 Wind turbine data set generation sample

图 6 为 MACDCGAN 模型在训练过程中判别器的损失函数 (`d_loss`) 和生成器的损失函数 (`g_loss`) 随着训练次数增加的变化趋势, 模型在训练初期 `loss` 比较稳定, 随着训练次数的增加, 生成器和判别器的 `loss` 出现明显的震荡, 训练后期判别器损失函数值收敛且波动幅度较小, 训练 20 000 轮以后生成样本的多样性相比于改进前有了很大的提升。

训练后的生成器补充了足够的样本, 然而生成样本的质量决定了模型的可靠程度, 为了评估本文 MACDCGAN 模型的样本生成能力, 使用 EMD (Earth

Mover's Distance), Kullback-Leibler 散度 (KL-D) 和结构相似性 (structural similarity index, SSIM) 三个指标判断生成样本与原始样本之间的相似度。EMD 用于度量两个概率分布之间的相异性, EMD 值越小, 表明生成的数据更接近原始数据。KL-D 为两个概率分布之间差异的非对称的度量, 较小的 KL-D 值代表了更好的性能。SSIM 旨在从亮度、对比度和结构来衡量两幅图像的相似性, SSIM 值越大, 表示两个图像之间的相似性越高。




图6 loss 值变化趋势

Fig. 6 Variation trend of loss value

对于该数据集, 每个类别使用 60 个真实样本和 60 个生成样本, 计算所有类别的每个统计指标的平均得分。用于对比的普通 GAN 网络在结构上采用三个完全连接的层来建立生成器和鉴别器 (如表 2 所示), 其中“/”代表全连接层。CGAN 在 GAN 网络的基础上加入了样本标签作为条件; CDCGAN 网络模型参数的设置与本文所提基础模型一致 (见图 2); DCGAN 在 CDCGAN 的基础上删除了数据标签。生成样本指标评估如表 3 所示。

表2 用于比较 GAN 的结构

Tab. 2 Used to compare the structures of GAN

GAN	Kernel 尺寸/数量			
	Layer1	Layer2	Layer3	Layer4
G	/	(3×3)/256	(3×3)/128	(3×3)/64
D	(3×3)/64	(3×3)/128	(3×3)/256	/

从表 3 可得, 本文的 MACDCGAN 模型 EMD 和 KL-D 均小于其它 GAN 网络模型, SSIM 值大于其他对比网

络, 有较好的性能。

4.1.3 故障诊断结果分析

为了验证在分类模型引入余弦退火算法的效果, 在相同试验条件下进行了对比试验。图 7 中 acc2 和 loss2 为 CNN 模型加入余弦退火算法后准确率和损失函数随着迭代次数增加的变化情况, 可以明显地看出, 随着试验迭代次数的增加, 引入学习率衰减算法的模型准确率的上升与损失函数的下降更加平稳。

表3 生成样本指标评估

Tab. 3 Evaluation of sample indicators generated

指标	生成样本				
	GAN	CGAN	DCGAN	CDCGAN	MACDCGAN
EMD	0.137 4	0.114 7	0.093 9	0.087 4	0.076 5
KL-D	0.154 2	0.137 6	0.128 7	0.118 9	0.109 1
SSIM	0.163 7	0.216 8	0.278 4	0.374 5	0.482 6




图7 模型 loss 值和准确率值变化情况

Fig. 7 Changes of loss value and accuracy value of the model

为了证明本文提出的方法的有效性, 对比了几种基于 GAN 网络模型的方法, 其中每类故障类型的训练集有 200 个样本 (60 个真实样本, 140 个生成样本), 测试样本每类 40 个。其它深度学习方法 WT-CNN(2D)、CNN(1D)、长短时记忆网络 (LSTM) 和自编码器 (SAE) 使用真实样本进行故障分类, 其中 WT-CNN(2D) 是将一维时序信号转换为灰度图像后用本文 2.3 所构建的模型进行分类, SAE 由三个自编码器堆叠而成, 其中间层的神经元数量分别为 900, 300, 50。LSTM 的输入维度为 (128, 512, 1), 得到 (128, 512, 32) 的时序特征, 并对特征进行分类。CNN (1D) 模型输入为 (128, 512, 1), 经过两层卷积池化后得到 (128, 38, 16) 特征, 再通过全连接层和 Softmax 函数得到分类结果。每种类别包含 60 个训练样本, 40 个测试样本。试验结果取十次平均值, 表 4 列出了分类结果。

本文提出的方法相比于其它基于 GAN 网络的模型诊断精度有明显的提高, 证明 MACDCGAN 模型能够从真实样本中学习更多的特征, 这些特征有助于提高故障分类的精度。

为了进一步验证本文所提出模型的性能,采用最大均方误差(MSE)对模型进行进一步的评估,MSE是指模型预测标签与真实标签之差平方的期望值。MSE可以评价数据的变化程度,更小的MSE值代表模型拟合试验数据能力更强。由表4可得,本文所提方法的MSE均小于其它方法,证明本文模型更能拟合试验数据。

表 4 风力发电机数据分类精度

Tab. 4 Classification accuracy of wind turbine data		
方法	平均精度/%	MSE
MACDCGAN	93.65	0.40
WT-CDCGAN-CNN	92.57	0.43
WT-DCGAN-CNN	92.12	0.45
WT-CGAN-CNN	91.76	0.46
WT-GAN-CNN	91.52	0.48
WT-CNN	91.25	0.49
CNN(1D)	87.33	0.56
LSTM	83.56	0.68
SAE	81.75	0.71

分类结果的混淆矩阵如图8所示,横轴和纵轴分别代表输入样本的预测标签和真实标签,主对角线上的元素代表正确分类的精度。其中 fault-I 错误分类最多,fault-II 的分类准确率最高,达到95%。

4.1.4 不同 CDCGAN 结构参数的影响

为了充分研究参数结构的影响,本文构建四个模

表 5 CDCGAN 结构

Tab. 5 CDCGAN structure								
CDCGAN	CDCGAN a		CDCGAN b		CDCGAN c		CDCGAN d	
	G	D	G	D	G	D	G	D
Layer1	32 × 32 × 32	/	32 × 32 × 32	/	32 × 32 × 64	/	32 × 32 × 64	/
Layer2	16 × 16 × 64	8 × 8 × 128	16 × 16 × 64	4 × 4 × 256	16 × 16 × 128	8 × 8 × 256	16 × 16 × 128	4 × 4 × 512
Layer3	8 × 8 × 128	16 × 16 × 64	8 × 8 × 128	8 × 8 × 128	8 × 8 × 256	16 × 16 × 128	8 × 8 × 256	8 × 8 × 256
Layer4	/	32 × 32 × 32	4 × 4 × 256	16 × 16 × 64	/	32 × 32 × 64	4 × 4 × 512	16 × 16 × 128
Layer5	—	—	/	32 × 32 × 32	—	—	/	32 × 32 × 64

表 6 不同结构参数下 CDCGAN 网络性能

Tab. 6 Network performance of CDCGAN under different structural parameters				
CDCGAN	a	b	c	b
训练时间	0.56	1.27	0.65	1.45
准确率	91.12%	91.43%	92.84%	92.89%

4.2 凯斯西储大学轴承数据集试验

为了验证本文所提模型在不平衡数据集下的诊断效果以及本文所提模型的泛化能力,在凯斯西储大学轴承公开数据集进行进一步的试验。

试验选取在 OHP 下损伤直径为 0.007 英寸,0.014 英寸,0.021 英寸下的驱动端数据,该数据包含正常、内圈故障、外圈故障和滚珠故障,每种故障包含损伤直径为 0.007、0.014 和 0.021 英寸的 3 种损失程度,因此数据集共有 10 种故障类型。

型对样本数据进行生成(具体参数如表5所示),其它超参数保持不变,使用本文所构建的分类器进行故障分类,对样本生成过程中一个 epoch 所需时间以及故障分类效果进行对比,试验结果取 10 次平均值结果如表6所示,试验结果表明,具有更多核的 CDCGAN 模型有着更高的分类精度,能够学习到更多图像的特征,但是层内核数的增加会导致计算成本变高,在模型选取时应考虑在计算成本和故障诊断精度之间进行权衡。由表6可得,CDCGAN c 模型在可接受的计算时间内获得了较好的分类精度,在卷积核数量继续增加时,测试精度并没有得到显著的提升,因此本文在所提出的 CDCGAN 中使用该模型。

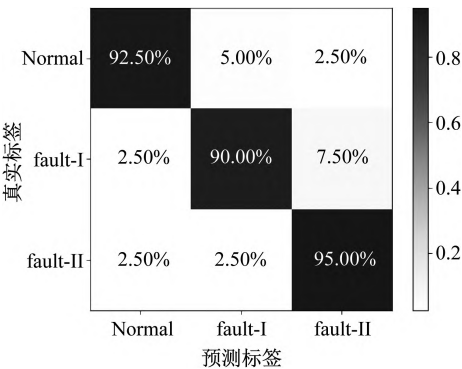


图 8 试验结果混淆矩阵

Fig. 8 Test results confusion matrix

4.2.1 数据的预处理

为了模拟在数据不平衡条件下的效果,数据集的划分如表7所示。

表 7 数据集详细描述

Tab. 7 Detailed description of data set		
故障类型	训练集	测试集
Normal	200	40
Inner (inner-1)	60	40
Inner (inner-2)	60	40
Inner (inner-3)	60	40
Outer(outer-1)	60	40
Outer(outer-2)	60	40
Outer(outer-3)	60	40
Ball(ball-1)	60	40
Ball(ball-2)	60	40
Ball(ball-3)	60	40

4.2.2 CDCGAN 的训练过程

图 9 为凯斯西储大学轴承数据集中前 64 个样本训练生成的样本随着 epoch 增加所发生的变化。






图 9 凯斯西储大学轴承数据生成样本

Fig. 9 Case western reserve university bearing data set generates samples

由图 10 可以看出,模型在训练初期损失函数较为平滑,在训练后期波动幅度较小,在总体趋势上,判别器和生成器的损失函数稳定在一个范围内。



(a) 生成器 loss



(b) 判别器 loss

图 10 loss 值变化趋势

Fig. 10 Variation trend of loss value

4.2.3 故障诊断结果分析

图 11 中 loss2 和 acc2 是模型引入余弦退火算法后的损失函数和准确率的变化趋势,相比于初始模型损失函数值和准确率值的变化趋势,引入余弦退火算法的模型在训练过程中稳定性更好。

训练集中正常数据包含 200 个真实样本,故障数据每类 60 个真实样本,140 个生成样本,共 2 000 个样本来训练 CNN 分类模型。用于对比的模型参数结构与上个试验相同,故障诊断精度如表 8 所示。

单次试验的混淆矩阵如图 12 所示,试验结果表明本文所提模型不仅能在数据标签条件的限制下生成预

期的样本,还能够利用卷积层提取特征的能力生成高质量的样本,并且模型有着较强的泛化能力,在样本数据不平衡的条件下,改进的 CDCGAN 网络模型对数据进行扩充能够有效地提高故障诊断的精度。




图 11 模型 Loss 值和准确率值变化情况

Fig. 11 Changes of loss value and accuracy value of the model

表 8 故障诊断精度

Tab. 8 Fault diagnosis accuracy

方法	平均精度/%	MSE
MACDCGAN	99.73	0.14
WT-CDCGAN-CNN	99.36	0.16
WT-DCGAN-CNN	99.12	0.18
WT-CGAN-CNN	98.97	0.21
WT-GAN-CNN	98.64	0.22
WT-CNN	98.41	0.25
CNN(1D)	89.53	0.54
LSTM	75.76	0.87
SAE	76.89	0.82




图 12 试验结果混淆矩阵

Fig. 12 Test results confusion matrix

5 结 论

本文提出的 MACDCGAN 的发电机故障诊断方法,使用小波变换对一维时序信号进行特征增强,将时序信号转换为时频域的图像样本,改进条件深度卷积生成对抗网络模型扩充数据集,使用学习率衰减的二维

卷积神经网络模型进行故障分类,解决了在故障样本数据有限条件下使用基于深度学习的方法进行故障诊断存在过拟合导致模型泛化能力较差以及诊断精度不高的问题。

试验结果表明,本文所提方法相比于其它几种深度学习有较好的故障分类效果,在不平衡数据集的条件下也有较高的诊断精度,对于不同的数据集,本文方法的故障诊断准确率更高,证明本文模型的泛化能力优于其它对比的网络模型。下一步将针对生成器模型和判别器模型在训练过程中训练速度较慢等问题进行深入研究。

参 考 文 献

- [1] ZHANG Z, LI W, JIA X. CFD Investigation of a Mobula Birostris-based bionic vortex generator on mitigating the influence of surface roughness sensitivity of a wind turbine airfoil[J]. IEEE Access, 2020, 8: 223889-223896.
- [2] YI C, QIN J, XIAO H, et al. Second-order synchro squeezing modified S transform for wind turbine fault diagnosis[J]. Applied Acoustics, 2022, 189: 108614.
- [3] LIM D H, KIM K S. Development of deep learning-based detection technology for vortex-induced vibration of a ship's propeller[J]. Journal of Sound and Vibration, 2021, 509: 116629.
- [4] ZHANG T, LIU S, WEI Y, et al. A novel feature adaptive extraction method based on deep learning for bearing fault diagnosis[J]. Measurement, 2021, 185: 110030.
- [5] 陈保家, 陈学力, 沈保明, 等. CNN-LSTM 深度神经网络在滚动轴承故障诊断中的应用[J]. 西安交通大学学报, 2021, 55(6): 28-36.
CHEN Baojia, CHEN Xueli, SHEN Baoming, et al. Application of CNN-LSTM deep neural network in fault diagnosis of rolling bearings[J]. Journal of Xi'an Jiaotong University, 2021, 55(6): 28-36.
- [6] HUANG K, WU S, LI F, et al. Fault diagnosis of hydraulic systems based on deep learning model with multirate data samples[J]. IEEE Transactions on Neural Networks and Learning Systems, 2021, 33(11): 6789-6801.
- [7] ZOU Y, ZHANG Y, MAO H. Fault diagnosis on the bearing of traction motor in high-speed trains based on deep learning[J]. Alexandria Engineering Journal, 2021, 60(1): 1209-1219.
- [8] WANG X, MAO D, LI X. Bearing fault diagnosis based on vibro-acoustic data fusion and 1D-CNN network[J]. Measurement, 2021, 173: 108518.
- [9] SARAVANAKUMAR R, KRISHNARAJ N, VENKATRAMAN S, et al. Hierarchical symbolic analysis and particle swarm optimization based fault diagnosis model for rotating machineries with deep neural networks[J]. Measurement, 2021, 171: 108771.
- [10] ZHOU F, YANG S, FUJITA H, et al. Deep learning fault diagnosis method based on global optimization GAN for unbalanced data[J]. Knowledge-Based Systems, 2020, 187: 104837.
- [11] LIU H, ZHOU J, XU Y, et al. Unsupervised fault diagnosis of rolling bearings using a deep neural network based on generative adversarial networks[J]. Neurocomputing, 2018, 315: 412-424.
- [12] WANG Z, WANG J, WANG Y. An intelligent diagnosis scheme based on generative adversarial learning deep neural networks and its application to planetary gearbox fault pattern recognition[J]. Neurocomputing, 2018, 310: 213-222.
- [13] ZHU Y, ZHUANG F, WANG J, et al. Deep subdomain adaptation network for image classification[J]. IEEE Transactions on Neural Networks and Learning Systems, 2020, 32(4): 1713-1722.
- [14] JIEFEI G U, YANG Q I, ZIYI Z, et al. Fault diagnosis of rolling bearings based on generative adversarial network and convolutional denoising auto-encoder[J]. Journal of Advanced Manufacturing Science and Technology, 2022, 2(2): 2022009.
- [15] 冯永, 张春平, 强保华, 等. GP-WIRGAN: 梯度惩罚优化的 Wasserstein 图像循环生成对抗网络模型[J]. 计算机学报, 2020, 43(2): 190-205.
FENG Yong, ZHANG Chunping, QIANG Baohua, et al. GP-WIRGAN: Wasserstein image cyclic generative adversarial network model with gradient penalty optimization[J]. Journal of Computer Science, 2020, 43(2): 190-205.
- [16] WANG X, GUPTA A. Generative image modeling using style and structure adversarial networks[C]//European Conference on Computer Vision. Cham: Springer, 2016.
- [17] ZHANG D, NING Z Q, YANG B, et al. Fault diagnosis of permanent magnet motor based on DCGAN-RCCNN[J]. Energy Reports, 2022, 8: 616-626.
- [18] ZHU F, HE M, ZHENG Z. Data augmentation using improved cDCGAN for plant vigor rating[J]. Computers and Electronics in Agriculture, 2020, 175: 105603.
- [19] SILIK A, NOORI M, ALTABEY W A, et al. Comparative analysis of wavelet transform for time-frequency analysis and transient localization in structural health monitoring[J]. Structural Durability & Health Monitoring, 2021(1): 015.
- [20] CHENG Yiwei, LIN Manxi, WU Jun, et al. Intelligent fault diagnosis of rotating machinery based on continuous wavelet transform-local binary convolutional neural network[J]. Knowledge-Based Systems, 2021(216): 106796.
- [21] LOSCHILOV I, HUTTER F. Decoupled weight decay regularization[J/OL]. arXiv preprint arXiv: 1711.05101, 2017.