

# 基于换档全过程振动强度的变压器CM型有载分接开关机械故障诊断方法

梁玄鸿, 王有元\*, 古洪瑞

(输变电装备技术全国重点实验室(重庆大学电气工程学院), 重庆市 沙坪坝区 400044)

## A Mechanical Fault Diagnosis Method of Transformer CM-type On-load Tap Changer Based on the Vibration Strength of the Overall Tap Changing Process

LIANG Xuanhong, WANG Youyuan\*, GU Hongrui

(State Key Laboratory of Power Transmission Equipment Technology (School of Electrical Engineering, Chongqing University), Shapingba District, Chongqing 400044, China)

**ABSTRACT:** The main fault type of power transformer on-load tap changer (OLTC) is mechanical fault. Most recent studies only diagnose diverter switch faults, and have difficulty in identifying the transmission mechanism faults affecting the whole process of tap changing. To diagnose the diverter switch and transmission mechanism faults more accurately, a mechanical fault diagnosis method of on-load tap changer based on the vibration strength of the overall tap changing process is proposed in this paper. First, multi-channel vibration burst data during the diverter switch operation is transformed into time-domain waveform images and input into improved convolutional neural network (CNN) to obtain pooling layer features. Then, the vibration strength feature of the overall tap changing process is proposed. The vibration signal of overall tap changing process is divided into multiple intervals, and the number of points in each interval whose amplitude exceeds the threshold is counted to characterize the average vibration strength in the interval. Finally, a novel feature processing method is proposed to change the relative size of the above two features, and the features are fused to train classifier for mechanical fault diagnosis. The case analysis shows that compared with the existing OLTC mechanical fault diagnostic methods, the proposed method can effectively identify transmission mechanism faults, further improve the diagnostic accuracy of diverter switch faults, and achieve strong robustness and generalizability, which provides a new idea for OLTC mechanical fault diagnosis.

**KEY WORDS:** on-load tap changer (OLTC); mechanical fault;

fault diagnosis; convolution neural network (CNN); feature extraction; feature processing

**摘要:** 变压器有载分接开关(on-load tap changer, OLTC)的主要故障类型是机械故障, 现有大多数研究仅诊断切换开关故障, 难以辨识影响换档全过程的传动机构故障。为准确诊断切换开关与传动机构故障, 该文提出一种基于换档全过程振动强度的 OLTC 机械故障诊断方法。首先, 将多通道切换开关振动爆发数据转换为时域波形图输入改进的卷积神经网络(convolutional neural network, CNN), 以获取池化层特征。然后, 提出换档全过程振动强度特征, 将换档全过程振动信号划分为多个区间, 统计各区间中幅值超过阈值的点数, 以表征各时间段平均振动强度。最后, 提出一种新的特征处理方法改变以上两种特征的相对大小, 并融合两种特征训练分类器诊断机械故障类型。实例分析表明: 相比于现有 OLTC 机械故障诊断方法, 所提方法能有效辨识传动机构故障, 进一步提升对切换开关故障的诊断精度, 具有较强的鲁棒性与泛用性, 可为 OLTC 机械故障诊断研究提供新的思路。

**关键词:** 有载分接开关; 机械故障; 故障诊断; 卷积神经网络; 特征提取; 特征处理

## 0 引言

有载分接开关(on-load tap changer, OLTC)是有载调压变压器的重要部件之一, 它通过切换绕组的分接头改变运行中的电力变压器电压比<sup>[1]</sup>。现有的有载调压变压器普遍安装机械式 OLTC, 该类 OLTC 作为变压器唯一频繁运动的部件, 长期工作在高电压、大电流的环境下, 易发生构件磨损、烧蚀等故障<sup>[2]</sup>。据故障类型统计分析, OLTC 故障占有载调压变压器故障的 20%, 其中机械故障占比高

基金项目: 国家自然科学基金(重点项目)(51637004)。

Project Supported by National Natural Science Foundation of China (Key Program)(51637004).

达 70%<sup>[3]</sup>。某些电气故障也是由于操作机构或切换部件故障引起的<sup>[2]</sup>。据故障部位统计分析,在 OLTC 一次设备故障中,开关本体、传动机构故障占比分别为 68%和 32%<sup>[4]</sup>。OLTC 传动机构缺陷可引起分接头不同步、压力释放阀误动、分接开关跳闸与滑档等多种突发性故障<sup>[4]</sup>。OLTC 故障将直接影响变压器电压比调节准确性,从而影响电力系统的稳定与安全,具有预警和处理的紧迫性。因此,准确的 OLTC 机械故障诊断对电力系统的正常运行起着至关重要的作用。

在机械式 OLTC 换档过程中,传动机构传输电机动力,使分接选择器、切换开关等部件按序动作,换档过程产生的振动信号蕴含丰富的状态信息,因此振动分析法已成为 OLTC 机械故障诊断领域的研究热点<sup>[5-10]</sup>。OLTC 振动分析法包含振动爆发数据选取、特征提取以及故障诊断 3 个过程,其中振动爆发(vibration burst)在以往文献中被定义为换档过程产生的高幅值冲击振动数据<sup>[1]</sup>。

用于识别切换开关故障的振动爆发数据具有非平稳、非线性的特性,难以通过时域分析提取特征。因此,一些学者研究了基于经验模态分解(empirical mode decomposition, EMD)的时频域特征提取方法<sup>[5-7]</sup>。近年来,基于 EMD 的研究使用优化方法选取 EMD 重要参数<sup>[5-7]</sup>,并基于分解结果提取多种特征以诊断故障。文献[8]基于动态时间规整(dynamic time warping, DTW)计算待诊信号与参考信号的距离,从而诊断故障。文献[9]以相空间重构方法,将振动数据转换为相点距离映射递归矩阵的灰度图,将图像输入卷积神经网络(convolutional neural network, CNN)诊断故障,降低了处理振动数据的经验需求。文献[10]通过贝叶斯估计相空间融合生成振动信号的相空间奇异值,并通过轮廓图改进的支持向量数据描述(support vector data description, SVDD)算法进行故障诊断。上述方法能有效诊断切换开关故障。然而,文献[5-7]设计特征以及文献[8]选取参考信号对信号分析经验要求较高,文献[9-10]使用的相空间重构对不同工况样本的最佳参数不同,若使用统一参数,则某些工况的信号处理效果可能欠佳。鉴于不同工况对切换开关振动爆发波形影响差异明显,本文基于时域波形图像,使用更高效的 CNN 挖掘其波形特征,以进一步降低信号分析的经验需求。

而传动机构故障则与切换开关故障相反,影响

整个换档过程的齿轮传动,但对切换开关动作影响较小。此时,切换开关振动爆发等于正常工况的切换开关动作振动与故障的传动振动叠加,其中大部分能量源于切换开关动作,仅分析切换开关振动爆发可能难以区分传动机构故障。因此,有必要将数据分析区域扩展到完整信号,结合完整信号提取的特征与切换开关振动爆发的特征,更准确地诊断切换开关与传动机构故障。

为了高效地使用上述两种特征诊断 OLTC 机械故障,需要使用传统的标准化、归一化等方法处理特征,使各类特征值的分布范围相近。这些方法先验地认为所有特征在分类器中重要性相同,但实际上,不同特征的分类准确率存在差异,重要性并不相同。为了更好地提升融合特征的数据质量,仍需进一步研究特征处理方法。

基于以上分析,本文提出一种基于换档全过程振动强度的变压器有载分接开关机械故障诊断方法。首先,将切换开关动作的多通道振动爆发数据转换为时序波形图像输入改进的 CNN,以获取其池化层特征。然后,提出 OLTC 换档全过程振动强度特征,基于训练集数据的幅值分布生成阈值,将振动信号划分为多个区间,以各区间中幅值超过阈值的点数以表征其振动强度。最后,提出一种新的特征处理方法,改变不同特征的相对大小,融合特征训练分类器诊断故障类型。

## 1 OLTC 机械故障诊断方法

### 1.1 总体思路

本文分别提取换档全过程与切换开关振动爆发数据的特征,并使用特征强调方法融合特征,训练分类器以诊断 OLTC 机械故障。总体思路如图 1 所示,步骤如下:

1) 数据采集。使用加速度传感器采集 OLTC 换档全过程中的振动信号;

2) 样本划分。将振动信号随机划分为训练模型的训练集、验证集以及测试集,比例分别为 55%、15%与 30%;

3) 切换开关振动爆发波形特征提取。选取各样本切换开关振动爆发数据,数据时长为 0.1 s,将数据转化为时域波形图像训练改进后的 CNN,再将图像输入已训练 CNN 中,从均值池化层中提取特征,特征维度为 448;

4) 换档全过程振动强度特征提取。根据单通

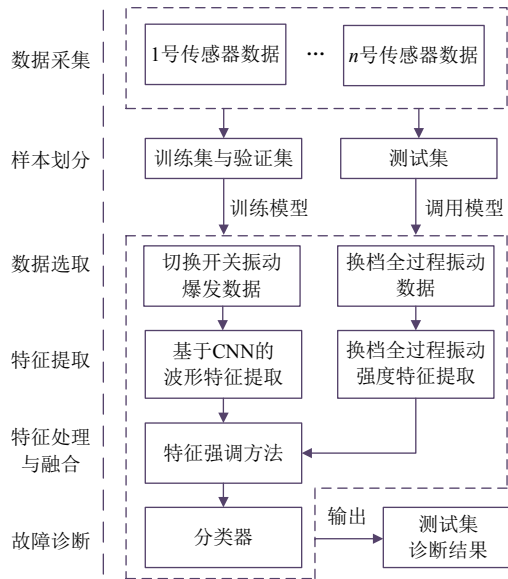


图 1 OLTC 机械故障诊断流程图

Fig. 1 Flow chart of OLTC mechanical fault diagnosis

道换档全过程振动数据训练集的幅值分布设定阈值，完整信号划分为 20 个区间，以各个区间中超过阈值的点数量作为特征值，2 个信号采集通道可提取共 40 维特征；

5) 特征处理与融合。使用特征强调方法改变两种特征的相对大小，再进行两种特征融合，融合后特征维度为 488；

6) 使用融合特征训练故障诊断模型；

7) 测试。将测试集输入已训练好的 OLTC 机械故障诊断模型，输出测试样本的诊断结果。

## 1.2 OLTC 实验数据采集

本文采用的组合式 OLTC 型号为上海华明 CMIII-600Y/126C-10193W，该类 OLTC 主要结构、工作原理与换流变用的 R 型 OLTC 相似<sup>[11]</sup>，即选择开关与切换开关为 2 个独立结构，换档时先选择后切换。该 CM 型 OLTC 换档过程详见参考文献[12]。为模拟 OLTC 在油浸式变压器中的运行环境，实验在充油罐体中进行，其余设置见参考文献[13]。数据采集系统采用电流传感器测量驱动电机电流，以判断开关启动与停止。现有研究以 50 kHz 或 100 kHz 频率采集信号<sup>[7-10]</sup>，考虑到本文模拟的传动机构故障信号频段可能更高，因此使用更高的 128 kHz 频率采集信号。本文故障模拟实验分别在 CM 型 OLTC 顶部与侧壁各安装一个压电式加速度传感器，安装位置如图 2 所示。

实验设置了 8 种状态以模拟各种 OLTC 常见工况，包括正常状态，传动轴齿轮磨损(使用过度磨损的齿轮替换正常的齿轮)、传动轴齿轮卡滞(齿轮盒




图 2 传感器安装位置

Fig. 2 Installation location of sensors

中塞入木屑)、切换开关触头松动(松动了中性点触头以及主通断触头相关螺丝)、弧形板松动(松动了弧形板相关螺丝)、弹簧弹力下降(削短主弹簧 1~2 圈以模拟主弹簧长期工作下弹力下降)、触头磨损(削短主通断触头 1~2 mm 以模拟长期带电切换下的磨损)以及弹簧弹力下降与触头磨损的复合故障。各种故障模拟设置如图 3 所示。




图 3 OLTC 机械故障模拟

Fig. 3 Simulation of OLTC mechanical faults

为降低环境因素对换档过程的影响，进行 3 次全档位奇偶交替切换档位测试，即从第 1 个档位切换到第 2 个档位，再从第 2 个档位切换到第 3 个档位，如此切换到最后 1 个档位为止，再从最后 1 个档位开始切换，直到切换到第 1 个档位结束。每个工况 96 个样本，8 个工况共 768 个样本。对采集后的样本进行快速傅里叶变换频谱分析，频谱值集中

于 50 kHz 以下, 低于本文信号采集系统奈奎斯特频率 64 kHz, 因此本文实验能有效采集到实际信号且不失真。

图 4 为 1 号传感器采集的正常工况以及传动轴齿轮故障下 OLTC 换档全过程振动信号。如图 4 所示, 现有大部分分析切换开关故障的研究均以切换开关振动爆发数据为分析对象<sup>[5-10]</sup>。




图 4 OLTC 不同工况下换档全过程振动信号

Fig. 4 Vibration signals of the OLTC overall tap changing process in different conditions

在图 4 中, 各工况换档过程存在多个明显的齿轮啮合冲击振动, 其冲击时间在 1 ms 以内, 与文献[14]的仿真结果相符。分接选择器开始动作与电机开始停转时齿轮负荷突然变化, 增加了齿轮啮合难度。在传动轴齿轮故障下, 这两个阶段可能出现多次啮合冲击振动, 冲击强度高于正常工况, 如图 4(b)~(d)所示。由于该冲击振动幅值较高, 将其定义为齿轮啮合振动爆发。这些冲击振动是传动

轴齿轮故障、正常工况、切换开关故障的最大区别。因此, 仅以切换开关振动爆发为分析对象, 可能难以诊断传动轴齿轮故障。

### 1.3 基于 CNN 的切换开关振动爆发波形特征提取

由于切换开关动作阶段数据总体在完整信号中幅值最高, 本文参考文献[13]选取切换开关动作阶段振动爆发数据。1 号传感器数据选取结果如图 5 所示, 其中各样本皆从偶数档移动至奇数档位。设奇、偶数档侧分别为 a、b 侧。切换时过渡触头 b、过渡触头 a、主通断触头 a 与主触头 a 按序碰撞, 其中主通断触头 a 与主触头 a 的动作有重合时间, 因此其振动重叠, 如图 5(a)所示。

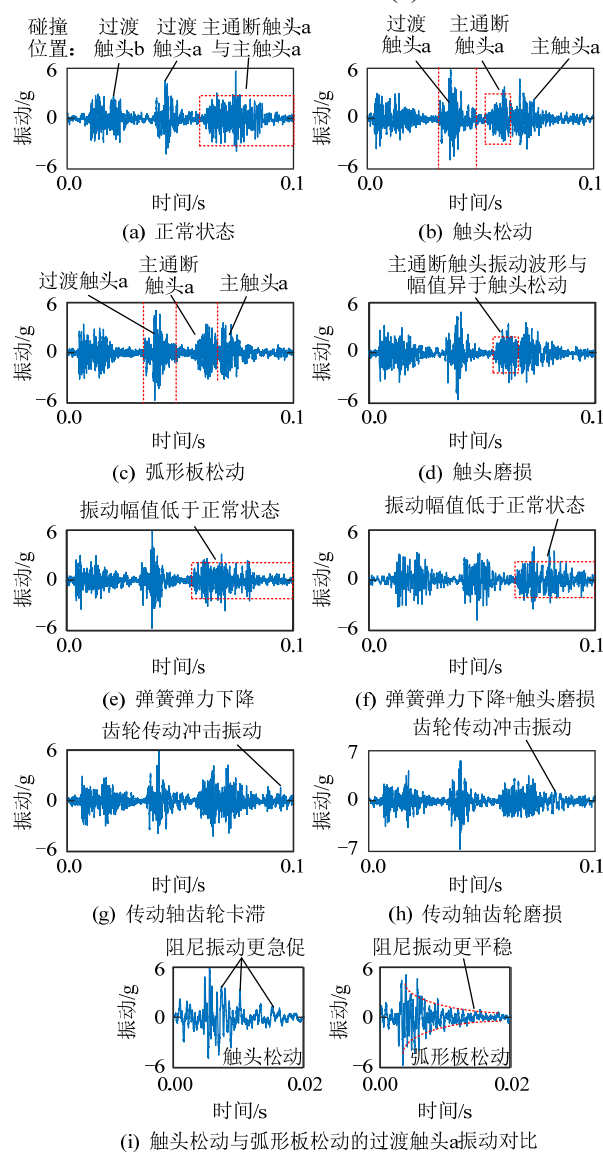


图 5 1 号传感器的切换开关振动爆发数据

Fig. 5 Diverter switch vibration burst data of sensor one  
对其他工况的波形差异分析如下:

1) 触头松动。主通断触头 a 碰撞产生的部分能量转换为触头松动引起的共振抖动, 使其冲击时



间变短, 图 5(b)中主通断触头 a 与主触头 a 的冲击振动波形已明显分离。

2) 弧形板松动。弧形绝缘板上固定多个静触头, 该故障对振动爆发波形影响更大, 除主通断触头 a 与主触头 a 的振动波形分离之外, 还使过渡触头 a 振动波形的阻尼振动更平稳, 如图 5(c)、(i)所示。

3) 触头磨损。主通断触头 a 的碰撞振动幅值低于正常状态与触头松动, 且其波形异于触头松动, 如图 5(d)所示。

4) 弹簧弹力下降。样本总体振动幅值下降, 其中最后一段振动爆发幅值下降较为明显, 如图 5(e)所示。

5) 弹簧弹力下降+触头磨损。波形与弹簧弹力下降较为相似, 触头磨损故障使其最后一段振动爆发与弹簧弹力下降略有差异, 如图 5(f)所示。

6) 传动轴齿轮故障。切换完成后出现明显的齿轮传动产生的冲击振动, 如图 5(g)、(h)所示。

以上不同工况的振动爆发波形虽然可通过人工经验分析其差异, 但仍难以通过人工设计特征以量化差异, 并自动识别不同工况。而卷积神经网络因其强大的自动特征提取能力, 已被广泛应用于轴承、齿轮箱等领域的机械故障诊断<sup>[15-17]</sup>。由于不同工况的振动爆发波形图像已具有一定的差异性, 因此本文将波形图像作为输入, 使用高效的残差网络(ResNet)<sup>[18]</sup>自动提取振动爆发波形特征。本文中工况数量与样本数远小于 ImageNet 数据规模<sup>[18]</sup>, 直接使用 ResNet 训练可能因网络参数过多而发生过拟合。因此, 本文减少 ResNet 深度以及卷积核以适配诊断任务, 并通过贝叶斯优化方法<sup>[19]</sup>获取初始学习率、L2 正则化、随机梯度下降的动量值以及网络结构等参数的最优组合, 优化时长为 8 h。其中, 网络结构优化参数范围如表 1 所示。网络输入的多通道数据归一化图像如图 6 所示。网络结构如图 7 所示, 其中卷积模块为卷积层、BN 层以及 Relu 层串联。

表 1 网络结构优化参数范围

Table 1 Optimization ranges of network architecture parameters

网络结构参数名称	参数范围
残差模块数	4、6、8
首个卷积层的卷积核个数	16、24、32、40、48、56、64

CNN 训练完成后, 可将图像输入已训练 CNN, 提取任意层输出作为特征<sup>[13]</sup>。网络深层输出特征含有更丰富的分类信息, 因此本文将均值池化层输出




图 6 多传感器数据归一化图

Fig. 6 Image of multi-sensor normalized data

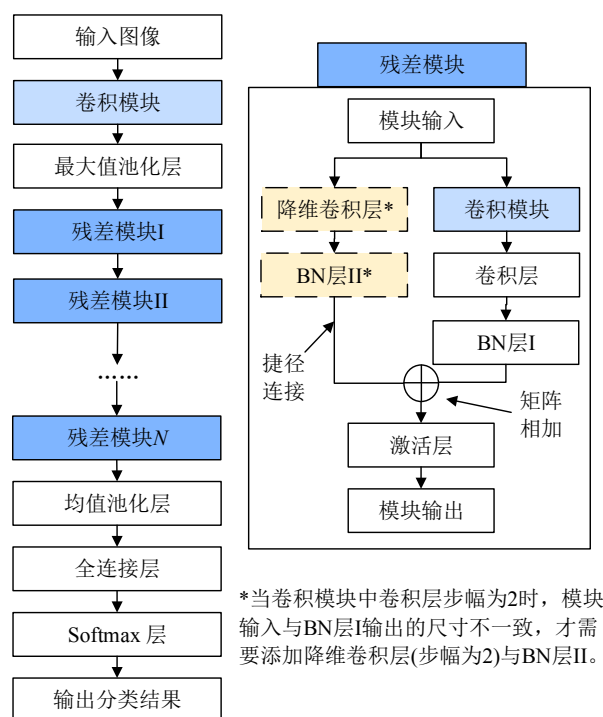


图 7 改进 ResNet 示意图

Fig. 7 Schematic diagram of improved ResNet

一维化作为特征, 本文中该特征维度为 448。

#### 1.4 换档全过程振动强度特征提取

图 8 为所有样本第 2~3.5 s 平均传动振动幅值, 其中齿轮故障振动幅值比正常工况更高, 弹簧弹力下降与切换开关相关的故障振动幅值比正常工况更低。以触头松动与弧形板松动为例, 由于切换开关与传动机构距离短, 其构件松动产生的共振抖动将影响振动传播过程, 吸收部分振动能量, 减小传播到罐体表面的振动幅值。因此, 除了切换开关振动爆发数据, 换档过程传动振动幅值也可用于区分不同工况。

振动信号的特征提取一般以时频域分析为主。以文献[15]为例, 由于机械轴承信号振动幅值相对




图8 1号传感器样本第2~3.5s平均传动振动幅值统计

Fig. 8 Statistics of average transmission vibration amplitude of samples at 2~3.5s from sensor one

平稳,使用完整信号的多种时频域统计特征即可准确诊断机械轴承故障。但本文研究的 OLTC 换档全过程信号振动幅值变化急剧,难以根据简单的时频域统计特征进行分析。因此,本文提出“换档全过程振动强度”特征,其定义为换档全过程多个时间段的平均振动强度,通过特征向量表征完整信号的振动幅值变化情况。其物理意义在于,较小的特征值代表该时间段为振动传动,较大的特征值代表该时间段出现振动爆发。

特征计算流程如附表 A1 所示,对训练数据集各样本数据从大到小进行排序,取所有样本第  $q \times n$  个序号数据生成数组  $b$ ,以数组  $b$  中的最大值作为自适应阈值,按步长划分完整信号,统计每个区域中幅值超过阈值的点数作为特征值。其中  $q \in (0,1)$ ,为阈值提取比例, $n$  为样本点数。


该算法需要选取 2 个参数,选取依据分析如下:

1) 提取步长  $r$ 。该参数需要大于一个完整的振动爆发时长,以尽量避免将振动爆发拆分为多个冲击振动,丢失关键信息。图 4 中振动爆发时长约 0.1~0.2s,故本文提取步长  $r=0.25$ s。每个样本时长为 5s,单通道每个样本可提取 20 个特征值。

2) 阈值提取比例  $q$ 。该参数越大,提取得到的阈值越小,各时间段大于阈值的点数越多,因此特征值越大,反之亦然。 $q$  值过小将导致部分特征值过于接近 0; $q$  值过大将导致不同工况的特征值差距缩小;这两种情况都将降低不同工况特征值的区分度。因此,本文取其取值范围的中间值, $q=50\%$ 。

所有样本的特征值的平均值如图 9 所示。从

图 9 可知,正常工况特征值与其他故障差异明显。传动轴齿轮故障特征值显著大于其他故障,而两种齿轮故障的差异主要在代表传动振动的特征值。对于与切换开关相关的故障,也可通过代表传动过程的特征值进行区分。上述分析表明该特征可有效区分不同工况。

图9 1号传感器样本振动强度特征值平均值  
( $q=0.5, r=0.25$ s)Fig. 9 Averages of vibration burst strength of samples from sensor one ( $q=0.5, r=0.25$ s)

### 1.5 特征强调方法

为了使分类器更高效地学习特征,本文提出“特征强调”的特征处理方法。使用在众多机器学习分类器中性能较优的支持向量机(support vector machine, SVM)作为故障诊断的分类器<sup>[20]</sup>。以下将基于 SVM 进行分析,进而说明特征相对大小对建模过程的影响。

对于数据集  $D=\{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_n, y_n)\}$ ,  $y_i \in \{-1, +1\}$ ,  $i=1, 2, \dots, n$ , SVM 需要在原始特征空间中寻找的最优超平面定义为

$$\begin{cases} \mathbf{w}^T \mathbf{x} + b = 0 \\ \text{s.t. } y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1, i = 1, 2, \dots, n \end{cases} \quad (1)$$

式中:  $\mathbf{w}=(w_1, w_2, \dots, w_d)$ 与  $b$  分别为权重与偏置系数; $d$  为特征维数。

由于原始特征空间不一定能得到有效区分样本类型的超平面,需要将原始特征空间映射至高维空间,设映射函数为  $\phi(\cdot)$ 。为了避免寻优过程中直接计算高维特征的内积  $\phi(\mathbf{x}_i)^T \phi(\mathbf{x}_j)$ ,该算法引入核函数  $k[\phi(\mathbf{x}_i), \phi(\mathbf{x}_j)]$ 。典型的线性核函数为

$$k[\phi(\mathbf{x}_i), \phi(\mathbf{x}_j)] = \mathbf{x}_i^T \mathbf{x}_j \quad (2)$$

假设特征  $\mathbf{x}$  具有  $n$  维变量,其中前  $n-1$  维特征具有相似的数值分布  $h$ ,第  $n$  维特征的数值分布为

$h \times 10^{-g}$ ,  $g$  为整数,  $g \geq 1$ 。记第  $i$  个样本的第  $m$  个特征数值为  $x_{i,m}=h_{i,m}$ , 第  $n$  维特征数值为  $x_{i,n}=h_{i,n} \times 10^{-g}$ 。此时, 式(2)中的内积为

$$k[(\phi(\mathbf{x}_i), \phi(\mathbf{x}_j))] = x_{i,n}x_{j,n} + \sum_{m=1}^{n-1} x_{i,m}x_{j,m} = h_{i,n}h_{j,n} \times 10^{-2g} + \sum_{m=1}^{n-1} h_{i,m}h_{j,m} \quad (3)$$

式(3)中第  $n$  维变量对内积几乎没有影响, SVM 将难以学习第  $n$  维变量与分类标签的关联。因此, 特征值之间的相对大小将影响 SVM 的建模过程。本文提出特征强调方法, 使处理的特征值分布总体大于参考特征值的分布, 计算方法如下:

$$W_i^* = W_i \times v \times 10^{O(I_{\max}) - O(W_{i,\max})} \quad (4)$$

式中:  $W_i$  为第  $i$  个需要强调的特征;  $W_i^*$  为强调后的特征;  $O(I_{\max})$  为参考特征最大值的数量级, 参考特征的维数不限;  $O(W_{i,\max})$  为第  $i$  个需要处理的特征中最大值数量级, 在本文中数值 0 的数量级定义为 0;  $v \in [1, 10]$ ,  $v$  为放大系数, 由于难以通过经验确认  $v$  值, 本文中  $v$  分别取 1、3、5、7、9, 自动以准确率最高者为最终的  $v$  值。

为体现使用不同来源的特征对最优超平面的贡献程度, 本文提出单类特征贡献度指标:

$$C = \frac{\sum_{j=1}^m \sum_A |w_j| |x_{i,j}|}{\sum_{j=1}^n \sum_A |w_j| |x_{i,j}|} \quad (5)$$

式中:  $C$  为某类特征的贡献度;  $n$  为总特征维度;  $m$  为该特征维度;  $x_{i,j}$  为支持向量集  $A$  中  $\mathbf{x}_i$  的第  $j$  个特征值;  $w_j$  为特征值权重。式(1)中的  $b$  只影响超平面的“位置”而不影响其“结构”, 因此贡献度与  $b$  无关。多分类 SVM 的贡献度为其多个二分类 SVM 的贡献度平均值, 因此  $C \in [0, 1]$ 。

## 2 实例验证与分析

### 2.1 实验数据集描述及划分

2.2 节至 2.6 节中使用 OTLC 机械故障模拟实验数据分析。2.7 节为验证本文方法的泛用性, 使用美国凯斯西储大学(Case Western Reserve University, CWRU)轴承数据中心实验数据进行分析。在使用深度学习网络训练时, 样本随机划分为训练集、验证集以及测试集, 比例分别为 55%、15% 与 30%, 在使用 SVM 进行训练时, 样本随机划分为训练集与测试集的比例分别为 70% 与 30%。本文进行 20 次随机

重新划分数据集的测试, 其中各工况比例保持不变。

### 2.2 改进前后 ResNet 收敛过程对比

图 10 为网络改进前后训练 60 轮的过程对比。图中改进后网络的残差模块数为 8, 首个卷积层卷积核个数为 56, 改进后网络参数从 11.1M 个减少至 8.5M 个, 因此其训练速度比 ResNet 更快。改进后验证集准确率更高, 在约 160 s 时训练已收敛, 验证集准确率整体上与训练集准确率接近。而 ResNet 在约 190 s 时训练已收敛, 但验证集准确率显著低于训练集准确率, 网络已过拟合。以上分析表明: 本文提出的改进方法可提升网络性能, 加快网络训练效率, 避免网络因参数过多而过拟合。

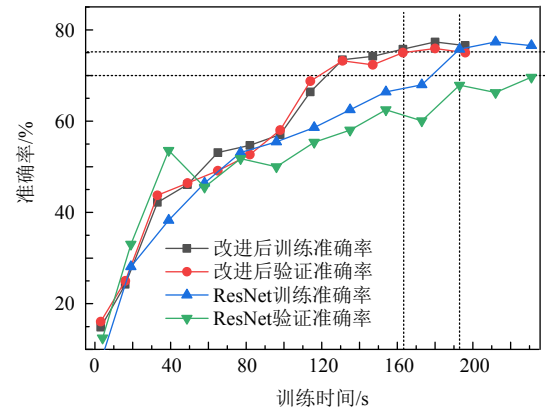


图 10 残差网络训练过程图

Fig. 10 Diagram of ResNet training processes

### 2.3 换档全过程振动强度特征参数选取分析

图 11 为不同参数组合下振动强度特征值统计结

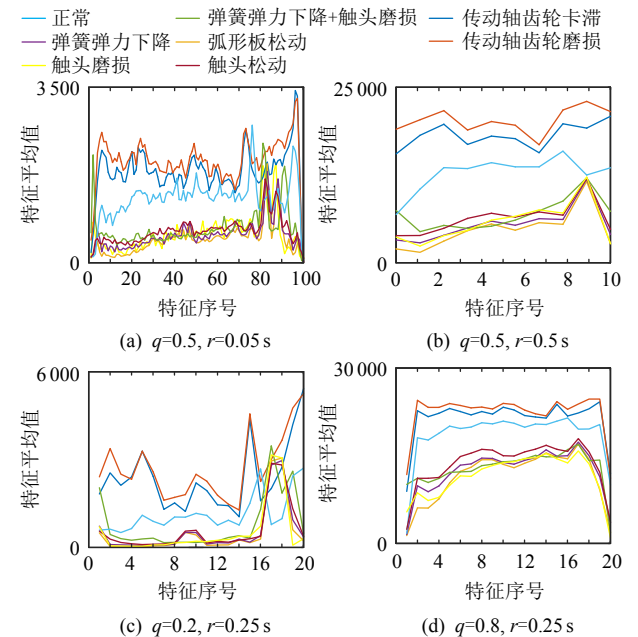


图 11 不同参数组合的振动强度特征平均值

Fig. 11 Averages of vibration strength features in different parameter combinations



果。表 2 为不同参数组合下特征值的 20 次测试的准确率对比结果。将影响各参数的因素作如下分析：

表 2 不同参数组合诊断准确率对比

Table 2 Comparison of diagnostic accuracies of different parameter combinations %		
参数组合( $q$ 与 $r$ )	平均测试准确率	准确率标准差
$q=0.5, r=0.05s$	87.05	1.73
$q=0.5, r=0.1s$	88.12	1.87
<b><math>q=0.5, r=0.25s</math></b>	<b>90.02</b>	<b>1.93</b>
$q=0.5, r=0.5s$	87.95	1.53
$q=0.2, r=0.25s$	82.56	2.87
$q=0.3, r=0.25s$	87.80	2.58
$q=0.7, r=0.25s$	89.89	1.50
$q=0.8, r=0.25s$	88.86	1.70
$q=0.2, r=0.05s$	78.88	3.04
$q=0.2, r=0.1s$	83.28	2.92
$q=0.8, r=0.05s$	87.97	1.79
$q=0.8, r=0.5s$	85.32	2.02

1) 提取步长  $r$ 。对比图 9 与图 11(a)、(b)可知,  $r$  值越大, 单个区间内大于阈值点数越多, 特征值也就越大。 $r$  取不同值时, 该特征值仍能反映信号幅值变化, 因此在表 2 中  $q=0.5$  下各参数组合的准确率差距较小。

2) 阈值提取比例  $q$ 。对比图 9 与图 11(c)、(d)可知,  $q$  值直接影响阈值大小, 从而改变特征向量数值与“形状”。图 11(c)中特征计算阈值较大, 虽然特征向量“形状”与图 9 较为相似, 但切换开关相关故障的部分特征值已接近于 0, 这些故障的区分度降低, 在表 2 中该参数组合的准确率大幅下降至 82.56%。而图 11(d)中特征计算阈值较小, 导致特征数值较大, 特征区分度下降, 因此在表 2 中该特征组合准确率略有下降。

3) 综合表 2 可知,  $q$  值对准确率影响更显著, 其中过低的  $q$  值使准确率大幅下降至 78.88%。在  $q$  值固定的情况下,  $r$  值对准确率影响较小, 因此使用本文方法提取振动强度特征时, 可优先选取  $q$  值。

2.4 本文 OLTC 机械故障诊断准确率分析

表 3 给出采用本文所提方法的诊断准确率, 其中融合特征使用特征强调方法预处理, 以 CNN 图像特征为参考特征, 以振动强度特征为强调特征。图 12 为各类特征某次测试的混淆矩阵。

从图 12(a)、(b)可知, CNN 波形特征与振动强度特征主要在切换开关相关故障之间与传动轴齿轮故障之间混淆。图 12(c)中融合特征显著降低了混淆程度。如表 3 所示, 融合特征显著提高了诊断平

表 3 特征融合前后诊断准确率对比

Table 3 Comparison of diagnostic accuracies between before and after feature fusion %		
特征类型	平均准确率	准确率标准差
CNN 波形特征	84.78	2.18
振动强度特征	90.02	1.93
融合特征	94.33	1.53

(a) CNN提取特征

(b) 振动强度特征

(c) 融合特征

图 12 不同特征混淆矩阵

Fig. 12 Confusion matrixes of different features

均准确率, 降低了准确率标准差。以上结果表明, 本文将数据分析区域扩展至换档全过程, 不仅可以识别传动机构故障, 还可以结合切换开关振动爆发数据, 进一步提升切换开关故障的诊断精度。

2.5 特征处理方法性能对比

表 4 为对融合特征使用不同特征处理方法的诊断准确率, 表中“特征强调”的平均准确率与准确率标准差均为最优。图 13 为不同特征处理方法贡献度柱状图, 图中“特征强调”的振动强度特征贡

表 4 不同特征处理方法的测试准确率对比

Table 4 Comparison of diagnostic accuracies between different feature processing methods %		
特征处理方法	平均准确率	准确率标准差
标准化	93.10	1.65
归一化	91.31	1.30
特征强调	94.33	1.53




图 13 特征贡献度柱状图

Fig. 13 Bar graph of feature contribution degrees



献度比其他两种方法显著提高。这说明了特征强调方法仅通过特征预处理即能使 SVM 建模过程中更多地学习振动强度特征,提升诊断准确率,该方法为特征预处理提供了新的思路。

## 2.6 与现有 OLTC 机械故障诊断方法对比

表 5 对比了 DTW<sup>[8]</sup>、距离映射递归图-卷积神经网络(distance mapping recurrence plot-convolutional neural network, DMRP-CNN)<sup>[9]</sup>、轮廓域图-支持向量数据描述(contour map-support vector data description, CM-SVDD)<sup>[10]</sup>与本文方法的测试准确率。现有方法混淆矩阵如图 14 所示。

表 5 不同 OLTC 机械故障诊断方法的性能比较

Table 5 Performance comparison between different OLTC mechanical fault diagnosis methods %

故障诊断方法	DTW	CM-SVDD	DMRP-CNN	本文方法
T1-正常	24.14	0	3.45	100.00
T2-触头松动	65.52	0	17.24	100.00
T3-弧形板松动	86.21	62.07	44.83	86.21
T4-弹簧弹力下降	24.14	58.62	68.97	89.66
T5-触头磨损	27.59	0	24.14	96.55
T6-弹簧弹力下降+触头磨损	41.38	0	17.24	100.00
T7-传动齿轮卡滞	20.69	82.76	41.38	89.66
T8-传动齿轮磨损	10.34	41.38	10.34	93.10
平均准确率	37.50	30.60	28.45	94.40
平均准确率(训练 20 次)	35.54	31.51	14.63	94.33
准确率标准差(训练 20 次)	6.73	2.13	5.79	1.53




图 14 不同方法的混淆矩阵

Fig. 14 Confusion matrix of different methods

由表 5 与图 14 可知,3 种方法的平均准确率较低,其中 DTW 主要混淆了弹簧弹力下降与其他工况,CM-SVDD 与 DMRP-CNN 主要混淆了传动轴齿轮故障与其他工况。上述结果表明,仅使用切换开关振动爆发数据的现有方法难以同时诊断传动机

构故障以及切换开关相关的复合故障。而本文方法能有效识别各类故障,证明了本文方法的有效性。

## 2.7 泛用性对比

目前,暂无 OLTC 机械故障公开数据集,本文使用已广泛应用于验证机械故障诊断方法有效性的 CWRU 电机轴承实验数据集,进一步验证本文所提方法的泛用性与鲁棒性<sup>[15-16, 21]</sup>。

实验采样频率为 12 kHz,从驱动端、风扇端以及基座端 3 个部位分别设置加速度传感器采集数据。实验通过电火花加工实现对轴承的点蚀损伤,其中的损伤直径为损伤裂纹宽度。由于基座端无正常状态数据,本文参考文献[15]仅选取故障状态数据进行分析。数据共有 3 种故障类型,每种类型又分为 3 种故障程度,点蚀直径分别为 0.18、0.36 以及 0.53 mm,共为 9 类故障状态。对滚动体故障、内圈故障、外圈故障按故障程度从小到大分别编号为 F1—F9。每种故障状态又分为 4 种电机转速,对每种故障状态与转速各截取 100 个样本,每个样本 1 200 个采样点,时长 0.1 s,每个采集通道获取 3 600 个样本。风扇端实验样本数据见图 15。

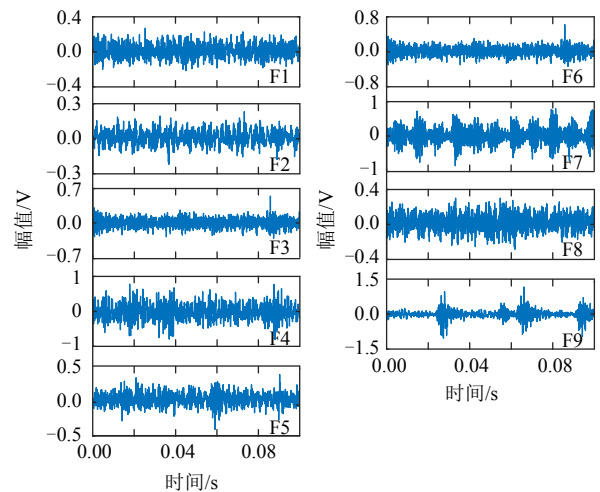


图 15 风扇端振动数据

Fig. 15 Vibration data of fan end

该数据集为周期性振动信号,无需从样本中提取某个阶段的数据。因此,使用本文方法提取两种特征的数据来源都为整个样本。各类样本的振动强度特征值见图 16,此时算法 1 中  $q=50\%$ ,  $r=0.005$  s。虽然机械轴承振动强度相对稳定,但当设置的振动强度提取步长  $r$  足够小时,可将信号视为连续多段冲击振动,如图 16 所示,此时特征能表征信号不同短时间段的振动强度差异。这些特征值与 OLTC 数据集的特征值变化规律差异较大,因此该数据集

对诊断方法的泛用性要求较高，可用于测试不同 OLTC 机械故障诊断方法。

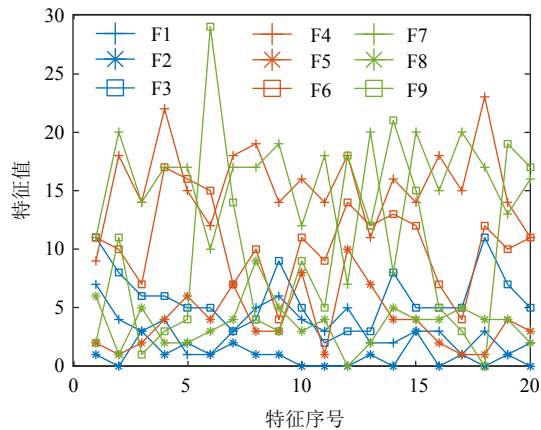


图 16 风扇端各状态样本振动强度特征

Fig. 16 Vibration strength feature of different condition samples from fan end

表 6 对比了文献[15]中 15 个时频域统计特征与 SVM、DTW<sup>[8]</sup>、DMRP-CNN<sup>[9]</sup>、CM-SVDD<sup>[10]</sup>以及本文方法在该数据集上训练 20 次的平均测试准确率及标准差。从表 6 可知，统计特征已达到 99.20% 的平均准确率，说明不同工况对振动信号的影响易于区分，但 DTW、CM-SVDD 以及 DMRP-CNN 难以从信号中提取有效信息，准确率较低，泛用性较差。

表 6 轴承数据集不同故障诊断方法的性能比较

Table 6 Performance comparison between different fault diagnosis methods on bearing dataset			%
故障诊断方法	平均准确率	准确率标准差	
统计特征	99.20	0.27	
DTW	56.33	5.61	
CM-SVDD	58.76	1.43	
DMRP-CNN	24.97	3.57	
本文振动强度特征	86.00	0.64	
本文 CNN 波形特征	96.63	3.23	
本文融合特征+特征标准化	99.50	0.27	
本文融合特征+特征归一化	99.24	0.30	
本文融合特征+特征强调	99.61	0.22	

对表 6 中数据进行分析，可得到以下结论：

1) 采用本文所提方法后振动强度特征平均准确率为 86%，远高于现有 OLTC 故障诊断方法，且标准差较低，说明了该特征泛用性与鲁棒性较好。CNN 波形特征平均准确率达到 96.63%，但准确率标准差较高，达到了 3.23%，说明了 CNN 波形特征泛用性更好，但鲁棒性较差。

2) 本文融合特征后的平均准确率比统计特征更好，准确率标准差大幅下降，证明了本文融合特

征具有较强的泛用性与鲁棒性。其中，基于本文提出的特征强调方法仍优于特征标准化与归一化，证明了本文提出的特征强调方法同样具有泛用性与鲁棒性。

3 结论

为解决现有研究中仅诊断 OLTC 切换开关故障而难以辨识传动机构故障的问题，本文提出了一种基于换档全过程振动强度的 OLTC 机械故障诊断方法。主要工作及结论如下：

1) 现有 OLTC 机械故障诊断方法主要以切换开关动作产生的振动爆发为研究对象，因此现有方法难以识别主要影响传动过程而对振动爆发影响较小的传动机构故障。本文提出的换档全过程振动强度特征，通过自适应阈值计算完整信号多个时间段的平均振动强度，能有效区分切换开关故障与传动机构故障。

2) 各类故障均使振动爆发产生差异显著的波形，但这些差异难以通过人工设计特征以量化分析。使用泛用性强的 CNN 可直接输入信号的时序图像提取有效特征。

3) 针对标准化、归一化等常用的特征预处理方法没有考虑到不同数据之间的重要性差异的问题，本文提出的特征强调方法根据重要性改变不同特征之间的相对大小，从而影响 SVM 建模过程，进一步提升融合特征的诊断准确率。

4) 相比于现有方法，本文提出的故障诊断方法在 OLTC 故障模拟实验数据集与 CWRU 轴承公开数据集实例分析中均达到较高的诊断准确率，具有较强的泛用性与鲁棒性。本文研究可为结构、工作原理相似的 OLTC 提供新的机械故障诊断思路。

参考文献

[1] RIVAS E, BURGOS J, GARCIA-PRADA J. Vibration analysis using envelope wavelet for detecting faults in the OLTC tap selector[J]. IEEE Transactions on Power Delivery, 2010, 25(3): 1629-1636.

[2] 王蕾, 袁洪跃, 王季琴, 等. 变压器有载分接开关技术和故障诊断发展现状及展望[J]. 高压电器, 2022, 58(3): 171-180.

WANG Lei, YUAN Hongyue, WANG Jiqin, et al. Development status and prospect of transformer on load tap changer technology and fault diagnosis[J]. High Voltage Apparatus, 2022, 58(3): 171-180(in Chinese).

- [3] 赵书涛, 王紫薇, 胡经纬, 等. 基于振动信号分析的有载分接开关故障诊断研究综述[J]. 华北电力大学学报: 自然科学版, 2021, 48(5): 11.  
ZHAO Shutao, WANG Ziwei, HU Jingwei, et al. Review on fault diagnosis of on-load tap changer based on vibration signal analysis[J]. Journal of North China Electric Power University, 2021, 48(5): 11(in Chinese).
- [4] 李彦斌, 聂丹, 徐艺璇, 等. 在运有载分接开关故障多维统计分析[J]. 中国安全生产科学技术, 2022, 18(3): 47-53.  
LI Yanbin, NIE Dan, XU Yixuan, et al. Multi-dimensional statistical analysis on faults of on-load tap changer in operation[J]. Journal of Safety Science and Technology, 2022, 18(3): 47-53(in Chinese).
- [5] DUAN R, WANG F. Fault diagnosis of on-load tap-changer in converter transformer based on time-frequency vibration analysis[J]. IEEE Transactions on Industrial Electronics, 2016, 63(6): 3815-3823.
- [6] YAN Y, MA H, WEN M, et al. Multi-Feature fusion-based mechanical fault diagnosis for on-load tap changers in smart grid with electric vehicles[J]. IEEE Sensors Journal, 2021, 21(14): 15696-15708.
- [7] 蔡宇琦, 方瑞明, 彭长青, 等. 基于 ANHGA-VMD 和耦合隐马尔可夫模型的有载分接开关机械故障诊断[J]. 高电压技术, 2021, 47(11): 3949-3959.  
CAI Yuqi, FANG Ruiming, PENG Changqing, et al. Mechanical fault diagnosis of on-load tap-changer based on ANHGA-VMD and coupled hidden markov model[J]. High Voltage Engineering, 2021, 47(11): 1-11(in Chinese).
- [8] YANG R, ZHANG D, LI Z, et al. Mechanical fault diagnostics of power transformer on-load tap changers using dynamic time warping[J]. IEEE Transactions on Instrumentation and Measurement, 2019, 68(9): 3119-3127.
- [9] 曾全昊, 王丰华, 郑一鸣, 等. 基于卷积神经网络的变压器有载分接开关故障识别[J]. 电力系统自动化, 2020, 44(11): 144-151.  
ZENG Quanhao, WANG Fenghua, ZHENG Yiming, et al. Fault recognition of on-load tap-changer in power transformer based on convolutional neural network[J]. Automation of Electric Power Systems, 2020, 44(11): 144-151(in Chinese).
- [10] 王丰华, 曾全昊, 郑一鸣, 等. 基于 Bayes 估计相空间融合和 CM-SVDD 的有载分接开关机械故障诊断[J]. 中国电机工程学报, 2020, 40(1): 358-368.  
WANG Fenghua, ZENG Quanhao, ZHENG Yiming, et al. A mechanical fault diagnosis of on-load tap-changers based on phase space fusion of Bayes estimation and CM-SVDD[J]. Proceedings of the CSEE, 2020, 40(1): 358-368(in Chinese).
- [11] 段若晨. 基于多特征分析的换流变用有载分接开关机械状态评估研究[D]. 上海: 上海交通大学, 2016.  
DUAN Ruochen. Mechanical condition assessment of on-load tap-changer in converter transformer based on multi-feature analysis[D]. Shanghai: Shanghai Jiao Tong University, 2016(in Chinese).
- [12] 祝小松. 基于虚拟样机的有载分接开关典型故障模拟与优化设计方法[D]. 重庆: 重庆大学, 2019: 12-14.  
ZHU Xiaosong. Typical fault simulation and optimum design method of on-load tap-changer based on virtual prototype[D]. Chongqing: Chongqing University, 2019: 12-14(in Chinese).
- [13] LIANG X, WANG Y, GU H, et al. A mechanical fault diagnosis model of on-load tap changer based on same-source heterogeneous data fusion[J]. IEEE Transactions on Instrumentation and Measurement, 2021(71): 1-9.
- [14] ZEYIN H, TAO Z, TENGJIAO L. Novel mathematical modelling method for meshing impact of helical gear[J]. Mechanism and Machine Theory, 2020, 152: 1-12.
- [15] XIA M, LI T, XU L, et al. Fault diagnosis for rotating machinery using multiple sensors and convolutional neural networks[J]. IEEE/ASME Transactions on Mechatronics, 2018, 23(1): 101-110.
- [16] 肖雄, 王健翔, 张勇军, 等. 一种用于轴承故障诊断的二维卷积神经网络优化方法[J]. 中国电机工程学报, 2019, 39(15): 4558-4568.  
XIAO Xiong, WANG Jianxiang, ZHANG Yongjun, et al. A two-dimensional convolutional neural network optimization method for bearing fault diagnosis[J]. Proceedings of the CSEE, 2019, 39(15): 4558-4568(in Chinese).
- [17] SENANAYAKA J, VAN KHANG H, ROBBERSMYR K. Multiple classifiers and data fusion for robust diagnosis of gearbox mixed faults[J]. IEEE Transactions on Industrial Informatics, 2019, 15(8): 4569-4579.
- [18] HE K, ZHANG X, REN S, et al. Deep residual learning for image recognition[C]//Proceedings of IEEE Conference on Computer Vision and Pattern Recognition, Las Vegas, USA, 2016.
- [19] 邹智, 吴铁洲, 张晓星, 等. 基于贝叶斯优化 CNN-BiGRU 混合神经网络的短期负荷预测[J]. 高电压技术, 2022, 48(10): 3935-3945.  
ZOU Zhi, WU Tiezhou, ZHANG Xiaoxing, et al. Short-term load forecast based on Bayesian optimized CNN-BiGRU hybrid neural networks[J]. High Voltage Engineering, 2022, 48(10): 3935-3945(in Chinese).
- [20] WAINBERG M, ALIPANAHI B, FREY B J. Are random forests truly the best classifiers?[J]. Journal of Machine Learning Research, 2016, 15(1): 1-5.
- [21] 李兵, 梁舒奇, 单万宁, 等. 基于改进正余弦算法优化堆叠降噪自动编码器的电机轴承故障诊断[J]. 电工技术学报, 2022, 37(16): 4084-4093.

LI Bing, LIANG Shuqi, SHAN Wanning, et al. Motor bearing fault diagnosis based on improved Sine and cosine algorithm for stacked denoising autoencoders[J] . Transactions of China Electrotechnical Society, 2022, 37(16): 4084-4093(in Chinese).

附录 A

表 A1 换档全过程振动强度特征计算流程

Table A1 Calculation flow of vibration strength feature of the overall tap changing process

输入: 单通道数据集 $X(m, n)$ , 其中 $m$ 为样本数量, $n$ 为序列长度	
振动信号采样率 $f$ , 单位 Hz	
提取步长 $r$ , 单位 s	
阈值提取比例 $q$	
输出: 换档全过程振动强度 $V(m, p)$ , 其中 $m$ 为样本数量, $p$ 为特征维数	
开始	
1	For $i=1:m$
2	$a=\text{descend}[X(m, :)]$ #对单个样本数据排序
3	$b(i) = a(q \times n)$
4	End
5	$T=\max(b)$
6	$l=f \times r$
7	For $i = 1:m$
8	For $j = 1:n$
9	If $X(i, j) > T$
10	$V[i, \text{ceil}(j/l)] += 1$
11	End
12	End
13	End
结束	



梁玄鸿

收稿日期: 2022-11-07。

作者简介:

梁玄鸿(1994), 男, 博士研究生, 主要研究方向为电力设备状态监测与故障诊断, liangxh1@126.com;

\*通信作者: 王有元(1971), 男, 博士, 教授, 博士生导师, 主要研究方向为高电压试验技术, 电力设备在线监测与故障诊断, 数字孪生等, y.wang@cqu.edu.cn;

古洪瑞(1994), 男, 博士研究生, 主要研究方向为电力设备状态监测与故障诊断, guhongrui@cqu.edu.cn。

(编辑 李婧妍, 胡琳琳)



# A Mechanical Fault Diagnosis Method of Transformer CM-type On-load Tap Changer Based on the Vibration Strength of the Overall Tap Changing Process

LIANG Xuanhong, WANG Youyuan\*, GU Hongrui

(State Key Laboratory of Power Transmission Equipment Technology, School of Electrical Engineering(Chongqing University))

**KEY WORDS:** on-load tap changer (OLTC); mechanical fault; fault diagnosis; convolution neural network (CNN); feature extraction; feature processing

The main fault type of power transformer on-load tap changer (OLTC) is mechanical fault. Most recent studies mainly analyze the diverter switch vibration burst data. Therefore, these studies have difficulty in diagnosing the transmission mechanism faults that affect the transmission vibration data but have less impact on the vibration burst data (see Fig. 1). To solve the problem, a mechanical fault diagnosis method of transformer CM-type OLTC is proposed in this paper, extracting pooling layer features from the vibration burst data with convolutional neural network (CNN) as well as vibration strength features from the whole signal of overall tap changing process, and train a support vector machine (SVM) with processed fusion features to diagnose faults.

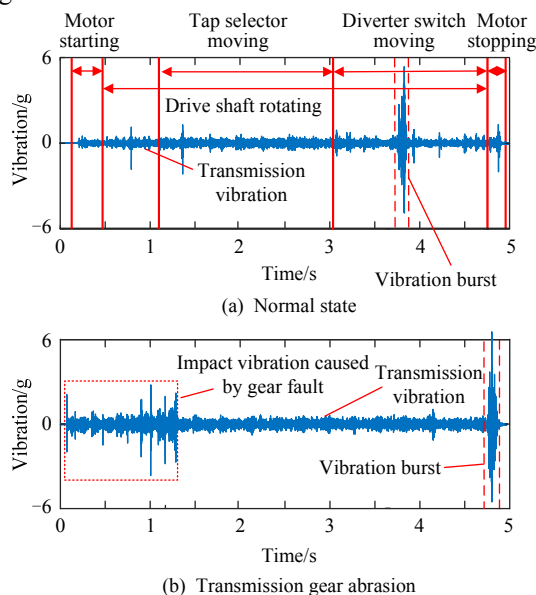


Fig. 1 Vibration signals of overall tap changing process

Firstly, multi-channel vibration burst data during the diverter switch operation is transformed into time-domain waveform images and input into improved

CNN to obtain pooling layer features. And then, the vibration strength feature of the overall tap changing process is proposed. The vibration signal of overall tap changing process is divided into multiple intervals, and the number of points in each interval whose amplitude exceeds the threshold is counted to characterize the average vibration strength in the interval. Finally, a novel feature processing method is proposed to change the relative size of the above two features, and the features are fused to train classifier for mechanical fault diagnosis. The Vibration strength feature average values of different conditions are shown in Fig. 2, and there are obvious differences between the values.

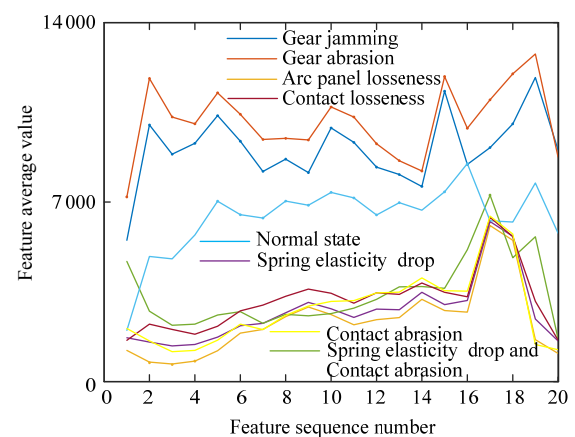


Fig. 2 Vibration strength feature averages of different conditions

The case analysis shows that compared with the existing OLTC mechanical fault diagnostic methods, the proposed method can effectively identify transmission mechanism faults, further improve the diagnosis accuracy of diverter switch faults, and has robustness and generalizability, which provides a new idea for OLTC mechanical fault diagnosis.