

基于改进生成对抗网络的变压器声纹故障诊断

王欢¹, 王昕², 张峰², 齐笑³, 柴方森³, 李文鹏³

(1. 上海电力大学电气工程学院, 上海 200090; 2. 上海交通大学电工与电子技术中心, 上海 200240;
3. 国网吉林省电力有限公司四平供电公司, 吉林 四平 136000)

摘要: 为了提高小样本条件下变压器声纹故障诊断的准确率, 提出了一种基于梅尔声谱图和改进的 Wasserstein 生成对抗网络(IW-GAN)的变压器声纹诊断模型。提取变压器声信号的梅尔声谱图, 将声谱图输入到 IW-GAN 中进行样本扩充。其中, IW-GAN 使用更具表达能力的 Transformer 网络, 判别器采用满足 Lipschitz 连续性约束的 SN-CNN, 从而使 IW-GAN 能够稳定生成多样性和高质量的样本; 将扩充后的数据输入不同的分类器中进行故障分类。实验证明, 所提方法在有效扩充变压器故障声纹数据的同时, 显著提升了小样本情况下变压器声纹故障诊断的整体性能。该方法对不同分类器的识别准确率均有显著提升, 特别是对卷积神经网络分类准确率的提升达到了 6.9%。

关键词: 变压器声纹; 生成对抗网络; 小样本; 故障诊断

中图分类号: TM411

文献标志码: A

文章编号: 2096-4145(2024)04-0024-08

Transformer Voiceprint Fault Diagnosis Based on Improved Generative Adversarial Network

WANG Huan¹, WANG Xin², ZHANG Feng², QI Xiao³, CHAI Fangsen³, LI Wenpeng³

(1. School of Electrical Engineering, Shanghai Electric Power University, Shanghai 200090, China; 2. Center of Electrical & Electronic Technology, Shanghai Jiao Tong University, Shanghai 200240, China; 3. State Grid Jilin Siping Power Supply Company, Siping 136000, China)

Abstract: In order to improve the accuracy of transformer voiceprint fault diagnosis under small sample conditions, a transformer voiceprint diagnosis model based on Mel spectrogram and IW-GAN is proposed. Firstly, the Mel spectrogram of transformer sound signal is extracted, and then the spectrogram is input into IW-GAN for sample expansion. Among them, IW-GAN uses a more expressive transformer network, and the discriminator uses SN-CNN that satisfies Lipschitz continuity constraints. This improvement enables IW-GAN to stably generate diverse and high-quality samples; Finally, the expanded data is input into different classifiers for fault classification. Experimental results show that the proposed method effectively expand the transformer fault voiceprint data and significantly improve the overall performance of transformer voiceprint fault diagnosis under small sample conditions. This method significantly improves the recognition accuracy of different classifiers, especially the recognition accuracy of CNN classifier has been improved by 6.9%.

Key words: transformer voiceprint; generative adversarial network; small sample; fault diagnosis

0 引言

电力变压器作为电网的重要组成部分, 其安全可靠运行对电力系统供电的稳定性和可靠性至关重要。当变压器发生故障时, 可能会产生不同的声

音信号, 这些声音信号蕴含丰富的状态信息, 对变压器故障的有效反映与识别具有重要意义^[1-4]。

目前变压器异常状态的声纹数据十分匮乏且不均衡, 造成深度学习算法过拟合、泛化能力低、训练不稳定等问题^[5], 使得现有方法在小样本变压器故障诊断场景下的识别准确率有限^[5-9]。为此, 有研究采用数据增强技术(Data Augmentation Technology, DAT)^[10-11]对小样本数据集进行扩充, 并调整训练数据的类间分布, 以提高诊断模型的泛化能力和故障识

基金项目: 国家自然科学基金资助项目(12327802)

Project Supported by the National Natural Science Foundation of China (12327802)

别准确率。生成对抗网络(Generative Adversarial Network, GAN)^[12-16]相比传统的数据增强方法,如几何变换法、过采样技术^[17-18]和 Mixup^[19]等,能够生成更高质量、更多样性的合成数据,且能够自适应学习。但传统 GAN 存在梯度消失和模式崩塌的问题,为解决该问题, Martin Arjovsky 等提出的 Wasserstein 生成对抗网络^[20](Wasserstein Generative Adversarial Network, W-GAN),引入了 Wasserstein 距离^[21-22]来替代 JS(Jensen-Shannon)散度,以更有效地度量真实数据分布和生成数据分布之间的距离。然而,尽管该方法在理论上表现出色,但在应用到变压器的声纹故障检测上仍存在一些缺陷:(1)需要针对变压器故障的每个类别单独训练 1 个生成器,使得每个生成器专门生成某个特定类别的样本,对于多类别的变压器故障诊断而言,操作繁琐且耗时较长;(2)为了满足 Lipschitz 连续性约束, W-GAN 规定所有参数矩阵的元素限制在某个范围 $[-c, c]$,但参数总是取到极限值,同时参数 c 也很难确定,选取不好就会引起梯度消失或爆炸,参数矩阵的结构不稳定,以致 W-GAN 收敛速度较慢。

本文提出 1 种基于梅尔声谱图和改进的 Wasserstein 生成对抗网络(Improve Wasserstein Generative Adversarial Network, IW-GAN)的变压器声纹故障识别的方法。其中,在 W-GAN 基础上加入条件约束项,使其更好引导多类别样本生成;同时,提出使用更具表达能力的 Transformer 网络^[23-24]作为生成器,设计满足 Lipschitz 连续性约束的谱归一化^[25]卷积神经网络(Spectral Normalization-Convolutional Neural Network, SN-CNN)作为判别器。Transformer 生成器的多头注意力机制使模型拥有更好的表达能力;结构简洁的 SN-CNN 判别器使得图像生成模型的计算复杂度低,且性能良好。最后采用了多种评价指标评价了在不同的数据增强算法和不同的分类算法下变压器故障诊断的效果,验证了本文模型的有效性。

1 变压器声纹诊断流程

小样本下基于改进生成对抗网络的变压器声纹故障诊断技术,其诊断流程分为数据预处理及特征提取、故障数据增强、诊断模型训练和诊断效果评价 4 个部分。具体流程如图 1 所示。

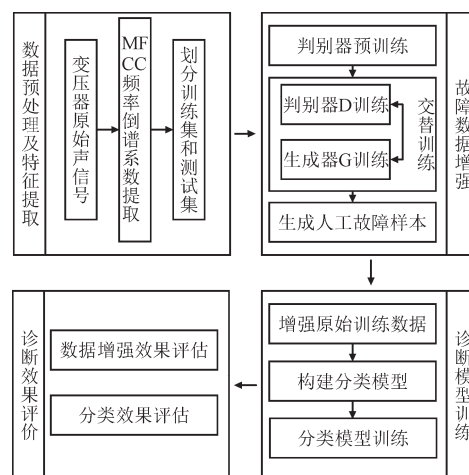


图1 变压器声纹诊断模型整体流程

Fig.1 Overall process of transformer voiceprint diagnosis model

1)在采集到待识别的变压器声纹样本后,将音频进行预处理,并提取梅尔频率倒谱系数(Mel Frequency Cepstral Coefficient, MFCC)^[26-27],沿时间堆叠得到声谱图;对原始数据集进行划分,增量样本与测试样本的比例为 8:2。

2)对 IW-GAN 的判别器 D 进行预训练,以提升其辨别能力,促进生成器 G 的优化;然后将生成器和判别器按 5:1 次数交替训练,直到达到平衡点。

3)用新生成的变压器故障样本对原始训练样本扩充后,输入到不同分类器,如支持向量机(Support Vector Machine, SVM)、长短期记忆网络(Long Short-Term Memory, LSTM)和卷积神经网络(Convolutional Neural Network, CNN)中进行识别。

4)采用 IS(Inception Score)、FID(Fr chet Inception Distance)、KID(Kernel Inception Distance)评价指标对生成效果进行评价,基于准确率、损失率对不同识别模型分类效果比对分析。

2 MFCC 特征提取

MFCC 的计算流程为:

1)预处理,包含预加重、分帧、加窗等。

2)对每一帧的时域信号进行快速傅里叶变换,得到线性频谱 $X(k)$,如式(1)所示:

$$X(k) = \sum_{n=0}^{N-1} x(n)e^{-\frac{j2\pi nk}{N}}, 0 \leq n, k \leq N-1 \quad (1)$$

式中: $x(n)$ 为时域信号; n 为时域上的采样点; k 为频域上的离散频率点; N 为第一帧信号的长度。

3)将 $X(k)$ 通过梅尔三角滤波器组,变换线性频

率到梅尔频率,如式(2)所示:

$$s(m) = \ln \left(\sum_{k=0}^{N-1} |X(k)|^2 H_m(k) \right) \quad (2)$$

式中: $s(m)$ 为第 m 个梅尔滤波器的输出; $H_m(k)$ 为第 m 个滤波器参数。

4) 随后再将得到的梅尔频率取对数后进行离散余弦变换 (Discrete Cosine Transform, DCT), 得到最终的特征参数 MFCC。

$$c(r) = \sum_{b=0}^{P-1} s(m) \cos \left(\frac{\pi r(b-0.5)}{M} \right), 1 \leq r \leq L \quad (3)$$

式中: b 为频率通道索引; M 为梅尔滤波器组的三角滤波器个数; L 为 MFCC 的阶数; $c(r)$ 为第 r 维倒谱系数值; P 为 $s(m)$ 的长度。

3 IW-GAN 数据增强

3.1 W-GAN 的原理

针对变压器故障声纹数据匮乏, 导致后续故障分类采用的深度学习算法过拟合、泛化能力低、识别准确率有限等问题, 常采用数据增强算法扩充故障数据。但是传统数据增强算法 GAN 网络会出现梯度消失和模式崩溃问题, 主要原因在于其使用了 KL (Kullback-Leibler) 散度和 JS 散度来度量 2 个分布之间的差异。为了解决这些问题, Wasserstein 生成对抗网络引入了 Wasserstein 距离 $W(P_{\text{data}}, P_g)$ 来取代 JS 散度, Wasserstein 距离的表达式如式(4)所示:

$$W[P_{\text{data}}(\mathbf{x}), P_g(\mathbf{x})] = \frac{1}{K} \sup_{\|f\|_L \leq K} E_{\mathbf{x} \sim P_{\text{data}}} [f(\mathbf{x})] - E_{\mathbf{x} \sim P_g} [f(\mathbf{x})] \quad (4)$$

式中: \sup 为最小上界; $E_{\mathbf{x} \sim P_{\text{data}}}$, $E_{\mathbf{x} \sim P_g}$ 分别为期望 \mathbf{x} 从 P_{data} , P_g 中获取; $f(\mathbf{x})$ 为一个任意的 Lipschitz 连续函数; K 为 Lipschitz 常数; P_{data} 为真实样本分布; P_g 为生成样本分布; $\|f\|_L \leq K$ 为函数 f 的 Lipschitz 范数被限制在 K 内。

函数 f 由神经网络表示, 并通过权重剪枝限制 f 中所有参数不超过确信范围以确保 K 的存在。但是, 剪枝使得判别器权重矩阵的结构被破坏, 以致 W-GAN 收敛速度较慢。

W-GAN 的生成器和判别器的损失函数 L_G 和 L_D 如下:

$$\begin{cases} L_G = -E_{z \sim p_z} [f_w(G(z))] \\ L_D = E_{\mathbf{x} \sim P_{\text{data}}} [f_w(\mathbf{x})] - E_{z \sim p_z} [f_w(G(z))] \end{cases} \quad (5)$$

式中: $E(\cdot)$ 为期望; $f_w(\mathbf{x})$ 为判别器对真实数据样本的评估输出; $f_w(G(z))$ 为判器对生成器生成样本 $G(z)$

的评估输出。

3.2 损失函数的改进

由于电力变压器故障的复杂性, 故障诊断是一个多分类问题。针对传统的 W-GAN 模型需要对每个故障类别单独训练生成器的问题, 提出了将故障样本的类别标签 \mathbf{y} 作为模型的额外条件变量。这样做使得模型能够生成多类故障数据, 并且显著提高了生成样本的效率。结合类别信息的模型结构如图 2 所示。




图2 改进的W-GAN模型结构
Fig.2 Improved W-GAN model structure

从图 2 可以看出, 在生成器中, 输入为随机变量 z 与类别标签 \mathbf{y} 的组合; 判别器的输入是真实故障样本 \mathbf{x} 和生成 $G(z)$ 分别与类别标签 \mathbf{y} 结合后共同输入以进行判别, 即判别器不仅能判断生成的梅尔声谱图是否真实, 还能判断生成声谱图的类别和输入真实故障声谱图的实际类别是否相符。这样使得模型能够生成指定类别的变压器声纹声谱图。

因此 IW-GAN 模型的损失函数如式(6)所示:

$$\begin{cases} L_G = -E_{z \sim p_z} [f_w(G(z)|\mathbf{y})] \\ L_D = E_{\mathbf{x} \sim P_{\text{data}}} [f_w(\mathbf{x}|\mathbf{y})] - E_{z \sim p_z} [f_w(G(z)|\mathbf{y})] \end{cases} \quad (6)$$

3.3 基于Transformer网络的生成器

近年来, 聊天生成型预训练变换模型 (Chat Generative Pre-trained Transformer, ChatGPT) 因其强大的创造性和逻辑思维能力而成为广受关注的模型。该模型采用了 Transformer 作为底层架构, 这种模型通过引入自注意力机制, 使网络能够并行处理输入序列中的位置信息, 更好地理解输入序列之间的相互依赖关系, 从而显著提高了训练和推理速度。因此, 在 GAN 中, 将 Transformer 作为生成器的结构能够赋予模型更强的表达能力和泛化能力。相对于 CNN, Transformer 能够建立图像的全局依赖关系, 从而获取更多的图像全局信息。为了适应图像任务, 本文模型对传统结构进行了调整, 去掉了解码器, 仅保留编码器。

编码器主要由多头注意力机制和多层感知机组成。单个的注意力机制, 其每个输入包含 3 个不同的向量, 分别为 Query 向量 (Q), Key 向量 (K), Value 向量 (V)。他们的结果分别由输入特征图 X 和 3 个权重 W_q , W_k , W_v 做矩阵乘法得到。

$$\begin{cases} Q = X \times W_q \\ K = X \times W_k \\ V = X \times W_v \end{cases} \quad (7)$$

接着通过 softmax 函数计算每个输入向量的注意力分数 Attention, 如式(8)所示:

$$\text{Attention} = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V \quad (8)$$

式中: d_k 为 Q 或 K 的维度, Q 和 K 的维度相等。

多头注意力机制 *MltiHead* 如式(9)所示:

$$\text{MltiHead} = \text{Concat}(\text{head}_1, \dots, \text{head}_h)W_o \quad (9)$$

式中: *Concat* 为连接操作; head_h 为第 h 个注意力头的输出; W_o 为权重矩阵。

3.4 基于 SN-CNN 的判别器

保证 GAN 判别器的训练稳定性, 本质上是需要判别器的函数满足 Lipschitz 条件, 若判别器仍采用 Transformer, 其模型函数不满足 Lipschitz 条件, 因此, 提出基于谱一化卷积神经网络设计判别器。W-GAN 首次提出了采用权重裁剪方法来使 GAN 的判别器满足 Lipschitz 条件。但是, 剪枝使得判别器权重矩阵的结构被破坏, 以致 W-GAN 收敛速度较慢。本文设计 SN-CNN 判别器, 通过在 CNN 中引入谱归一化层, 将每一层网络的权重矩阵限制在一个范围内, 即通过使参数矩阵中的每个元素除以其谱范数, 使得 Lipschitz 常数为 1。在算法实现中, 使用幂迭代法来计算权重矩阵的奇异值, 以减少计算资源的使用。

在满足 Lipschitz 连续性的条件下, 梯度 $\nabla_x(f(x))$ 提出了新的要求, 如式(10)所示。

$$\begin{aligned} \|\nabla_x(f(x))\|_2 &= \|H_a w_a H_{a-1} w_{a-1} \cdots H_1 w_1\|_2 \leq \\ &\|H_a\|_2 \|w_a\|_2 \|H_{a-1}\|_2 \|w_{a-1}\|_2 \cdots \|H_1\|_2 \|w_1\|_2 \end{aligned} \quad (10)$$

式中: w_a, w_{a-1} 分别为第 a 层和第 $a-1$ 层的权重矩阵; H_a, H_{a-1} 分别为第 a 层和第 $a-1$ 层的海森矩阵; $\|\cdot\|_2$ 为谱范数。

$\sigma(\omega)$ 为矩阵 ω 的最大奇异值。对于对角矩阵 H , 有 $\sigma(H) = \max(h_1, h_2, \dots, h_a)$, 其中 h_1, h_2, \dots, h_a 为 H 的奇异值。因此, 式(10)可以写成:

$$\|\nabla_x(f(x))\|_2 \leq \prod_{i=1}^a \sigma(w_i) \quad (11)$$

为了让 $f(x)$ 满足 Lipschitz 连续性约束, 需要对其梯度进行归一化处理, 如式(12)所示。

$$\begin{aligned} \|\nabla_x(f(x))\|_2 &= \left\| H_a \frac{w_a}{\sigma(w_n)} H_{a-1} \frac{w_{a-1}}{\sigma(w_{n-1})} \cdots H_1 \frac{w_1}{\sigma(w_1)} \right\|_2 \\ &\leq \prod_{i=1}^a \frac{\sigma(w_i)}{\sigma(w_i)} = 1 \end{aligned} \quad (12)$$

式中: i 为神经网络层次。

由式(12)可知, SN-CNN 判别器每层网络的权重矩阵的最大奇异值恒等于 1, 且没有破坏权重矩阵的结构。因此, SN-CNN 判别器不仅能够满足 Lipschitz 条件, 还能保持参数矩阵的稳定性, 加速训练, 简化超参数调整。

4 算例分析

4.1 实验方法与频谱分析

通过实验评估本文所提变压器声纹故障诊断模型的性能, 使用信号采集系统采集了 220 kV 变压器正常运行、短路故障和过电压异常 3 种状态的声信号。

将采集后的声音分割为 1 s 的长度并保存为音频文件, 共 675 条声纹切片样本数据。在特征提取 MFCC 的预处理阶段, 首先需要对采集的变压器音频分帧, 取帧长为 30 ms, 取帧重叠率为 40%; 然后对每帧信号加窗, 窗函数选择汉明窗; 本文提取 13 维的 MFCC 特征向量, 对正常运行、短路故障和过电压运行 3 种状态下的 MFCC 沿时间维度堆叠起来得到二维矩阵并进行可视化分析, 结果如图 3 所示。图例中数值的大小对应特征强度和能量的高低。

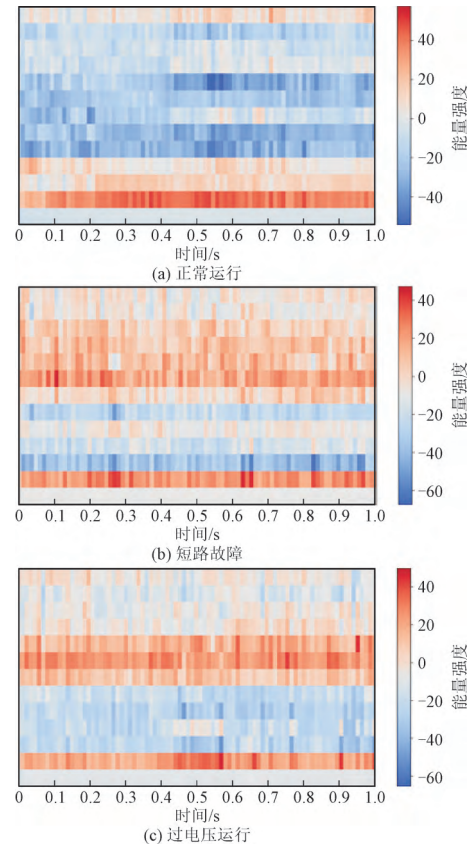


图3 不同状态下的可视化声谱图

Fig.3 Visual spectrograms under different states

实验采用电容式麦克风对某 220 kV 变电站主变不同状态的声信号进行采集,麦克风频率响应范围为 20~ 20 000 Hz,设置变压器声信号的采样频率为 8 000 Hz。变压器的正前方、正后方和右侧分别布置一只麦克风,均距离变压器表面 0.5 m,距离地面 1.2 m。

由图 3 可以看出,正常运行、短路故障、过电压运行 3 种状态的梅尔声谱图颜色分布和明暗存在明显差异,故可以作为声纹提取的有效特征。

经过预处理和特征提取后,需要对样本集进行划分。实验共采集变压器声纹数据 675 条,为了进行后续的增量学习研究,首先从变压器 3 种运行状态中分别提取 80%的样本作为增量样本,剩下 20%作为测试集。利用 IW-GAN 生成的新梅尔声谱图对原始数据集进行扩充,使得每一类变压器运行状态的总样本数达到 500,以起到提高数据集样本多样性的目的。具体的样本分布如表 1 所示。

表 1 样本数据具体分布
Table 1 Specific distribution of sample data

项目状态	训练样本数/条	扩充样本数/条	测试样本数/条	总样本数/条
正常运行	224	220	56	500
短路故障	144	320	36	500
过电压运行	172	285	43	500

4.2 IW-GAN 网络结构及参数设置

根据所需生成数据和输入数据的规模,判别器的结构与参数设如表 2 所示,本实验采用的生成器具体结构如图 4 所示。

表 2 SN-CNN 判别器网络结构
Table 2 SN-CNN discriminator network structure

网络层	卷积核大小/步长	激活函数	谱归一化 SN
卷积层	(3×3)/2	LeakyRelu	是
卷积层	(3×3)/2	LeakyRelu	是
卷积层	(3×3)/2	LeakyRelu	是
全连接层	-	-	否

如图 4 所示,生成器的输入是随机噪声向量 z 与类别标签 y 相乘组成,输入向量经多层感知机映射形成一段长序列 T_0 ,并与位置编码向量相加,经过线性展平后输入到 N_1 个 Transformer 编码器中。输出的张量经线性展平恢复后,进行 Pixel Shuffle 上采样,并重复之前步骤。最后线性展平后,进行 1×1 卷积,输出声谱图。其中,Transformer 编码器由归一化层、多头注意力机制层、多层感知机层和 Dropout 层组成。取 $N_1=3$, $N_2=2$ 。

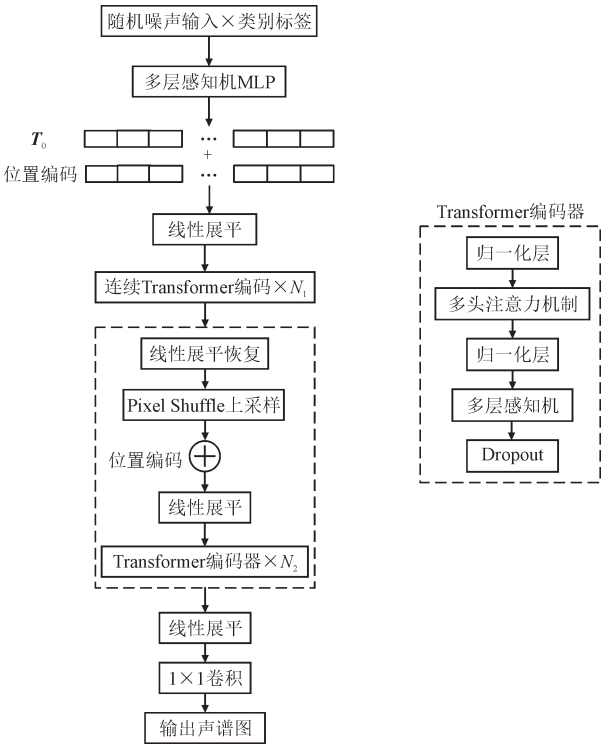


图 4 Transformer 生成器网络结构

Fig.4 Transformer generator network structure

如表 2 所示,本文使用 CNN 作为判别器网络,由 3 个卷积层和 1 个全连接层组成。其中,卷积核大小选为 3×3 ,步长为 2,激活函数选择 LeakyRelu,每个卷积层后面都跟 1 个谱归一化层。生成器和判别器的训练过程中,均采用了 Adam 优化器,矩估计参数 β_1 和 β_2 分别设置为 0.5 和 0.99。设置生成器的学习率为 0.000 2,批次大小为 1 280 判别器的学习率为 0.000 15,批次大小为 64。

4.3 模型评价和结果分析

4.3.1 生成图像质量评价和分析

为了对比不同数据增强算法对样本数据的生成效果,这里选用 SMOTE(Synthetic Minority Oversampling Technique, SMOTE),GAN, W-GAN 和 IW-GAN 网络进行对比。目前比较通用的对 GAN 网络生成样本质量的评价指标有 IS,FID,KID 3 种。

IS 首先使用 Inception 模型来评估每张生成图像的真实性,然后计算生成图像类别分布的 KL 散度,以此作为多样性的度量。IS 数值越高表示生成图像质量越好。FID 使用了 Inception 模型中抽取的特征向量,并计算了它们之间的 Fréchet 距离。FID 的值越低表示生成图像与真实图像的分布越接近。KID 使用了核函数来衡量特征空间中的样本之间的距离,KID 值越低表示生成图像质量越高。

生成样本质量评估结果如表 3 所示,从表 3 可

以看出,IW-GAN 模型的 IS 值高达 8.92,在 4 种方法当中最高,而该方法的 FID 值和 KID 值最低,分别为 14.62,0.71。这说明本文提出的 IW-GAN 模型在维持样本相似性同时,有效增强了样本的多样性。

表 3 生成样本质量评估
Table 3 Quality assessment of generative sample

增强算法	IS 值	FID 值	KID 值
SMOTE	3.50	30.73	1.88
GAN	5.67	25.69	1.23
W-GAN	7.87	18.68	0.98
IW-GAN	8.92	14.62	0.71

4.3.2 故障识别评价和分析

在适用性分析中,本文分类算法采用了 SVM, LSTM 及 CNN。不同分类模型在经过本文模型进行数据扩充后,测试集上对不同故障类型辨识的混淆矩阵如图 5 所示。




图 5 不同分类模型的混淆矩阵
Fig.5 Confusion matrices of different classification models

采用不同数据生成模型,如 SMOTE, GAN 和 W-GAN 扩充数据后,采用 CNN 分类时,模型在测试集上的准确率、损失率随训练轮数的变化情况如图 6 所示。不同模型的准确率对比如表 4 所示。

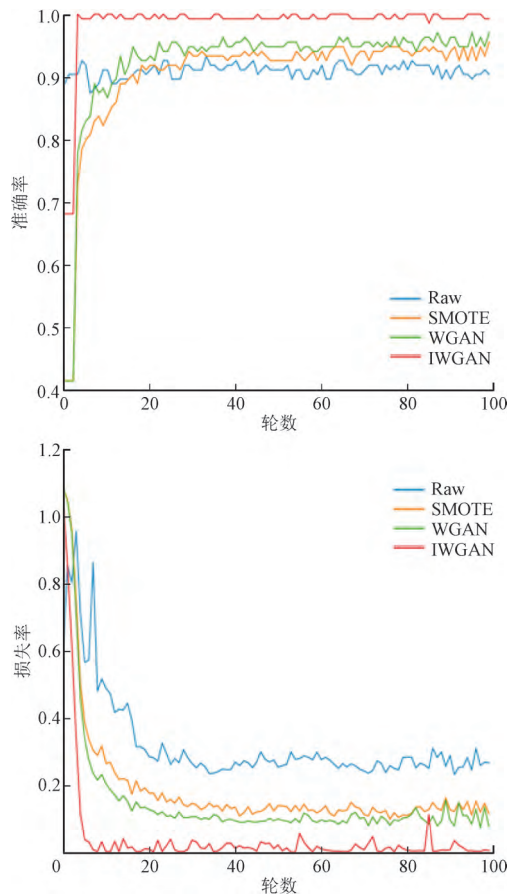


图 6 不同生成模型的准确率和损失率对比
Fig.6 Comparison of accuracy and loss rate of different generative models

由图 5,图 6 可以看出,相对于其他数据增强模型结合其他分类算法,采用 IW-GAN 数据增强后使用 CNN 进行分类的模型表现出明显的识别率提升和损失率降低。

表 4 不同模型组合的准确率对比
Table 4 Accuracy comparison of different model combinations %

模型	SVM	LSTM	CNN
原始数据	92.7	87.8	93.1
SMOTE	94.9	90.2	95.1
W-GAN	95.6	91.5	96.9
IW-GAN	99.2	93.3	100.0

由表 4 可知,相较原始数据,采用不同的数据增强算法扩充样本后,对不同分类器的变压器声纹

故障诊断模型的识别率均有不同程度的提升。采用 SMOTE 算法时,分类器 SVM,LSTM 和 CNN 识别准确率相较于原始数据分别提升了 2.2%,2.4%,2.0%;采用原始 W-GAN 算法时,分类器 SVM,LSTM 和 CNN 识别准确率相较于原始数据分别提升了 2.9%,3.7%,3.8%;采用本文改进设计的 IW-GAN,分类器 SVM,LSTM 和 CNN 识别准确率相较于原始数据分别提升了 5.5%,5.5%,6.9%。

本文提出的采用更具表达能力的 Transformer 网络作为 IW-GAN 的生成器,谱归一化卷积神经网络(SN-CNN)作为 IW-GAN 的判别器,能够有效对小样本数据进行扩充,进而提升变压器声纹故障诊断模型的故障识别能力。

5 结论

本文针对电力变压器声纹故障诊断中因变压器故障声纹数据匮乏而导致的模型识别故障识别准确率不高、泛化能力低的问题,提出的基于 IW-GAN 的变压器声纹诊断模型,通过实验和评价系统验证了本文方法的有效性,得到结论如下:

1)IW-GAN 能够实现对原始数据分布特征的有效学习,相较于传统数据增强算法能够更稳定生成多样性和高质量的样本。

2)应用本文提出的 IW-GAN 数据增强后,相较于原始数据,不同分类器的识别准确率都得到了提升,且相比于 SMOTE 与原始 W-GAN,本文方法的提升效果更加显著。

3)该变压器声纹诊断模型可在数据匮乏和不均衡的情况下对变压器在线状态进行有效诊断,采用 IW-GAN 相较原始数据故障识别率提升 6.9%。

参考文献

- [1] 谢璐佳,张凡,刘灿东,等.基于分步有限元法的 110 kV 变压器振动与噪声研究[J].高压电器,2023,59(8):22-34.
XIE Lujia, ZHANG Fan, LIU Candong, et al. Research on vibration and noise of 110 kV transformers based on staged finite element method[J]. High Voltage Appliances, 2023, 59 (8): 22-34.
- [2] 罗传仙,张民,程林,等.基于声电联合传感阵列的变压器局部放电诊断技术研究[J].电网与清洁能源,2023,39(9):81-90.
LUO Chuanxian, ZHANG Min, CHENG Lin, et al. Research on transformer partial discharge diagnosis technology based on combined acoustic and electrical sensing array[J]. Power System and Clean Energy, 2023, 39(9): 81-90.
- [3] 李琪茜,张振东,刘浩,等.影响油浸式电力变压器振动因素的研究[J].电测与仪表,2023,60(9):96-101.
LI Qiqian, ZHANG Zhendong, LIU Hao, et al. Study on factors affecting vibration of oil immersed power transformers[J]. Electrical Measurement & Instrumentation, 2023, 60(9): 96-101.
- [4] 王荣昊,李喆,孙正,等.基于 FISVDD 与 GRU 的变压器声纹识别技术[J].高电压技术,2022,48(11):4546-4556.
WANG Ronghao, LI Zhe, SUN Zheng, et al. Transformer voiceprint recognition technology based on FISVDD and GRU[J]. High Voltage Engineering, 2022, 48 (11): 4546-4556.
- [5] 李渊,王生杰,马国祥,等.换流变压器运行状态智能诊断分析评价系统研究[J].高压电器,2023,59(8):70-77.
LI Yuan, WANG Shengjie, MA Guoxiang, et al. Research on intelligent diagnosis analysis and evaluation system of operation status of converter transformers[J]. High Voltage Electrical Appliances, 2023, 59(8): 70-77.
- [6] 杨威,蒲彩霞,杨坤,等.基于 CNN-GRU 组合神经网络的变压器短期故障预测方法[J].电力系统保护与控制,2022,50(6):107-116.
YANG Wei, PU Caixia, YANG Kun, et al. Short-term fault prediction method for a transformer based on a CNN-GRU combined neural network[J]. Power System Protection and Control, 2022, 50 (6): 107-116.
- [7] 赵廷志,田晖,崔勇,等.基于多维参量关联分析的变压器故障诊断算法研究[J].电子设计工程,2023,31(9):109-113.
ZHAO Tingzhi, TIAN Hui, CUI Yong, et al. Research on transformer fault diagnosis algorithm based on multi-dimensional parameter correlation analysis[J]. Electronic Design Engineering, 2023, 31(9): 109-113.
- [8] 刘建锋,刘梦琪,董倩雯,等.基于改进 VMD 去噪和优化 ELM 方法的变压器早期故障诊断[J].电力科学与技术学报,2023,38(6):55-66.
LIU Jianfeng, LIU Mengqi, DONG Qianwen et al. Transformer early fault diagnosis based on improved VMD denoising and optimized ELM method[J]. Journal of Electric Power Science and Technology, 2023, 38(6): 55-66.
- [9] 李婷,肖京,刘赞,等.基于信息融合和神经网络的变压器内部故障快速诊断方法[J].电测与仪表,2023,60(11):194-200.
LI Ting, XIAO Jing, LIU Yun, et al. Fast diagnosis method of transformer internal faults based on information and neural networks[J]. Electrical Measurement & Instrumentation, 2023, 60 (11): 194-200.
- [10] 王辉东,姚海燕,郭强,等.基于多尺度卷积神经网络的变压器故障诊断方法[J].电力科学与技术学报,2023,38(4):104-112.
WANG Huidong, YAO Haiyan, GUO Qiang, et al. A transformer fault diagnosis method based on multiscale 1DCNN[J]. Journal of Electric Power and Technology, 2023, 38(4): 104-112.
- [11] 朱瑞金,郝东光,胡石峰.小样本条件下基于卷积孪生网络的变压器故障诊断[J].电力系统及其自动化学报,2021,33(1):64-69,84.

- ZHU Ruijin, HAO Dongguang, HU Shifeng. Transformer fault diagnosis based on convolutional siamese network with small samples[J]. Proceedings of the CSU-EPSC, 2021, 33 (1): 64-69, 84.
- [12] 赵凯琳, 靳小龙, 王元卓. 小样本学习研究综述[J]. 软件学报, 2021, 32(2): 349-369.
- ZHAO Kailin, JIN Xiaolong, WANG Yuanzhuo. Survey on few-shot learning[J]. Journal of Software Science, 2021, 32(2): 349-369.
- [13] GOODFELLOW I J, POUGET-A J, MIRZA M, et al. Generative adversarial nets[C]//Proceedings of the 27th International Conference on Neural Information Processing Systems, June 10, Montreal, Dec 8-13, Cambridge: 2014: 2672-2680.
- [14] 魏富强, 古兰拜尔·吐尔洪, 买日旦·吾守尔. 生成对抗网络及其应用研究综述[J]. 计算机工程与应用, 2021, 57(19): 18-31.
- WEI Fuqiang, Gulanbair TURHONG, Mairidan WUSHOUER. Review of research on generative adversarial networks and its application[J]. Computer Engineering and Applications, 2021, 57(19): 18-31.
- [15] 梁俊杰, 韦舰晶, 蒋正锋. 生成对抗网络GAN综述[J]. 计算机科学与探索, 2020, 14(1): 1-17.
- LIANG Junjie, WEI Jianjing, JIANG Zhengfeng. Generative adversarial networks GAN overview[J]. Computer Science and Exploration, 2020, 14(1): 1-17.
- [16] 李东东, 刘宇航, 赵阳, 等. 基于改进生成对抗网络的风机行星齿轮箱故障诊断方法[J]. 中国电机工程学报, 2021, 41(21): 7496-7507.
- LI Dongdong, LIU Yuhang, ZHAO Yang, et al. Fault diagnosis method of wind turbine planetary gearbox based on improved generative adversarial network[J]. Proceedings of the CSEE, 2021, 41(21): 7496-7507.
- [17] 欧阳鑫, 李志斌. 基于样本扩充和特征优选的IGWO优化SVM的变压器故障诊断技术[J]. 电力系统保护与控制, 2023, 51(18): 11-20.
- OUYANG Xin, LI Zhibin. Transformer fault diagnosis technology based on sample expansion and feature selection and SVM optimized by IGWO[J]. Power System Protection and Control, 2023, 51(18): 11-20.
- [18] 刘云鹏, 和家慧, 许自强, 等. 基于SVM SMOTE的电力变压器故障样本均衡化方法[J]. 高电压技术, 2020, 46(7): 2522-2529.
- LIU Yunpeng, HE Jiahui, XU Ziqiang, et al. Equalization method of power transformer fault sample based on SVM SMOTE[J]. High Voltage Engineering, 2020, 46(7): 2522-2529.
- [19] 张京爱, 王江涛. 基于多尺度卷积神经网络和类内mixup操作的磁瓦表面质量识别[J]. 计算机应用, 2021, 41(1): 275-279.
- ZHANG Jing'ai, WANG Jiangtao. Magnetic tile surface quality recognition based on multi-scale convolutional neural network and within-class mixup operation[J]. Computer Applications, 2021, 41(1): 275-279.
- [20] ARJOVSKY M, CHINTALA S, BOTTOU L. Wasserstein generative adversarial networks[C]//Proceedings of the 34th International Conference on Machine Learning, Sydney, 2017: 214-223.
- [21] 刘云鹏, 许自强, 和家慧, 等. 基于条件式 Wasserstein 生成对抗网络的电力变压器故障样本增强技术[J]. 电网技术, 2020, 44(4): 1505-1513.
- LIU Yunpeng, XU Ziqiang, HE Jiahui, et al. Data augmentation method for power transformer fault diagnosis based on conditional wasserstein generative adversarial network[J]. Power System Technology, 2020, 44(4): 1505-1513.
- [22] 傅尧, 周凯, 朱光亚, 等. 一种基于改进的 WGAN 模型的电缆终端局部放电识别准确率提升方法[J]. 电网技术, 2022, 46(5): 2000-2008.
- FU Yao, ZHOU Kai, ZHU Guangya, et al. Accuracy improvement of cable termination partial discharging recognition based on improved WGAN algorithm[J]. Power System Technology, 2022, 46(5): 2000-2008.
- [23] 房佳姝, 刘崇茹, 苏晨博, 等. 基于自注意力Transformer编码器的多阶段电力系统暂态稳定评估方法[J]. 中国电机工程学报, 2023, 43(15): 5745-5759.
- FANG Jiashu, LIU Chongru, SU Chenbo, et al. Multi-stage transient stability assessment of power system based on self-attention transformer encoder[J]. Proceedings of the CSEE, 2023, 43(15): 5745-5759.
- [24] 刘俊锋, 俞翔, 万海波, 等. 基于MFMD和Transformer-CNN的滚动轴承故障诊断方法[J]. 航空动力学报, 2023, 38(6): 1446-1456.
- LIU Junfeng, YU Xiang, WAN Haibo, et al. Fault diagnosis method of rolling bearing using MFMD and Transformer-CNN[J]. Journal of Aerospace Power, 2023, 38(6): 1446-1456.
- [25] 雷蕾, 郭东恩, 靳峰. 基于谱归一化条件生成对抗网络的图像修复算法[J]. 计算机工程, 2021, 47(1): 230-238.
- LEI Lei, GUO Dong'en, JIN Feng. Image inpainting algorithm based on conditional generative adversarial network with spectral normalization[J]. Computer Engineering, 2021, 47(1): 230-238.
- [26] 向志昊, 魏华. 基于声纹特征识别的电力变压器运维检测技术研究[J]. 电子设计工程, 2023, 31(20): 114-118.
- XIANG Zhihao, WEI Hua. Research on power transformer operation and maintenance detection technology based on voiceprint feature recognition[J]. Electronic Design Engineering, 2023, 31(20): 114-118.
- [27] 王丰华, 王邵菁, 陈颂, 等. 基于改进MFCC和VQ的变压器声纹识别模型[J]. 中国电机工程学报, 2017, 37(5): 1535-1543.
- WANG Fenghua, WANG Shaojing, CHEN Song, et al. Voiceprint recognition model of power transformers based on improved MFCC and VQ[J]. Proceedings of the CSEE, 2017, 37(5): 1535-1543.

(责任编辑 申光艳)

收稿日期: 2024-01-26; 修改日期: 2024-03-26

作者简介: 王欢(1998), 女, 重庆人, 硕士研究生, 主要研究方向为电气设备在线监测与故障检测。

王昕(1972), 男, 通信作者, 上海人, 博士, 副教授, 主要研究方向为电气设备在线监测与故障检测。