

基于极限学习的变压器声纹特征分析与故障识别

冶海平, 方保民, 牟书亮, 马育林, 彭家琦, 马志彬

(国网青海省电力公司 海东供电公司, 青海 海东 810699)

摘要: 针对故障样本数量的高度不平衡, 易导致对变压器故障样本的预测性能变差问题, 提出基于极限学习机的电网变压器故障声纹信号诊断方法。使用极限学习机对信号进行去噪处理, 对处理后的时域信号进行快速傅里叶变换, 从而获取故障声纹特征。通过研究不同学习率对模型故障识别的影响, 以验证基于极限学习机模型的故障识别效果。结果表明, 应用阈值去噪的方法能够在一定程度上消除原始声纹特征信号中的噪声成分。学习率为 10^{-3} 的极限学习机模型对分接开关故障的识别准确率为 99.42%, 且其他 4 种变压器故障状态的对应识别率均大于 99.85%。极限学习机算法的故障识别平均精度高达 96.75%。

关键词: 极限学习机; 变压器; 声纹故障; 准确率

中图分类号: TP277; TM41

文献标志码: A

文章编号: 1001-5922(2024)05-0149-04

Transformer voiceprint feature analysis and fault identification based on extreme learning

YE Haiping, FANG Baomin, MI Shuliang, MA Yulin, PENG Jiaqi, MA Zhibin

(State Grid Qinghai Electric Power Company Haidong Power Supply Co., Ltd., Haidong 810699, Qinghai China)

Abstract: In order to solve the problem that the number of fault samples is highly unbalanced, which can easily lead to the deterioration of the prediction performance of transformer fault samples, a power grid transformer fault voiceprint signal diagnosis method based on extreme learning machine was proposed. Extreme learning machines were used to denoise the signal. Fast Fourier transform was performed on the processed time-domain signal to obtain fault voiceprint features. By studying the impact of different learning rates on model fault recognition, the fault identification effect based on the extreme learning machine model was verified. The results showed that the application of threshold denoising method could eliminate the noise components in the original voiceprint feature signal to some extent. The extreme learning machine model with a learning rate of 10^{-3} had a recognition accuracy of 99.42% for tap changer faults, and the corresponding recognition rates for the other four transformer fault states were all greater than 99.85%. The average accuracy of fault identification using the Extreme Learning Machine algorithm was as high as 96.75%.

Key words: extreme learning machine; transformer; voiceprint failure; accuracy

收稿日期: 2023-12-25; 修回日期: 2024-02-25

作者简介: 冶海平(1984-), 男, 高级工程师, 研究方向: 电气工程; E-mail: chinaxue09@163.com。

基金项目: 国网青海省电力公司科技项目(项目编号: SGQHHD00YJJS2310278)。

引文格式: 冶海平, 方保民, 牟书亮, 等. 基于极限学习的变压器声纹特征分析与故障识别[J]. 粘接, 2024, 51(5): 149-152.

电网变压器是电网中最重要的设备之一。工作时,电流流经绕组线圈,在漏磁场中产生电磁力,导致绕组振动^[1]。引起变压器设备振动和相应的声学特征变化^[2]。因此分析不同条件下变压器设备的声纹特征信息可以作为判断变压器状况的重要依据。传统的电网变压器故障诊断方法主要依靠维修人员丰富的工作经验^[3]。根据伽马酮频率倒频谱系数(GF-CC)声纹频谱对不同故障下的10 kV干式变压器声纹信号进行了分类^[4]。使用UHF PD传感器采集了4个典型PD模式的变压器故障信号。经过预处理后,使用卷积神经网络对样本进行分类,从而提高了PD模式识别的准确性^[5]。然而,受短路等低概率故障事件的影响,实验研究缺乏足够的样本^[6]。当故障样本不均衡时,容易出现过拟合事件,影响模型的分类效果。而极限学习机(ELM)是一种新兴的学习算法^[7]。但目前较少应用于变压器的故障诊断^[8]。基于此,研究采用极限学习机模型用于变压器故障诊断。

1 极限学习机模型理论

极限学习机(ELM)最初是为单隐层前馈网络开发的,且极限学习机中的隐藏层不需要进行调整。极限学习机是一个单隐层前馈神经网络。图1为极限学习机网络结构,包括一个输入层,一个隐藏层,一个输出层。该模型的输入层由 n 个特征值组成。隐藏层有 l 个神经元^[9]。输出层有 m 个神经元,对应于电网设备变压器的 m 个工作状态。




图1 极限学习机网络结构

Fig. 1 Extreme machine network structure

设定变压器声纹故障样本集为 $(X, Y) = \{(x_j, t_j) | 1 \leq j \leq P\}$ ^[10]。其中, X 是输入样本矩阵, Y 是与 X 相对应的预期输出矩阵。 P 是样本数量。 $x_j = [x_{1j}, x_{2j}, \dots, x_{nj}]^T$ 是 X 中第 j 个样本的输入向量。 $y_j = [y_{1j}, y_{2j}, \dots, y_{mj}]^T$ 是 Y 中的第 j 个期望输出向量。 m 是输出向量的维数^[11]。隐层神经元的激活功能是 $g(\cdot)$ 。具有 l 个隐层节点的单隐层前馈神经网络的输出矩阵(T)可以用式(1)表示:

$$T = [t_1, t_2, \dots, t_p]_{m \times P} \quad (1)$$

$$t_j = \begin{bmatrix} t_{1j} \\ t_{2j} \\ \vdots \\ t_{mj} \end{bmatrix}_{m \times 1} = \begin{bmatrix} \sum_{i=1}^l \beta_{i1} g(w_i \cdot x_j + b_i) \\ \sum_{i=1}^l \beta_{i2} g(w_i \cdot x_j + b_i) \\ \vdots \\ \sum_{i=1}^l \beta_{im} g(w_i \cdot x_j + b_i) \end{bmatrix} \quad (2)$$

式中: $j=1, 2, \dots, P$ 、 $w_i = [w_{i1}, w_{i2}, \dots, w_{in}]$ 是第1个隐藏层神经元到第1个隐藏层神经元的权值; $b = [b_1, b_2, \dots, b_l]^T$ 代表了第 i 个隐含层神经元与第 k 个隐含层神经元的权值。隐层神经元的偏差为 $b = [b_1, b_2, \dots, b_l]^T$,其中 b_i 是第 i 个隐层神经元的偏置。则式(1)和式(2)可以表示为:

$$H\beta = T' \quad (3)$$

式中: T' 是神经网络输出矩阵 T 的转置^[14]; H 是神经网络的隐层输出矩阵。则 H 的表达式为:

$$H(w_1, w_2, \dots, w_l, b_1, b_2, \dots, b_l, x_1, x_2, \dots, x_p) = \begin{bmatrix} g(w_1 \cdot x_1 + b_1) & g(w_2 \cdot x_1 + b_2) & \dots & g(w_l \cdot x_1 + b_l) \\ g(w_1 \cdot x_2 + b_1) & g(w_2 \cdot x_2 + b_2) & \dots & g(w_l \cdot x_2 + b_l) \\ \vdots & \vdots & \vdots & \vdots \\ g(w_1 \cdot x_p + b_1) & g(w_2 \cdot x_p + b_2) & \dots & g(w_l \cdot x_p + b_l) \end{bmatrix}_{P \times l} \quad (4)$$

当单隐层前馈神经网络的隐层神经元数等于训练集数 p 时,对于任意权重矩阵 W 和偏置向量 b ,神经网络都能以零误差接近训练样本^[13],即:

$$\sum_{j=1}^P \|t_j - y_j\| = 0 \quad (5)$$

但在训练样本数为 P ,并且学习速率很高的情况下,隐含层的神经元数目一般都比 P 小,从而降低了网络的计算量;因此,该神经网络具有一个近似于任意 ε_0 的训练误差。

$$\sum_{j=1}^P \|t_j - y_j\| < \varepsilon \quad (6)$$

因此,当隐层的激励函数 $g(\cdot)$ 是无穷维,则可在学习之前,任意地决定输入层与隐层权阵 W 及隐层偏置^[14],并在训练过程中保持不变。此时,隐层的输出矩阵 H 是一个恒定矩阵^[17]。利用最小二乘法对隐含层与输出级的加权矩阵进行求解,从而求得 $H\beta = T'$,即:

$$\hat{\beta} = H^+ \cdot T' \quad (7)$$

式中: H^+ 为隐层输出矩阵 H 的摩尔-彭罗斯广义逆。

其学习步骤如下:

决定有多少个潜在的神经元。在输入和隐藏层间,对加权矩阵 W 进行随机设定,并对隐藏层单元进行偏移矢量 b ^[18]。

选取一个无穷可导的函数,对隐含层元进行激励。在此基础上,求出隐含层的输出矩阵 H 。

2 基于极限学习机的变压器声纹故障识别

2.1 基于极限学习机模型阈值的声纹去噪方法

本文采用极限学习机阈值进行变压器信号去噪。选择一个正交小波基。用 K 层极限学习机分解法对处理信号 $s(n)$ 进行分解。为每个分解后的极限学习机系数选择一个合适的阈值进行阈值量化。最后,通过极限学习机重构得到去噪信号 $s'(n)$ 。在极限学习机去噪过程中,阈值函数的选择更为关键。常用的阈值函数有硬阈值函数和软阈值函数。对于硬阈值法,当极限学习机分解系数的绝对值大于阈值时,系数保持不变;反之,则设定为零。这种量化方法容易使信号产生振荡。因此,研究选择了软阈值处理方法。软阈值函数的定义:

$$\delta_{\lambda}(d)=\begin{cases} \text{sgn}(d)\times(|d|-\lambda), & |d|\geq\lambda \\ 0, & |d|<\lambda \end{cases} \quad (8)$$

式中: $\delta_{\lambda}(d)$ 为阈值处理后的极限学习机系数; d 为原始的极限学习机分解系数; λ 为阈值。

2.2 变压器故障信号处理

变压器故障信号预处理目的是使低频高频部分的能量具有相似的振幅。因此,需要加强采集到的声纹信号的高频部分,以便模型能更好地利用高频声母,从而提高变压器故障识别的准确性。而预处理主要通过一阶高通滤波器实现,其频域表示为:

$$H(z)=1-\mu z^{-1} \quad (9)$$

式中: μ 是系数,通常为0.97。变压器故障信号作为典型的非稳态信号,设备噪声信号以 F 个采样点为一个观测单位,称为一帧。在本文中,一帧就是一个采样点,取帧的过程就是将原始信号分成 p 个采样点。每个帧乘以一个窗口函数,以增加左信号和右信号的连续性。其他信号被屏蔽,也称为短时信号处理。基于极限学习机预处理后的声纹信号则为:

$$x(n)=s'(n)w(n) \quad (10)$$

式中: $s'(n)$ 是去噪后的声纹信号; $x(n)$ 是预处理之后的每个帧的时域信号; $w(n)$ 是Hamming函数。

3 基于极限学习机模型的故障识别测试结果

3.1 声纹特征提取

在采集电网变压器声音信号的过程中,由于环境噪声的影响,采集到的故障信号掺杂了许多噪声成分。为了从变压器故障声音信号中提取声纹特征,首先对采集到的声音信号进行阈值去噪处理。图2(a)为原始声纹特征,图2(b)为基于极限学习机的声纹特征提取。




图2 声纹特征去噪提取

Fig. 2 Voiceprint feature extraction

由图2(a)、(b)可以观察到,应用阈值去噪的方法能够在一定程度上消除原始声纹特征信号中的噪声成分。为了提高识别准确率,去噪后对声音信号的高频部分进行了预处理。且预处理是为了平整幅度频谱,平衡高频和低频成分。

3.2 学习率对故障识别的影响

在极限学习机网络训练过程中,对模型训练影响的参数包括运行时间、学习率和优化器类型。在对极限学习机模型进行多次训练后,确定迭代次数为100。而学习率的选择也会影响模型的训练效果,过高的学习率会导致模型不收敛;而过低的学习率则可能导致模型学习结果的局部优化,进一步影响电网变压器的故障识别。因此,需要研究不同学习率(LR分别为 10^{-2} 、 10^{-3} 、 10^{-4})对模型故障识别的影响。图3为不同学习率条件下的故障识别准确率变化。




图3 不同学习率的故障准确率识别结果

Fig. 3 Fault accuracy recognition results with different learning rates

从图3可以看出,当学习率为 10^{-2} (LR= 10^{-2})时,故障识别模型没有收敛,准确率约为20%。当学习率设置为 10^{-3} (LR= 10^{-3})时,故障识别模型收敛,大约在第10个迭代次数之后模型变得稳定。同样,当学习率等于 10^{-4} (LR= 10^{-4})时,故障识别模型仍然收敛,大约在第12个迭代次数后达到稳定,准确率约为99.2%。此外,学习率越大,模型接近最优解的收敛速度越快。同时可观察到学习率等于 10^{-4} 时,故障识别模型表现出更好的稳定性。由此可以得出,基于极限学习机的识别模型在变压器故障诊断中是可行的。

表1为极限学习在2种收敛学习率条件下对5种电网变压器故障的识别率研究结果。

表1 不同变压器故障识别准确率
Tab.1 Accuracy of fault identification for different transformers

极限学习机模型	LR=10 ⁻⁴	LR=10 ⁻³
绕组故障/%	99.93	100
套管故障/%	98.17	100
铁芯故障/%	99.93	99.93
瓦斯保护故障/%	100	99.93
分接开关故障/%	99.86	99.42
平均准确率/%	99.59	99.85

由表1可知,对于学习率为10⁻⁴的模型,在其第100个Epoch中,套管故障的识别准确率约为98.17%,而其他4个变压器故障状态的对应识别准确率均大于99.80%。学习率为10⁻³的极限学习机模型对分接开关故障的识别准确率为99.42%,其他4种变压器故障状态的对应识别率均大于99.85%。

3.3 故障识别精度对比

表2为极限学习机与深度学习、随机森林模型在故障识别精度中的对比。

表2 不同算法模型故障识别精度比较
Tab.2 Comparison of fault recognition accuracy of different algorithm models

故障类别	极限学习机/%	深度学习/%	随机森林/%
绕组故障	0.95	0.86	0.92
套管故障	0.96	0.91	0.91
铁芯故障	0.97	0.82	0.89
瓦斯保护故障	0.99	0.85	0.87

由表2可知,极限学习机算法的识别平均精度最高(96.75%),随机森林算法的识别效果较差(89.75%),其次是深度学习(86%)。当变压器发生绕组故障时,极限学习机算法模型的识别精度高达0.95,比深度学习算法的0.86高出9.47%,比随机森林算法的0.92高出3.58%。而变压器发生套管故障时,3种模型的故障识别精度均大于0.91。当变压器发生铁芯故障时,极限学习机的故障识别精度高达0.97,较深度学习及随机森林算法提高15.46%、8.25%。同时还可观察到,极限学习机在瓦斯保护故障中的故障识别精度最高(0.99),而深度学习、随机森林模型在瓦斯保护故障中,识别精度小于0.87,无法有效监测变压器故障状态。因此,极限学习机算法模型可满足电网变压器实际故障状态监测。

4 结语

且当学习率设置为10⁻³时,故障识别模型收敛,大

约在第10个Epoch之后模型变得稳定。当学习率等于10⁻⁴时,故障识别模型仍然收敛,大约在第12个Epoch后达到稳定,准确率约为99.2%。学习率为10⁻⁴的极限学习机模型具有更好的稳定性,学习率为10⁻³的极限学习机模型具有更好的识别准确率。

【参考文献】

- [1] 王玉伟,余俊龙,彭平,等.基于多模型融合的变压器故障在线检测方法[J].高电压技术,2023,49(8):3415-3424.
- [2] 李楠,马宏忠,段大卫,等.基于多传感器融合声纹特征图谱的变压器铁芯松动故障诊断方法[J].振动与冲击,2023,42(15):129-137.
- [3] 张波,黄英龄,明志茂,等.基于同步压缩小波变换和ResNet的变压器放电故障诊断方法[J].现代电子技术,2023,46(10):159-165.
- [4] 张可,杨可军,黄文礼,等.基于声纹识别的变压器工况检测方法 & 验证系统[J].计算技术与自动化,2022,41(1):1-6.
- [5] 刘云鹏,罗世豪,王博闻,等.基于Mel时频谱-卷积神经网络的变压器铁芯夹件松动故障声纹模式识别[J].华北电力大学学报(自然科学版),2020,47(6):52-60.
- [6] 何萍,李勇,陈寿龙,等.基于变压器声纹Mel语谱图-ResNet的铁心松动故障诊断[J].电机与控制应用,2022,49(9):75-80.
- [7] 杨帆,张文娟,孙剑伟,等.通过振动信号判断机械设备故障方法研究[J].粘接,2020,41(4):171-175.
- [8] 刘云鹏,王博闻,周旭东,等.基于等效源法的变压器瞬态声场重构与声学监测测点位置定量评价方法[J].中国电机工程学报,2022,42(7):2765-2776.
- [9] 张重远,罗世豪,岳浩天,等.基于Mel时频谱-卷积神经网络的变压器铁芯声纹模式识别方法[J].高电压技术,2020,46(2):413-423.
- [10] 周梦茜,唐志国,王泽瑞,等.基于声纹识别系统的局部放电超声信号识别研究[J].高压电器,2022,58(9):127-133.
- [11] 程凯.基于卷积神经网络的化工旋转机械故障识别[J].粘接,2022,49(4):88-92.
- [12] 包海龙,邵宇鹰,王泉,等.基于反卷积波束形成算法的干式变压器异响故障识别技术[J].中国电力,2022,55(2):90-97.
- [13] 张重远,岳浩天,王博闻,等.基于相似矩阵盲源分离与卷积神经网络的局部放电超声信号深度学习模式识别方法[J].电网技术,2019,43(6):1900-1907.
- [14] 孙安青,贾廷波,王丰华,等.基于二维主成分分析法的变压器声纹特征参数融合方法[J].广东电力,2022,35(9):127-134.
- [15] 孙玉伟,罗林根,陈敬德,等.基于声音特征与改进稀疏表示分类的断路器机械故障诊断方法[J].电网技术,2022,46(3):1214-1222.
- [16] 何奋彪.基于遗传算法化工领域往复压缩机故障诊断分析[J].粘接,2022,49(8):182-185.