

基于 Apriori 和 C5.0 算法的智能电表故障预测

文耀宽 侯慧娟 王 雍

(国网河南省电力公司营销服务中心 河南 郑州 450007)

摘 要: 针对智能电表故障状态的预测问题,提出了一种基于 Apriori 算法和 C5.0 算法建立智能电表故障识别模型,实现智能电表故障的预测。首先,对智能电表历史故障数据库进行数据挖掘预处理,并采用 Apriori 算法进行强关联因素深度挖掘。然后,将强关联因素组成的数据集合分为训练数据集和测试数据集两部分,采用 C5.0 算法对训练数据集进行数据挖掘,生成智能电表故障初步预测规则。接着,根据测试集的数据对初步预测规则的正确性进行评估:如果准确度满足要求,确定预测规则;如果不满足,则返回训练集。最后,根据获得的预测规则建立智能电表故障状态预测模型进行智能电表故障预测。算例分析结果证明,智能电表故障状态预测模型具有较高的精度,可获得极为准确的故障状态预测结果。

关键词: 智能电表; 数据分析; 故障预测; 关联规则挖掘; 决策树算法; C5.0; Apriori; 数据集

中图分类号: TH89

文献标志码: A

DOI: 10.16086/j.cnki.issn1000-0380.2021040034

Fault Prediction of Smart Electricity Meter Based on Apriori and C5.0 Algorithm

WEN Yaokuan, HOU Huijuan, WANG Yong

(Marketing Service Center, State Grid Henan Electric Power Company, Zhengzhou 450007, China)

Abstract: Aiming at the problem of fault state prediction of smart electricity meter, a smart electricity meter fault identification model based on Apriori algorithm and C5.0 algorithm is proposed to realize the fault prediction of smart electricity meter. Firstly, the historical fault database of smart electricity meter is preprocessed by data mining, and the Apriori algorithm is used for deep mining of strong correlation factors. Secondly, the data set composed of strong correlation factors is divided into training data set and test data set. C5.0 algorithm is used to conduct data mining on training data set and generate preliminary prediction rules for smart meter faults. Then, the correctness of the preliminary prediction rule is evaluated according to the data of the test set. If the accuracy meets the requirements, the prediction rule is determined. If not, the training set is returned. Finally, a smart meter fault state prediction model is established according to the obtained prediction rules to predict smart meter faults. The result of example analysis proves that the smart meter fault state prediction model has high precision and can obtain extremely accurate fault state prediction results.

Keywords: Smart electricity meter; Data analysis; Fault prediction; Association rule mining; Decision tree algorithm; C5.0; Apriori; Data set

0 引言

智能电表作为建设泛在电力物联网的核心边缘计算装置,承担着电能计量信息采集、用户电能信息储存、双向通信、多阶梯费率统计、用户侧远程调控等功能,是未来泛在电力物联网用户智能化终端的主要发展方向^[1]。在我国重点建设泛在电力物联网的背景下,用电状况信息采集系统的建设已初具规模。智能电表在其中得到了广泛的应用。然而,智能电表一旦发生故障,将影响用电信息采用的准确性。如未能及

时解决智能电表故障,将可能为电力企业和用户带来严重的经济损失^[2-3]。

目前,一般使用检测仪器进行现场测试,以获得准确的电表故障信息。这会耗费大量的人力和物力,且存在无法准确发现智能电表故障的情况。此外,由于电能表的智能化应用程度的不断提升,电表故障的通用性、突然性和复杂性等特点越发凸显^[4-6]。这些问题对智能电表故障状态的准确性预测提出了巨大的挑战。因此,依据国网信息化平台采集到的海量智能电表故障状态历史数据^[7],运用数据分析与挖掘技术对

收稿日期: 2021-04-26

作者简介: 文耀宽(1969—),男,硕士,高级工程师,主要从事电能计量方向的研究, E-mail: Wenyaokuanhenan@163.com

详细的智能电表故障状态数据进行深度挖掘,并通过提取关键性信息寻找故障数据与智能电表状态的相关性,可实现智能电表故障状态的准确性预测。

本文采用 Apriori 算法进行强关联性因素特征挖掘;采用 C5.0 算法计算关联性因素特性的信息增益率,建立智能电表故障预测模型实现智能电表故障的预测。研究结果表明,该模型能取得良好的预测效果。

1 智能电表故障预测方法

决策树在分类、预测和规则提取等数据分析领域具有广泛应用。作为一种对数据实例进行分类的树状形结构模型^[8-9],决策树由有向边和节点共同构成。决策树的节点分为内部节点与叶节点:内部节点表示一个因素;叶节点表示一个不能再进行分类的类别。分类判断决策的运算过程中,需以根节点为始端对实例数据的某个因素特征进行检测,并依据检测结果将实例分配到对应的内部子结点位置。此时,每个内部子节点对应着该因素特征的一个相对应取值。依据上述检测方法进行递推式下行搜索运算,直至到达决策树末端的叶节点为止,可实现实例数据到叶节点类的分配^[10]。

基于决策树的智能电表故障预测流程如下。首先,对用户信息采集系统中智能电表的故障状态历史数据进行缺失值插补、异常值剔除和数据标准化等预处理。然后,将智能电表的历史数据划分为预测训练数据集和预测测试数据集,采用分类决策树算法对预测训练数据集进行数据分析,进而建立智能电表的故障状态决策树和待定预测规则。接着,利用测试数据集的数据信息对待定预测规则的准确性进行评估:如果精度满足要求则建立预测规则;否则,返回训练集重新训练。最后,根据达到准确性要求的预测规则建立智能电表的故障状态预测模型。

2 智能电表故障预测强影响因素挖掘

关联规则数据挖掘是一种无指导的数据分析算法,用于揭示数据信息中未直接表示出来的隐含关联特征因素^[11]。Apriori 算法是应用广泛的关联分析算法之一^[12],以规则置信度和支持度作为规则有效性的测度指标。置信度和支持度的数学定义分别如式(1)和式(2)所示。

$$C_{X \rightarrow Y} = \frac{|T(X \cap Y)|}{|T(X)|} \quad (1)$$

$$S_{X \rightarrow Y} = \frac{|T(X \cap Y)|}{|T|} \quad (2)$$

式中: X 、 Y 分别为规则 $X \rightarrow Y$ 的前项和后项; $C_{X \rightarrow Y}$ 为 $X \rightarrow Y$ 的置信度; $|T(X \cap Y)|$ 为同时包含 X 和 Y 的事务数; $|T(X)|$ 为包含 X 的事务数; $S_{X \rightarrow Y}$ 为 $X \rightarrow Y$ 的支持度; $|T|$ 为总事务数。

良好的强关联规则应同时具备较高的置信度和支持度。假设最小的置信度与支持度阈值分别为 C_{\min} 和 S_{\min} ,Apriori 算法将关联规则的发现过程分为频繁项集搜索和最小置信度规则构造两个环节^[13]。

该算法根据数据项集性质对目标信息数据集进行逐次搜寻,完成所有频繁项集的完整遍历。将第一次搜寻获得的频繁 1-项集记为 L_1 ,利用频繁 1-项集 L_1 自连接生成候选 2-项集 Q_2 。第 k 次信息数据集搜寻时,首先利用上一次搜寻结果生成候选 k -项集 Q_k ;然后计算每个元素的支持度;最终在第 k 次搜寻完成时候选 k -项集 L_k 的计算。当项集 L_k 为空集时,停止计算。

Apriori 算法执行流程如图 1 所示。

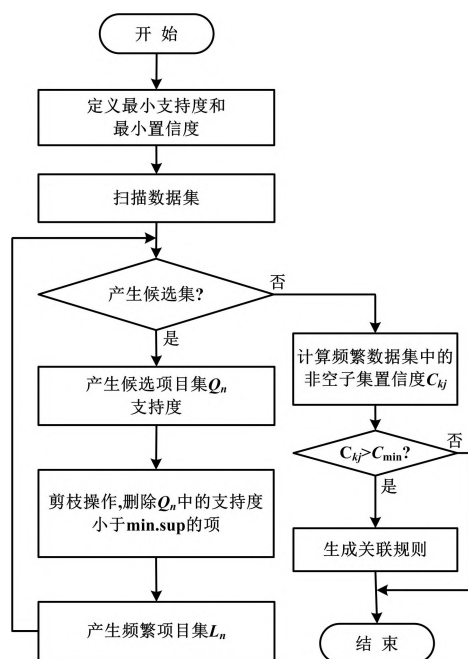


图 1 Apriori 算法执行流程

Fig.1 Apriori algorithm execution process

①信息数据集 D 进行搜寻,产生 L_1 。

对信息数据集进行全面搜寻,并统计每一项的支持度计数,将支持度计数不小于信息数据集 D 中事务项目总数目与预先设定的最小支持度阈值乘积的项目合并到 L_1 内。

②自身连接操作。

将 L_{k-1} 与其本身采取连接计算,并且相连接的两个项集的前 $(k-2)$ 项数值完全相等,前一个项集的第 $(k-1)$ 项的值小于后一个项集的第 $(k-1)$ 项的值,

连接后生成候选项集 Q_k 。

③ 剪枝操作。

Q_k 中包含 L_k 和非频繁集 $\sim L_k$ 。首先,根据频繁项所有子集都是频繁项集的特性,删除 Q_k 中不符合该特性的子集;然后,搜寻信息数据集合 D ,计算剪枝操作步后的 C_k 中剩余项集支持度计数;最后,依据设定的最小支持度阈值 S_{\min} 找出所有 L_k 。

④ 搜寻终止条件判别。

重复步骤②、步骤③的操作运算。当 L_k 或 Q_k 为空集时,结束搜寻。

⑤ 关联规则生成。

分别计算每个 L_k 中所有非空子集合 L_{kj} 的置信度值 C_{kj} 。若 $C_{kj} > C_{\min}$,则生成强关联规则 $L_{kj}' \rightarrow (L_k - L_{kj})$ 。

将智能电表故障状态作为规则的后项,以采集到的智能电表历史故障数据作为规则的前项。设置合理的支持度和置信度,利用 Apriori 算法可获得多个强关联规则,并根据强关联规则获得评判智能电表故障的强影响特征因素。

3 基于 C5.0 算法的智能电表故障预测模型

C5.0 算法是一种经典的分析决策树算法,根据统计学上的置信区间计量概念进行评估,并基于信息熵进行最佳测试属性选取^[14-15]。假设数据集 S_D 是智能电表故障历史数据集合。将 S_D 中的 50% 数据分配给预测训练数据集 S ,另 50% 数据分配给预测测试数据集 T ,并采用 C5.0 算法对训练数据集 S 进行数据分析。

C5.0 算法的计算流程如下。将 S 分成 n 个子集 S_1, S_2, \dots, S_n 。其中 n 是 S 中属性 X 的个数。假设训练集 S 的熵 $i_{\text{info}}(S)$ 为:

$$i_{\text{info}}(S) = \sum_{i=1}^N \frac{f_{\text{req}}(C_i, S)}{|S|} \log_2 \left(\frac{f_{\text{req}}(C_i, S)}{|S|} \right) \quad (3)$$

式中: $|S|$ 为训练集 S 中的样本总数; $f_{\text{req}}(C_i, S)$ 为训练集 S 的中心决策因素类别 C_i 的样本数 ($i = 1, 2, \dots, N$), N 为决策属性的类别总数。

基于因素特征 X ,将训练数据集 S 划分为 n 个子集合,可计算得到各个子集合的信息熵为:

$$i_X(S) = \sum_{i=1}^m \frac{|S_i|}{|S|} \times i_{\text{info}}(S_i) \quad (4)$$

式中: $i_X(S)$ 为属性 X 的信息熵; $|S_i|$ 为 S_i 中的 C_i 的样本总数 $i = 1, 2, \dots, m$, m 为属性 X 中的类别总数。

增益标准 $g_{\text{ain}}(X)$ 为:

$$g_{\text{ain}}(X) = i_{\text{info}}(S) - i_X(S_i) \quad (5)$$

属性 X 产生的潜在信息 $s(X)$ 为:

$$s(X) = - \sum_{i=1}^m \frac{|S_i|}{|S|} \times \log_2 \left(\frac{|S_i|}{|S|} \right) \quad (6)$$

属性 X 的信息增益比 $g(X)$ 可以用以下公式表示:

$$g(X) = \frac{g_{\text{ain}}(X)}{s_{\text{plit}} - i_{\text{info}}(X)} \quad (7)$$

将信息增益比的最大影响因素作为根节点,其余因素根据信息增益比的最大化进行递归计算,从而建立整个决策树,并产生待预测规则。

模型的精度可通过式(8)进行评估。对待预测规则进行初步验证,以确定其可靠性:

$$Z = \frac{P}{O} \times 100\% \quad (8)$$

式中: P 为预测测试数据集中能够实现准确预测的样本数; O 为预测测试数据集中的样本总个数。

假设 Z' 是评价模型的精度基准值。如果 $Z \geq Z'$,则可以确定分类规则;如果 $Z < Z'$,则返回训练集对决策树进行重新训练,从而形成最终决策树,生成预测规则,对智能电表进行故障预测。

4 算例分析

4.1 强关联因素挖掘

为提高某区域内的电力公司所获取的智能电表故障状态原生历史数据的整体质量,需采用缺失性数据插补、异常数据剔除、数据一致性检测以及数据标准化处理等方法对原生数据进行预处理,以保障数据质量。

通过对智能电表故障历史数据的启发性分析,本文初步筛选了智能电表故障状态的 10 个可能影响因素。智能电表故障的可能影响因素如表 1 所示。

表 1 智能电表故障的可能影响因素
Tab.1 Possible factors affecting smart electricity meter failures

序号	因素	代表字母	属性值
1	平均预期寿命	A	较短(I); 较长(II); 很长(III)
2	电能使用状态	B	轻度用电(I); 一般用电(II); 重度用电(III)
3	家族缺陷	C	无(I)、较少(II)、较多(III)
4	未检测天数	D	较短(I); 较长(II)
5	运行故障率	E	极少(I)、较少(II)、一般(III)
6	可靠性	F	较高(I); 较低(II)
7	批量测试合格率	G	较高(I); 较低(II)
8	外观缺陷	H	无(I)、较少(II)、较多(III)
9	谐波	I	较少(I)、一般(II)、较多(III)
10	运转时长	J	较短(I); 较长(II); 很长(III)

表1中,数值I、II、III标示了各个因素的属性值。为了方便决策树与关联规则表示,分别用A、B、…、L的顺序表示表1中各影响因素,并分别用I、II、III表示不同因素的属性值。

以智能电表状态作为规则后项,设定最小支持度阈值 S_{\min} 为 10%、最小置信度阈值 C_{\min} 为 80%。采用 Apriori 算法进行关联分析,共获取 873 条关联规则。其中:最小支持度为 10.034%,最大支持度为 88.67%;最小置信度为 80%,最大置信度为 98.23%。其中,拥有较高置信度和支持度的部分关联规则提取结果如表2所示。

表2 部分关联规则提取结果
Tab.2 Extraction results of some association rules

序号	关联规则	支持度/%	置信度/%
1	[BII ,DII ,FII]→故障	88.67	99.12
2	[DII ,FII ,SII]→故障	80.44	99.01
3	[OI ,JII ,FII]→故障	75.56	98.67
4	[BII ,DI ,OI ,SII]→正常	61.73	98.23
5	[DI ,FI ,JII]→正常	56.21	97.85
6	[FII ,JIII ,SII]→故障	43.87	97.01
7	[JI ,OI ,SII]→正常	40.88	96.32
8	[DII ,QI ,SII]→故障	38.74	95.83
9	[BII ,FII ,JIII ,OII ,QII]→故障	35.97	94.23
10	[DII ,JIII ,OII ,PIII]→故障	32.29	93.91
11	[JII ,OI ,SII]→正常	30.12	93.34
12	[BIII ,FII ,JIII ,OII]→故障	27.33	92.81
13	[AII ,DII ,FII ,JII ,SII]→故障	61.73	91.79

通过表2中高置信度与支持度的关联规则分析提取结果,可知电能使用状态、环境条件、运转时长、未检测天数、可靠性和异常频次这6个因素是智能电表故障的预测评判的强影响因素。智能电表的强影响因素如表3所示。

表3 智能电表的强影响因素
Tab.3 Strong influence factors of smart electricity meter

序号	因素	属性值
1	电能使用状态	轻微用电(I);普通用电(II);重度用电(III)
2	环境条件	正常条件(I);恶劣条件(II)
3	运转时长	短(I);中等(II);长(III)
4	未检修天数	短(I);长(II)
5	可靠性	高(I);低(II)
6	异常频次	少(I);多(II)

电能使用状态因素中:轻微用电表示用户的用电量较少;普通用电表示用户用电情况一般;重度用电表示户用电量较大。3类用电情况分别划分为I、II、III这3个等级。环境条件因素中:正常条件表示智能电表所处环境的平均温度、湿度适宜;恶劣条件表示智能电表所处的平均温度、湿度环境恶劣。这2类环境条件分别划分成I、II这2个等级。运转时长因素中的短、中等、长分别表示电表运转时长,分别划分为I、II、III这3个等级。未检修天数因性中,短、长代表距离前次检修节点的天数小于30天和大于等于30天,可分别划分为I、II这2个等级。可靠性因素中,高、低表示智能电表的出厂可靠性。异常频次中,少、多表示智能电表在1年中发生异常的频次小于2和大于等于2。

4.2 基于 C5.0 算法的决策树的建立

在 Python 中,采用 C5.0 算法对由 50% 的智能电表故障历史数据形成的预测训练数据集进行数据分析,并输出 dot 格式的文本文件;同时,采用 Graphviz 绘图工具将 dot 格式文件转换为如图2所示的智能电表故障决策树。

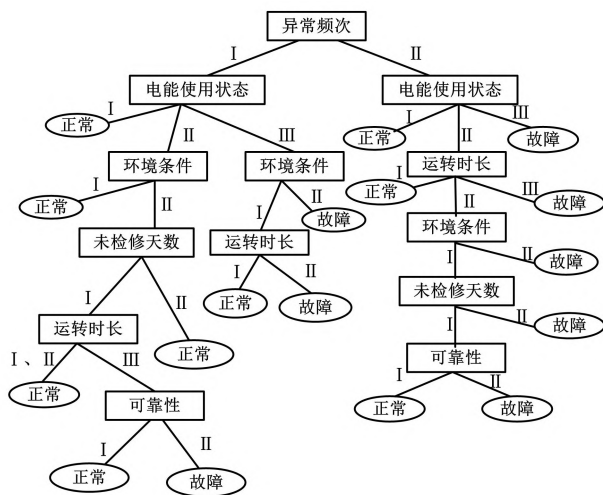


图2 智能电表故障决策树

Fig.2 Fault decision tree of smart electricity meter

生成的决策树模型共有6层。第一层分类属性为异常频次,其重要性程度为0.345;其余分类属性分别为电能使用状态、环境条件、运行时长、未检修天数、可靠性,其重要性程度分别为0.215、0.196、0.164、0.174、0.129。

智能电表故障状态决策树的每个分支与相应的一条智能电表故障状态预测规则相对应。依据智能电表故障状态,决策树可生成以下9条最终的电表故障状

态预测规则。

预测规则 1: IF 异常频次 IN [“I”] AND 电能使用状态 IN [“I”] THEN 电表状态 = “正常”。

预测规则 2: IF 异常频次 IN [“I”] AND 电能使用状态 IN [“II”] AND 环境条件 IN [“I”] THEN 电表状态 = “正常”。

预测规则 3: IF 异常频次 IN [“I”] AND 电能使用状态 IN [“II”] AND 环境条件 IN [“II”] AND 未检修天数 IN [“I”] AND 运转时长 IN [“I” or “II”] THEN 电表状态 = “正常”。

预测规则 4: IF 异常频次 IN [“I”] AND 电能使用状态 IN [“II”] AND 环境条件 IN [“II”] AND 未检修天数 IN [“I”] AND 运转时长 IN [“III”] AND 可靠性 IN [“I”] THEN 电表状态 = “正常”。

预测规则 5: IF 异常频次 IN [“I”] AND 电能使用状态 IN [“II”] AND 环境条件 IN [“II”] AND 未检修天数 IN [“I”] AND 运转时长 IN [“III”] AND 可靠性 IN [“II”] THEN 电表状态 = “故障”。

预测规则 6: IF 异常频次 IN [“I”] AND 电能使用状态 IN [“II”] AND 环境条件 IN [“II”] AND 未检修天数 IN [“II”] THEN 电表状态 = “故障”。

预测规则 7: IF 异常频次 IN [“I”] AND 电能使用状态 IN [“III”] AND 环境条件 IN [“I”] AND 运转时长 IN [“I” or “II”] THEN 电表状态 = “正常”。

预测规则 8: IF 异常频次 IN [“I”] AND 电能使用状态 IN [“III”] AND 环境条件 IN [“I”] AND 运转时长 IN [“III”] THEN 电表状态 = “故障”。

预测规则 9: IF 异常频次 IN [“I”] AND 电能使用状态 IN [“III”] AND 环境条件 IN [“II”] THEN 电表状态 = “故障”。

4.3 模型评估

本文取某型号智能电表 50% 的故障状态历史数据作为预测测试数据集, 设定精度基准值为 $Z' = 90\%$, 利用上述预测规则对预测测试数据集中的数据实现精度评估。智能电表故障状态预测结果如表 4 所示。预测测试数据集 T 中。数据样本条目数 J 为 248; 电表故障状态预测结果正确的样本条目数 K 为 235。则由式(6)可以得出评估精度 $Z = \frac{235}{248} \times 100\% = 94.7\%$ 。

由于实际评估精度 $Z \geq Z'$, 可确认已生成的待定预测规则为最终的电表状态预测规则, 并能在此基础上得

到智能电表故障状态的精准预测模型。

表 4 测试数据集预测结果
Tab.4 Test data set prediction results

序号	电能使用状态	未检测天数	环境条件	运转时长	异常频次	可靠性	电表状态	预测结果
1	III	II	II	III	II	I	故障	故障
2	II	II	II	II	I	II	故障	故障
3	I	I	II	II	II	I	正常	正常
4	II	II	I	II	II	II	故障	故障
5	II	I	II	III	I	II	故障	故障
6	II	II	I	II	I	II	正常	正常
7	II	II	II	II	I	II	故障	故障
8	II	I	I	II	II	I	正常	正常
9	II	II	I	II	II	I	故障	故障
...
60	I	II	II	II	I	II	正常	正常
...
183	II	II	II	I	I	II	正常	正常

5 结论

针对智能电表的故障预测问题, 本文提出了基于 Apriori 算法获取智能电表状态的强影响因素。根据 Apriori 算法获得的 873 条关联规则, 确定了电能使用状态、环境条件、运转时长、未检修天数、可靠性和异常频次作为智能电表状态强影响因素。以此为基础, 采用 C5.0 算法建立了智能电表故障预测模型。该预测模型以 9 条预测规则作为智能电表故障预测方法, 可实现智能电表状态的快速准确预测。基于某地区智能电表故障状态历史数据的算例分析结果表明, 本文提出的基于 C5.0 决策树算法的智能电表故障状态精准预测模型的准确率高达 94.7%, 预测效果良好。

参考文献:

- [1] 张文嘉, 江小昆, 王旭, 等. 基于误差在线自诊断技术的智能电表设计[J]. 自动化仪表, 2020, 41(4): 16-22.
- [2] 徐大青, 梁文鹏, 王鹏, 等. 智能电表数据分析方法及应用[J]. 供用电, 2015, 32(8): 25-30.
- [3] 刘紫熠, 刘卿, 王崇, 等. 基于智能电表运行故障数据的纵向分析模型[J]. 计算机科学, 2019, 46(S1): 436-438, 456.
- [4] 郑松松. 基于面向对象通信协议的智能电表功能深化应用[J]. 中国仪器仪表, 2017(7): 26-29.
- [5] 何熹, 龙周. 基于物联网的用电信息采集系统[J]. 信息通信, 2016(11): 83-84.
- [6] 梁文鹏, 赵磊, 王兵, 等. 智能电表数据分析元及示例[J]. 南方电网技术, 2016, 10(1): 1-5.
- [7] 刘卫兵, 许春香. 基于物联网的智能电表实时监测系统[J]. 仪表技术与传感器, 2017(12): 72-75.
- [8] 王涛, 孙志鹏, 崔青, 等. 基于分类决策树算法的电力变压器故障诊断研究[J]. 电气技术, 2019, 20(11): 16-19.

(下转第 101 页)

模式下,通过站台门和间隙探测系统的就地控制盘分别关闭站台屏蔽门、启动间隙探测系统时,如检测到有障碍物,间隙探测系统向信号系统反馈“有障碍物”信息,联锁系统立即关闭出站信号机,以防止列车运行,避免发生乘客被夹在站台屏蔽门和列车车门之间的危险事故。

5 结论

随着轨道交通技术装备水平的不断提升,特别是全自动运行线路的逐步推广应用,无人值守运行条件对系统的安全性、可靠性和可用性提出了更高的要求。通过站台间隙探测系统与信号系统的接口设计,实现系统间的联动控制,是保障运营安全、提升运营效率的重要条件。在实际工程设计中,应根据运营线路特点,选取适合工程实际运行等级、线路应用场景的接口方案,以满足运营实际需求,提升运营安全和效率,从而更好地服务于城市轨道交通发展。

(上接第89页)

4 结论

本文提出了在DCS网络中增加网络安全管理设备,以实现网络安全管理中心功能的方案。通过合规性分析,该方案在安全管理中心方面基本可以满足等保四级的要求。同时,本文也提出了现有方案和网络安全设备的改进方案,可开发与不同品牌网络安全设备、网络设备、DCS之间的通信接口,增加与DCS相适应的冗余网络切换机制,满足核电厂DCS网络安全的设计要求。

参考文献:

- [1] 张卫军.铁路通信网络安全管理中心技术方案研究[J].中国安全科学学报,2019,12(29):89.
- [2] 王伟,苏耀东.智能工厂工业控制系统安全体系构建与思考[J].

(上接第94页)

- [9] 赵鹏,赵明敏,林姗姗,等.智能变电站电子式互感器电磁干扰分析[J].自动化仪表,2021,42(1):10-16.
- [10] 王立州,付飞亚,刘亚辉.基于IR46标准的新型智能双芯电表设计[J].自动化仪表,2018,39(5):20-24.
- [11] MARIO B, BRYAN R. Goldsmith. Identifying consistent statements about numerical data with dispersion-corrected subgroup discovery[J]. Data Mining and Knowledge Discovery, 2017, 31(5): 1391-1418.
- [12] 文武,郭有庆.结合遗传算法的Apriori算法改进[J].计算机工

参考文献:

- [1] 侯妍君,李鑫磊,申樟红,等.站台门与车门间隙探测装置研究[J].现代机械,2020(1):94-97.
- [2] 郭禹.激光雷达技术在北京地铁站台门间隙探测系统的应用[J].工艺设计改造及检测检修,2019(10):67-71.
- [3] 中华人民共和国国家质量监督检验检疫总局,中国国家标准化管理委员会.轨道交通城市轨道交通运营管理和指令/控制系统第1部分:系统原理和基本概念:GB/T 32590.1—2016[S].北京:中国标准出版社,2016.
- [4] 田波,祁艳艳,魏琳,等.光电技术在轨道交通测量中的应用研究[J].自动化仪表,2019(7):57-59.
- [5] 许敬辉.全自动运行系统下站台门新增异物探测与控制功能方案研究[J].铁道标准设计,2019(10):177-181.
- [6] 上官王请,王宁.轨道车辆的车厢门与站台间隙自动保护装置及其自动控制系统[J].建筑工程技术与设计,2018(12):5167.
- [7] 王炯.城市轨道交通站台屏蔽门与列车间隙安全探测系统[J].城市轨道交通研究,2013(10):113-116.
- [8] 魏刚,张小虎,陈宁宁.城市轨道交通站台门与车门间隙探测系统研究[J].铁道通信信号,2020(9):85-88.

石油化工自动化,2021(3):1-5.

- [3] 国家市场监督管理总局,中国国家标准化管理委员会.信息安全技术 网络安全等级保护基本要求:GB/T 22239—2019[S].北京:中国标准出版社,2019.
- [4] 国家质量技术监督局.计算机信息系统安全等级保护划分准则:GB 17859—1999[S].北京:中国标准出版社,1999.
- [5] 国家市场监督管理总局,中国国家标准化管理委员会.信息安全技术 网络安全等级保护定级指南:GB/T 22240—2020[S].北京:中国标准出版社,2020.
- [6] 国家质量监督检验检疫总局,中国国家标准化管理委员会.信息安全技术 术语:GB/T 25069—2010[S].北京:中国标准出版社,2010.
- [7] 国家质量监督检验检疫总局,中国国家标准化管理委员会.信息安全技术 工业控制系统安全控制应用指南:GB/T 32919—2016[S].北京:中国标准出版社,2016.

程与设计,2019,40(7):1922-1926.

- [13] 陈勇,李胜男,张丽,等.基于改进Apriori算法的智能变电站二次设备缺陷关联性分析[J].电力系统保护与控制,2019,47(20):135-141.
- [14] 杜冠洲,韦古强,凌俊斌.基于数据挖掘技术的风电设备可靠性分析[J].中国设备工程,2017(12):92-94.
- [15] 蒋平,李宁,孙谊娟,等.C5.0算法在极端环境输电线路巡检中的应用[J].电网与清洁能源,2016,32(11):20-24,30.