

基于时空卷积神经网络的智能电表故障预测

高文俊, 薛斌斌, 庞振江

(北京智芯微电子科技有限公司, 北京 102299)

摘要: 针对智能电表故障具有的突发性、复杂性以及多面性等特点, 提出一种基于时空卷积神经网络(ST-CNN)的故障预测方法。该方法首先采用滑动窗口将时间信息融入特征变量中, 构建具有时空特性的输入矩阵, 然后与 CNN 相结合, 建立智能电表故障预测模型, 并采用 Adam 算法对模型参数进行优化。最后应用现场的实际数据对基于 ST-CNN 的智能电表故障预测模型进行仿真, 结果表明该方法预测精度高, 泛化能力强。

关键词: 智能电表; 故障预测; 卷积神经网络; 时空

中图分类号: TP183; TM933.4

文献标识码: A

DOI: 10.16157/j.issn.0258-7998.212289

中文引用格式: 高文俊, 薛斌斌, 庞振江. 基于时空卷积神经网络的智能电表故障预测[J]. 电子技术应用, 2022, 48(3): 59-63.

英文引用格式: Gao Wenjun, Xue Binbin, Pang Zhenjiang. Fault prediction of smart meter based on spatio-temporal convolution neural network[J]. Application of Electronic Technique, 2022, 48(3): 59-63.

Fault prediction of smart meter based on spatio-temporal convolution neural network

Gao Wenjun, Xue Binbin, Pang Zhenjiang

(Beijing Zhixin Microelectronics Technology Co., Ltd., Beijing 102299, China)

Abstract: The faults of smart meters are sudden, complex and multifaceted. A fault prediction method based on spatio-temporal convolutional neural network(ST-CNN) is proposed. Firstly, the sliding window is used to integrate the time information into the characteristic variables, and the input matrix with space-time characteristics is constructed. Then, combined with CNN, the fault prediction model of smart meter is established, and the model parameters are optimized by adaptive momentum estimation (Adam) algorithm. Finally, the actual field data are used to simulate the fault prediction model of smart meter based on ST-CNN. The results show that this method has high prediction accuracy and strong generalization ability.

Key words: smart meter; fault prediction; CNN; spatio-temporal

0 引言

我国电网从“信息化”向“智能化”发展是未来的必然趋势^[1]。智能电表是智能电网数据采集的基本设备之一, 承担着原始电能数据采集、计量和传输的任务, 是实现信息集成、分析优化和信息展现的基础。近年来, 随着智能电网信息采集系统的建设, 智能电表已经获得了大范围的推广和应用。如此大规模的智能电表一旦出现故障, 会影响到电网的控制和管理, 与人民的切身利益和社会的和谐稳定密切相关^[2-3]。

目前, 国内主要是通过定期巡检的方式确定电表的故障信息, 并作进一步处理。但是该方法需要耗费大量的人力、物力和时间资源, 并且需要巡检人员具备一定的专业知识^[4]。随着我国科技的快速发展, 越来越多的智能电表数据被采集和存储, 采用数据挖掘的方法对智能电表的故障数据进行特征提取, 捕捉各特征间的影响规律, 实现对智能电表的故障预测成为未来发展的重要方向^[5]。

近年来, 关于智能电表的故障预测研究仍处于初步阶段。文献[6]采用一种基于聚类分析和云模型的智能电表故障分类方法, 但是聚类的方法很难定义故障的种类。文献[7]采用基于评分搜索的方法构建了贝叶斯网络结构, 在此基础上对智能电表的故障进行预测和决策分析。但是贝叶斯网络对输入数据的表达形式敏感, 当属性个数较多或属性之间相关性较大, 数据量较大时, 分类效果会受到影响。文献[8]通过人为删除重复数据与无关数据, 补全数据中的缺失值, 获得预测数据和特征数据, 采用神经网络的方法对智能电表的故障类型进行分析。该方法可以良好地针对海量数据进行建模, 但是需要先对数据的输入特征和无关数据进行人为处理, 人为选择的相关特征很有可能会舍弃掉一部分有用的数据信息, 使故障预测精度受到影响。

卷积神经网络相比于传统的 BP 神经网络、SVM 等算法^[9-10], 更适用于高维数据, 具有更强的特征捕捉能力, 目前在诸多工业领域都有良好的表现^[11-13]。

考虑到智能电表故障呈现出的动态性、复杂性、多面性等特点,本文提出了一种基于时空卷积神经网络的智能电表故障预测模型,该模型将时间信息融入特征变量中,构建具有时空特性的输入矩阵,并与卷积神经网络相结合,实现对智能电表故障的准确预测。通过实例验证,本文提出的模型具有较高的预测精度,对于实现智能电表的故障预测是合理有效的。

1 基于 ST-CNN 智能电表故障预测的研究

1.1 基于 ST-CNN 智能电表故障预测模型建立

考虑到智能电表故障呈现出的动态性、复杂性、多面性等特点,本文提出基于 ST-CNN 的智能电表故障预测方法,其预测流程如图 1 所示。

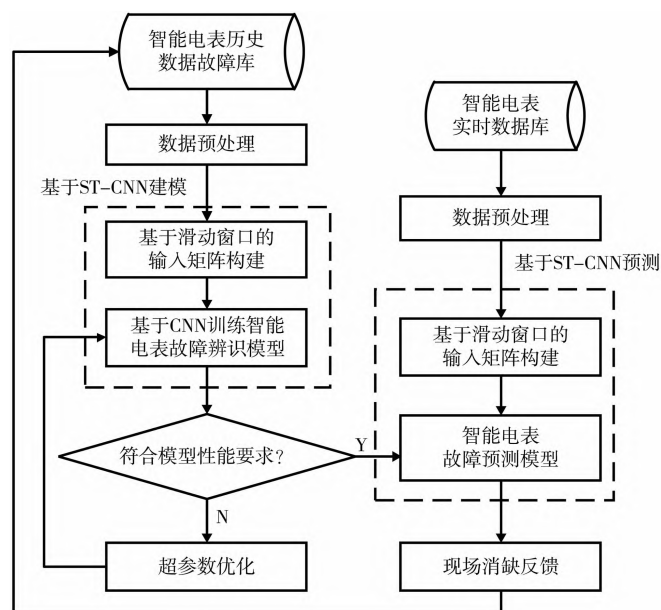


图 1 智能电表故障预测流程

首先对智能电表历史数据做预处理,包括基于中值滤波的异常值处理和归一化;然后基于滑动窗口将时间信息融入输入数据中,构建具有时空特性的输入矩阵;并与 CNN 相结合建立智能电表故障辨识模型,通过超参数优化的方法保证模型性能达到预设要求;最后,在此基础上,对实时数据进行故障预测,并与现场消缺反馈相结合,补充历史故障库,实现预测模型的实时优化与校正。

1.1.1 数据预处理

考虑到采集数据中异常值的存在会对模型精度造成影响,本文采用中值滤波的方法对特征变量进行异常值剔除。

设 $o=(o_1, \cdots, o_i, \cdots, o_n)$ 为智能电表某变量的时间序列数据, o_n 表示第 n 时刻该变量的值。设窗口长度为 $2K+1$, K 为整数。那么对 o_i 进行中值滤波就是从变量 o 中抽取 $2K+1$ 个数,表示为: $o_{i-K}, \cdots, o_i, \cdots, o_{i+K}$, 其中, i 为窗口的中心位置;再将抽出的 $2K+1$ 个数按照数值大

小进行排列,选取中间位置的数据,数学表达式如式(1)所示:

$$\hat{x}_i = \text{median}(o_{i-K}, \cdots, o_i, \cdots, o_{i+K}) \quad (1)$$

式中, $\text{median}(\cdot)$ 表示求向量的中值, \hat{x}_i 就是 o_i 经过窗口长度为 $2K+1$ 的中值滤波器滤波后的结果。由于异常值相对较少,采用直接删除的方法。

设 \hat{x} 为变量 o 经过中值滤波后的结果,依据式(2),对 \hat{x} 进行归一化处理得到 x :

$$x = \frac{\hat{x} - \hat{x}_{\min}}{\hat{x}_{\max} - \hat{x}_{\min}} \quad (2)$$

式中, \hat{x}_{\min} 表示变量 \hat{x} 的最小值, \hat{x}_{\max} 表示变量 \hat{x} 的最大值。

1.1.2 基于滑动窗口的输入矩阵构建

现有智能电表故障预测研究往往忽略特征变量的时间特性,时间序列数据可以包含更多的有效信息,提高故障预测的实时性和准确性^[14]。本文采用滑动窗口的方法对每个特征变量的时间信息进行选择,获得输入矩阵,如图 2 所示。




图 2 基于滑动窗口的输入矩阵构建

为了捕捉数据的时间信息,对预处理后的数据 $\{X_i\}_{i=1}^n \in \mathbf{R}^{m \times n}$ 进行滑动窗口操作, $m=8$ 表示特征变量数量, n 表示时间序列个数, $X_i=(x_i^{(1)}, x_i^{(2)}, \cdots, x_i^{(8)})$ 。如图 2 所示,首先运行一个长度为 ω 的重叠滑动窗口,对于第 j 个特征变量,可以得到重叠的窗口子集序列 $x_i^{(j)}=(x_{i-\omega+1}^{(j)}, x_{i-\omega}^{(j)}, \cdots, x_i^{(j)})$, 则第 i 时刻,构造的输入矩阵表示如下:

$$X_i = \begin{bmatrix} x_{i-\omega+1}^{(1)} & x_{i-\omega+1}^{(2)} & \cdots & x_{i-\omega+1}^{(8)} \\ x_{i-\omega}^{(1)} & x_{i-\omega}^{(2)} & \cdots & x_{i-\omega}^{(8)} \\ \vdots & \vdots & \ddots & \vdots \\ x_i^{(1)} & x_i^{(2)} & \cdots & x_i^{(8)} \end{bmatrix} \quad (3)$$

1.1.3 基于 CNN 的故障预测模型建立

CNN 是一种人工神经网络,不同于 MLP,它考虑了输入数据的空间关系,可以更好地捕捉多变量间的非线性相关性^[15]。本文结合智能电表故障预测模型,介绍 CNN 算法的基本思想。

本文采用的 CNN 结构为 2 个卷积层、2 个池化层和 1 个全连接层,如图 3 所示。




图 3 本文所用 CNN 网络结构

已知构建的输入矩阵 \mathbf{X} 为输入变量,对应的故障类别 \mathbf{Y} 为输出变量。CNN 的训练过程主要包括正向传播和反向传播。

(1) 正向传播:

卷积层 C_1 的传播过程如下式所示:

$$\begin{cases} \mathbf{Z}_{q_1}^{C_1} = \mathbf{X} \otimes \mathbf{K}_{1,q_1}^{C_1} + b_{q_1}^{C_1} \\ \mathbf{X}_{q_1}^{C_1} = f_{C_1}(\mathbf{Z}_{q_1}^{C_1}) \end{cases} \quad (4)$$

式中, \mathbf{X} 和 $\mathbf{X}_{q_1}^{C_1}$ 分别表示输入特征图(feature map)与输出特征图, q_1 表示输出的特征映射个数; \otimes 表示卷积运算; $\mathbf{K}_{1,q_1}^{C_1}$ 表示卷积核; $b_{q_1}^{C_1}$ 表示偏置; $f_{C_1}(\cdot)$ 表示 ReLU(Rectified Linear Unit)激活函数,并且满足 $f_{C_1}(x) = \max\{0, x\}$, 使用非线性激活函数能够更好地捕捉多个输入变量之间的非线性关系。

对于池化层 P_1 的每一个特征映射组 $\mathbf{X}_{q_1}^{C_1}$, 将其划分很多区域 $R_{m',n'}^{q_1}$, 则其最大池化(取一个区域内所有神经元的最大值)可以表示为:

$$\mathbf{X}_{q_1}^{P_1} = \max_{j \in R_{m',n'}^{q_1}} \mathbf{X}_{q_1}^{C_1}(j) \quad (5)$$

式中, $\mathbf{X}_{q_1}^{C_1}(j)$ 为区域 $R_{m',n'}^{q_1}$ 内每个神经元的激活值。

卷积层 C_2 的传播过程如下式所示:

$$\begin{cases} \mathbf{Z}_{q_2}^{C_2} = \sum_{q_1=1}^6 \mathbf{X}_{q_1}^{P_1} \otimes \mathbf{K}_{q_1,q_2}^{C_2} + b_{q_2}^{C_2} \\ \mathbf{X}_{q_2}^{C_2} = f_{C_2}(\mathbf{Z}_{q_2}^{C_2}) \end{cases} \quad (6)$$

式中, $f_{C_2}(\cdot)$ 表示 ReLU 激活函数。

池化层 P_2 的传播过程如下式所示:

$$\mathbf{X}_{q_2}^{P_2} = \max_{j \in R_{m',n'}^{q_2}} \mathbf{X}_{q_2}^{C_2}(j) \quad (7)$$

全连接层的作用则是对提取的特征进行非线性组合以得到输出,特征图在全连接层中会失去空间拓扑结构,被平铺(Flatten)为向量,如下所示:

$$\mathbf{X}^{FC-1} = \text{Flatten}(\{\mathbf{X}_{q_2}^{P_2}\}_{q_2=1,2,\dots,12}) \quad (8)$$

则全连接层输入为 \mathbf{X}^{FC-1} ,全连接层的正向传播过程可以表示为:

$$\begin{cases} \mathbf{Z}^{FC} = \mathbf{W}^{FC} \cdot \mathbf{X}^{FC-1} + b^{FC} \\ \hat{\mathbf{Y}} = f_{FC}(\mathbf{Z}^{FC}) \end{cases} \quad (9)$$

式中, \mathbf{W}^{FC} 表示全连接层权重, b^{FC} 表示全连接层偏置, $\hat{\mathbf{Y}}$ 表示预测的故障结果, $f_{FC}(\cdot)$ 表示 sigmoid 激活函数, $f_{FC}(x) = \frac{1}{1+e^{-x}}$ 。

(2) 反向传播

损失函数如下式:

$$L(\mathbf{Y}, \hat{\mathbf{Y}}) = \frac{1}{2} \sum_{i=1}^N \|\mathbf{Y}_i - \hat{\mathbf{Y}}_i\|^2 \quad (10)$$

式中, N 表示训练样本个数, $\hat{\mathbf{Y}}$ 表示模型预测结果, \mathbf{Y} 表示实际结果。

CNN 的反向传播就是对参数 \mathbf{W}^{FC} 、 b^{FC} 、 $\mathbf{K}_{q_1,q_2}^{C_2}$ 、 $b_{q_2}^{C_2}$ 、 $\mathbf{K}_{1,q_1}^{C_1}$ 、 $b_{q_1}^{C_1}$ 的迭代更新,本文选用 Adam 优化方法对模型参数进行更新^[16]。

1.1.4 模型性能评价标准

本文采用准确率(Accuracy)、精确率(Precision)、召回率(Recall)和综合评价指标 $F1$ 共同作为智能电表故障辨识模型的评价标准。

分类评价指标的定义: TP(True Positive)表示将正类预测为正类数, TN(True Negative)表示将负类预测为负类数, FP(False Positive)表示将负类预测为正类数, FN(False Negative)表示将正类预测为负类数。

准确率(Accuracy)的计算公式如式(11)所示:

$$\text{ACC} = \frac{\text{TP} + \text{TN}}{\text{TP} + \text{TN} + \text{FP} + \text{FN}} \quad (11)$$

精确率(Precision)的计算公式如式(12)所示:

$$P = \frac{\text{TP}}{\text{TP} + \text{FP}} \quad (12)$$

召回率(Recall)的计算公式如式(13)所示:

$$R = \frac{\text{TP}}{\text{TP} + \text{FN}} \quad (13)$$

综合评价指标($F1$)的计算公式如式(14)所示:

$$F1 = \frac{2 \times P \times R}{P + R} \quad (14)$$

1.2 基于 ST-CNN 智能电表故障预测的算法研究

由节 1.1 可知基于 ST-CNN 智能电表故障预测的具体流程,本节对基于 ST-CNN 的智能电表故障预测算法进行具体描述。

(1) 通过智能电表故障库获得故障相关特征变量 $\mathbf{o} = (\mathbf{o}^{(1)}, \mathbf{o}^{(2)}, \dots, \mathbf{o}^{(s)})$, 输出故障类别 \mathbf{Y} 。其中, s 表示特征变量个数。

(2) 将 \mathbf{o} 代入式(1)进行异常值去除得到 $\hat{\mathbf{x}}$, 然后代入

式(2)进行归一化得到 \mathbf{x} 。

(3)将时间信息融入到 \mathbf{x} 中,根据式(3)构建输入矩阵 \mathbf{X} 。

(4)将 \mathbf{X} 作为输入,根据式(4)~式(9)进行 CNN 前向传播,得到输出结果 $\hat{\mathbf{Y}}$ 。

(5)根据式(10)计算模型损失函数,并采用 Adam 优化算法对模型参数进行更新,得到智能电表故障辨识模型。

(6)根据式(11)~式(14)建立模型评价标准,当该 4 个标准均大于 85%时,保存模型参数,获得智能电表故障预测模型;如果不满足预设要求则继续进行参数优化,直至满足要求为止。

(7)对于实时数据,根据式(1)~式(3)构建输入矩阵,并放入训练好的故障预测模型中,对故障类别进行实时预测。

(8)现场人员根据预测结果进行实时消缺和反馈,并将数据放入历史故障库,对故障预测模型进行实时的参数更新。

2 智能电表故障预测试验

2.1 样本数据选取

本文选择某公司智能电表故障库中的故障数据,故障类别共 8 类,分别是:正常、采集异常、电表示值不平、电表飞走、电表反向有功示值异常、电表倒走、电表时间异常和电表潜动异常。

智能电表故障相关数据共 8 种:包括总电量数、峰段电量数、平段电量数、谷段电量数、电流、电压、电表时间、终端时间。

数据的采样频率为每秒 1 个点,选择智能电表分别处于 8 类故障时,运行 30 min 的数据作为原始数据,共 14 400 个点。选择前 20 min 的连续数据为训练原始数据,共 9 600 个;选择后 10 min 连续数据作为预测原始数据,共 4 800 个。

2.2 输入矩阵构建

滑动窗口的大小选择为 1 min,即 60 个连续数据点,步长选择为 1。选择 8 个与智能电表故障相关的变量,所以,输入矩阵可以构建为 60×8 的矩阵。

将每个输入矩阵与对应的故障类别作为一个样本,获得样本数据共 14 280 个,其中训练样本 9 540 个,预测样本 4 740 个。

2.3 时空卷积神经网络模型结构

本文采用的时空卷积神经网络模型结构见表 1 所示,共采用 2 个卷积层、2 个池化层、1 个全连接层。学习率设置为 0.001,第一次估计的指数衰减率为 0.9,第二次估计的指数衰减率为 0.999,训练轮数设置为 1 000 次。

本文采用的核函数是 3×3,这是因为 3×3 是最小的能够捕获像素八邻域信息的尺寸,而且多个 3×3 的卷积层比一个大尺寸卷积层使用了更多的非线性激活函数,

表 1 时空卷积神经网络模型结构

层类型	核函数大小	步长	核函数数目	输出大小
输入层	—	—	—	60×8
卷积层 C ₁	3×3	1×1	6	60×8×6
池化层 P ₁	2×2	2×2	6	30×4×6
卷积层 C ₂	3×3	1×1	12	30×4×12
池化层 P ₂	2×2	2×2	12	15×2×12
全连接层 FC	—	—	—	360×1
输出层	—	—	—	8×1

判决性更强,同时使用的参数更少,模型复杂度更低。

本文采用 3×3 核函数堆叠的方法对模型结构进行试凑,当模型具有 2 层卷积层时,模型精度已经可以满足故障预测的需求,过高的层数在模型精度提升并不大,同时会造成大量的计算冗余。

2.4 智能电表故障预测结果

本文将目前智能电表故障预测常用的 BP 神经网络、随机森林、SVM 和朴素贝叶斯模型与本文方法作对比,结果如图 4 所示。




图 4 智能电表故障预测多模型对比

表 2 给出了本文方法与其他 4 个常用模型的预测结果对比。从表 2 可以看出,本文方法与其他 4 个模型相比,无论是在准确率、精确率、召回率,还是 F1 评价指标,都是表现最好的模型,这也说明了本文算法的有效性。

表 2 智能电表故障预测多模型对比

故障预测模型	准确率	精确率	召回率	F1
BP 神经网络	95.26	84.38	82.82	83.59
随机森林	95.97	88.13	84.43	86.24
SVM	96.15	90.63	83.82	87.09
朴素贝叶斯	96.78	90.00	87.80	88.89
本文方法	97.32	91.25	90.12	90.68

从表 2 可以看出,朴素贝叶斯的召回率高于 SVM,但是精确率低于 SVM,随机森林的召回率高于 SVM,但是精确率低于 SVM。这说明采用 4 种不同的评价标准,从不同的角度对模型进行综合判断才能更准确地对模型性能进行评价。

表 3 给出了本文所采用的方法在 8 种故障的预测结果。从表 3 可知,采集异常与电表示值不平这 2 类故障预测准确率较低,其他故障的预测准确率相差不多,其中,电表反向有功示值异常预测准确率最好。

表 3 本文方法各故障的预测结果

序号	故障类型	准确率	精确率	召回率	F1
1	正常	97.12	90.00	90.00	90.00
2	采集异常	96.43	85.00	89.47	87.18
3	电表示值不平	96.38	85.00	89.47	87.18
4	电表飞走	97.14	90.00	90.00	90.00
5	电表反向有功示值异常	98.58	100.00	90.91	95.24
6	电表倒走	97.84	95.00	90.48	92.68
7	电表时间异常	97.16	95.00	86.36	90.48
8	电表潜动异常	97.86	90.00	94.74	92.31

导致某类故障预测准确率较低的原因有很多,后续可以针对预测准确率低的故障开展详细研究,找到准确率低的具体原因,通过输入特征的修改和模型结构参数的调整提高模型的整体性能。

3 结论

本文采用滑动窗口的方法将时间信息融入输入变量中,并结合 CNN 捕捉数据的时空特性,提高了模型的精度和实时性。仿真结果表明,本文提出基于 ST-CNN 智能电表故障预测模型的准确率、精确率、召回率、F1 均高于其他 4 种对比模型。准确的预测智能电表故障不仅可以为现场运维人员提供数据参考,同时也可为电网的控制和管理提供理论和技术支持。

参考文献

[1] 辛培哲,蔡声霞,邹国辉,等.未来智能电网发展模式与技术路线初探[J].电力系统及其自动化学报,2019,31(2): 89-94.

[2] 毕晓东.智能电网:万亿蛋糕如何分享[J].电子技术应用, 2017,43(2):10-12.

[3] 张晶,代攀,吴天京,等.新一代智能电网技术标准体系架构设计及需求分析[J].电力系统自动化,2020,44(9): 18-26.

[4] 朱中文,周韶园.智能电能表的概念,标准化和检测方法初探[J].电测与仪表,2011,48(6):48-53.

[5] 商曦文,吉莹,张建寰.智能电能表运行状态评估技术研究综述[J].电测与仪表,2020,57(3):8.

[6] 江剑峰,朱彬若,张垠,等.一种基于聚类分析和云模型 的智能电表故障分类方法:中国,105866725A[P].2016- 04-20.

[7] 郑安刚,张密,曲明钰,等.基于贝叶斯网络的智能电能 表故障类型预测[J].电测与仪表,2018,55(21):143-147.

[8] 李贺龙,于海波,王春雨,等.一种基于机器学习预测智 能电表故障的方法及系统:中国,110794360A[P].2020- 02-14.

[9] 张宇,张昊,李胜,等.基于改进型神经网络的变电站监 控信息点表优化分析[J].电子技术应用,2019,45(11): 96-99.

[10] 赵彦涛,单泽宇,常跃进,等.基于 MI-LSSVM 的水泥生 料细度软测量建模[J].仪器仪表学报,2017,38(2):487- 496.

[11] YANG Y, FANG H. Research on the feature smoothing algorithm for point cloud data of large complex surfaces based on multichannel convolutional neural network[J].IEEE Transactions on Instrumentation and Measurement, 2020, 70:1-11.

[12] 陈利,刘艳艳.基于改进的 Faster R-CNN 的古建筑地砖 缺陷检测[J].电子技术应用,2021,47(1):31-35.

[13] 程起泽,陈泽华,张雲钦,等.基于 CNN-LSTM 的太阳能 光伏组件故障诊断研究[J].电子技术应用,2020,46(4): 66-70.

[14] 李媛,郑安刚,谭煌,等.基于时间序列的电能表月故障 数预测方法[J].中国电力,2020(6):72-80.

[15] HELBING G, RITTER M. Deep learning for fault detection in wind turbines[J].Renewable & Sustainable Energy Reviews, 2018,98(12):189-198.

[16] SUN Y, SZUCS G, BRANDT A R. Solar PV output predic- tion from video streams using convolutional neural net- works[J].Energy & Environmental Science, 2018,11(7): 1811-1818.

(收稿日期:2021-11-02)

作者简介:

高文俊(1981-),男,硕士,高级工程师, 主要研究方向:用电技术和电力自动化。

薛斌斌(1987-),男,硕士,工程师,主 要研究方向:电力采集。

庞振江(1978-),男,硕士,高级工程 师,主要研究方向:电力自动化。



扫码下载电子文档