

基于鉴别性粒度自适应设定和衰退掩码的智能电表可视故障分类方法

黄旭¹, 高欣¹, 李保丰², 翟峰², 秦煜², 梁晓兵²

(1. 北京邮电大学人工智能学院, 北京市 海淀区 100876;

2. 中国电力科学研究院有限公司, 北京市 海淀区 100192)

Classification of Smart Meter Visual Faults Based on Discriminative Granularity Adaptive Setting and Fading Mask

HUANG Xu¹, GAO Xin¹, LI Baofeng², ZHAI Feng², QIN Yu², LIANG Xiaobing²

(1. School of Artificial Intelligence, Beijing University of Posts and Telecommunications, Haidian District, Beijing 100876, China;

2. China Electric Power Research Institute, Haidian District, Beijing 100192, China)

ABSTRACT: Achieving accurate detection of the visual faults in the smart meters is crucial for the efficient operation and maintenance at the grid metering sites. Since different faulty meters have the highly similar layout structures with the features of small inter-class variance, the fine-grained image classification methods are effective means to mine the discriminative features under this condition. In the current mainstream researches, the confusion jigsaw mechanism is used to guide the model to learn the fixed granularity features, which tends to result in the redundant or incomplete features within the jigsaw patches. The masking mechanism is adopted to highlight the discriminative features by its constant masking of the non-discriminative feature regions, which ignores the information in the region that helps the classification. In this paper, a visual fault classification for smart meters based on the discriminative granularity adaptive setting and the fading mask is proposed. First, an attention map is constructed to present the importance distribution of the target features. The outlines of the important features in the map are transformed into the granularity values corresponding to the division of the jigsaw mechanism, and the discriminative granularity values reflecting the typical size of the target features are clustered and mined. According to this granularity of the division of the jigsaw, the integrity of the semantic features are effectively preserved within the jigsaw patches while reducing the redundant information. On this basis, the non-discriminative feature regions are mined according to the target feature importance distribution, and masks are applied to them. The mask

probability is attenuated in the iterative training to gradually reduce the occlusion degree of this region and guide the model to learn the feature information in this region that helps the classification. Finally, a progressive multi-granularity feature-guided learning framework is combined to fuse the feature information of different granularities to complete the classification. Extensive experiments are conducted on several authoritative and publicly available fine-grained image classification datasets and the smart meter visual fault dataset, and the proposed method is compared with 10 typical fine-grained image classification methods to verify its advancedness in terms of accuracy and the other metrics.

KEY WORDS: visual fault detection of smart meters; fine-grained image classification; discriminative granularity adaptive setting; fading mask mechanism

摘要: 实现智能电表可视故障的精准检测, 对电网计量现场的高效运维至关重要。不同故障电表的布局结构高度相似, 其特征呈现类间方差小的特点, 细粒度图像分类方法是此条件下挖掘鉴别性特征的有效手段。在目前主流研究中, 混淆拼图机制引导模型学习固定粒度的特征, 但容易导致拼图块内的特征冗余或不完整。掩码机制通过恒定遮挡非鉴别性特征区域来突出鉴别性特征, 但忽视了该区域中有助于分类的信息。该文提出了一种基于鉴别性粒度自适应设定和衰退掩码的智能电表可视故障分类方法。首先, 对训练图像构建注意力图, 以呈现目标特征的重要性分布, 将图中重要特征的轮廓尺寸转换为等效粒度值并进行聚类挖掘, 获得反映目标特征尺寸特点的鉴别性粒度值, 据此自适应设定拼图的划分粒度, 有效保留拼图块内语义特征完整性的同时减少冗余信息; 在此基础上, 根据目标特征重要性分布挖掘非鉴别性特征区域, 并对其施加掩码, 在迭代训练中衰减掩码概率, 逐步降低对该区域的遮挡程度, 引导模型学习此区域中有助于

基金项目: 国家电网有限公司总部科技项目(5400-202355230A-1-1-ZN)。

Project Supported by Science & Technology Project of State Grid Corporation of China (5400-202355230A-1-1-ZN).

分类的特征信息;最后结合渐进式多粒度特征引导学习框架,融合不同粒度的特征信息以完成分类。在多个权威公开的细粒度图像分类数据集和智能电表可视故障数据集开展大量实验,与10种典型细粒度图像分类方法对比,验证了所提方法在准确率等指标上的先进性。

关键词: 智能电表可视故障检测;细粒度图像分类;鉴别性粒度自适应设定;衰退掩码机制

DOI: 10.13335/j.1000-3673.pst.2023.0255

0 引言

国家正在大力建设新型电力系统,电力物物互联模式正在形成,新一代智能电能表正逐步走上时代舞台^[1]。智能电表是智能电网数据采集的基本设备之一,是实现信息集成、分析优化和信息展现的基础。智能电表的普及也带动新能源汽车、分布式电源等行业发展^[2]。

在新业务场景下,对智能电表的安全可靠性提出了更高的要求。计量现场中,智能电表在运行期间会遇到显示屏故障、外表盘破损、烧表、封印遭到破坏等可视故障,但目前其无法自主检测此类反映在电表外部的可视故障,主要依靠运维人员巡检排查、人眼识别、手工录入等方式进行处理。由于智能电表的数量暴增,过高的作业强度导致录入信息的可靠性受个体工作水平的影响较大,容易造成故障排查的不及时和不合理,难以满足高效运维的需求^[3]。通过构建“设备异常精准研判-现场辨识标注提示-后台信息融合归档”的智能化作业模式,运维人员借助移动作业终端拍摄图像,通过云边协同技术和机器视觉技术,自动完成设备故障信息和身份信息的识别及自动归档,这对提高计量现场的运维效率、保障电力系统的稳定运行具有重要意义。

目前,利用机器视觉技术来识别智能电表故障类型,已有学者开展了一定的研究。梁伟建等人^[4]设计了智能电表外观缺陷检测系统,利用边缘检测、模板匹配等图像处理技术,实现对智能电表屏幕、标牌、条码及指示灯的缺陷检测,并应用在生产线上。张昭等人^[5]设计了基于图像处理的智能电表显示屏缺陷的检测系统,利用边缘检测、直线检测、图像二值化处理算法对显示屏区域进行提取,分别对智能电表显示屏的字符、亮度和安装位置进行检测,实现对显示屏出厂合格要求的检测。王胜等人^[6]设计了智能电表显示缺陷质量检测系统,通过高斯金字塔对电表图像进行配准,进而以差影法进行缺陷分析检测,对包括标牌条形码与字符进行

识别,达到智能电表显示缺陷检测的目的。而此类方法的检测效果大多依赖专家在标准场景下进行精细化的参数调整。而在复杂的运维场景下,拍摄环境和拍摄角度的改变都会对上述传统机器视觉处理算法的识别效果产生较大的影响,鲁棒性较差。孙凯等人^[7]针对智能电表通信模块外观划痕检测的问题,采用了深度卷积神经网络技术,提出了一种像素级划痕检测框架,通过卷积、残差结构、空洞卷积、级联等操作实现了像素级的划痕检测。综上,目前针对智能电表可视故障问题,多数研究仍采取模板匹配法或人工提取特征等传统图像处理方法在标准场景下对电表的可视故障进行检测。基于深度学习的研究较少,且检测故障的类型较为单一。同时,针对非标准化环境下的智能电表可视故障多分类问题研究较少,智能化水平还远远不足^[8]。随着深度学习的发展,深度学习模型能够在大量图像中自动挖掘数据的内在规律和深层表示,能够有效解决复杂场景下电表可视故障检测的难点。智能电表发生可视故障时,不同故障电表间结构布局高度相似,故障特征的视觉差异较小,呈现类间方差小的特点,如电表屏幕不显示时,与正常电表之间往往只有屏幕上的局部差别。而深度学习中的常规图像分类方法,通过学习全局结构挖掘高级语义特征,却忽视了细节局部特征的作用。而基于细粒度图像分类的方法,能加强模型对目标局部和细节特征的关注,更适用于电表可视故障分类。

细粒度图像分类的任务是对同一父类的子类开展进一步的分类^[9]。由于技术的广泛应用价值,细粒度图像分类技术被广泛应用于生物多样性检测^[10]、智能零售^[11]、智能交通^[12]等。细粒度图像分类的对象通常具有相似的全局结构,部分类别间的差异往往存在于局部细节中。此外,同类中也可能存在较大差异,或许是姿态、环境、拍摄角度导致的,也可能是因为同类中存在个体差异较大的样本。类间方差小和类内方差大都是影响分类效果的重要因素,如何在这样的干扰下挖掘具有鉴别性的类间差异特征对于细粒度图像分类至关重要。

为了解决上述挑战,早期的研究主要利用一些额外人工注释(边界框、关键点)来帮助分类模型定位图像中的更具鉴别性的特征区域^[13]。但在许多真实应用场景中,额外的人工注释依赖大量的专家经验,加上海量的数据需求,其带来的成本十分高昂,因此需要额外人工注释的方法难以投入实际应用。而近几年基于弱监督的细粒度图像分类方法避免了上述问题,此类方法的训练和测试无需引入额外

的人工标注,仅利用类别标签来建立图像特征与类别间的映射关系。弱监督方法主要分成2类^[14]:

1) 基于区域定位的方法; 2) 基于特征编码的方法。

基于区域定位的方法: 通过定位网络来定位目标的鉴别性特征区域, 根据该区域特征进行处理和分类。Zheng 等人^[15]提出的多头注意力卷积神经网络(multi-attention convolutional neural network, MA-CNN)采用特征通道聚类分组的方法,生成多样的候选区域以关注目标的多处局部细节。Ding 等人^[16]提出了选择性稀疏采样(selective sparse sampling, S3M)来分组学习鉴别性特征区域和互补性特征区域,通过非齐次变换来增强特征的纹理细节信息。

基于特征编码的方法: 通过对特征进行特殊的编码,挖掘更丰富的特征信息用于处理和分类。双线性卷积神经网络(bilinear convolutional neural network, B-CNN)^[17]是特征编码里最经典的方法之一,该方法提出了双线性卷积神经网络,对2组特征图进行外积融合,得到特征的二阶信息用于分类。Chen 等人^[18]提出了一种破坏和构造学习方法(destruction and construction learning, DCL),通过混淆机制打乱拼图,让模型学习局部细节信息,通过对抗损失函数来学习还原初始的空间语义信息。Chang 等人^[19]提出了通道交互损失(mutual-channel loss, MC-loss),引导特征通道分组,每组对应一个类别,每组中的多个通道关注该类别的不同鉴别性区域,仅用一个损失函数便可以解决细粒度图像分类问题,能与主流框架相结合。

对于区域定位的方法,在图像级监督下,准确预测局部特征的边界框仍然是一个开放性的问题,主流方法仍使用复杂且耗时的区域定位模型。同时,局部特征的边界框大小比例和数量通常是一个预定义的超参数,依赖专家经验设定。此外,通过边界框进行硬剪裁的方式忽略了局部区域的上下文信息,限制了特征的表达能力,尤其是定位错误时^[16]。而特征编码的方法更直接高效,近年来特征编码中关于多粒度特征挖掘技术已得到更多学者的关注。

一些关于多粒度特征挖掘的研究证明了兼顾细节纹理特征和全局结构特征的方式对于细粒度视觉任务十分有效。Du 等人^[20]提出了拼图块的渐进式多粒度训练方法(progressive multi-granularity training, PMG),构建多种尺度的混淆拼图,通过细粒度拼图学习细节特征,通过粗粒度拼图学习局部特征,通过渐进式训练完成由细到粗的逐步学习。Zhang 等人^[21]提出了多尺度擦除和混淆方法

(multi-scale erasure and confusion, MSEC)在高置信度拼图内二次构建混淆拼图来学习重要区域的更细粒度的特征信息,但仅对鉴别性区域进行更细粒度的特征划分,忽略了互补区域中细粒度特征的积极作用。

基于以上分析,融合分析细节局部特征和全局结构特征的多粒度特征挖掘技术,成为了细粒度图像分类领域的热点研究方向。目前主流研究中,引导模型学习固定粒度特征的混淆拼图机制,由于粒度设置不当,容易导致拼图块内出现特征冗余或不完整的问题;而恒定遮挡背景来突出鉴别性特征的掩码机制,忽视了非鉴别性特征中有助于分类的信息。为此,本文提出了一种基于鉴别性粒度自适应设定(discriminative granularity adaptive setting, DGAS)和衰退掩码(fading mask, FM)的智能电表可视故障分类方法,有效解决智能电表多类可视故障的检测问题,为电力系统的稳定运行和用电业务的稳定运转提供保障。

1 基于鉴别性粒度自适应设定和衰退掩码的细粒度图像分类方法

1.1 总体流程

所提方法整体流程如附录图 A1 所示,在第一阶段,设计了特征信息挖掘模块,该模块通过计算图像的梯度加权类激活映射关系构建注意力图,以反映特征的重要性分布,根据图中反映的特征轮廓完成等效粒度转换计算,随后对训练数据集的所有等效粒度进行聚类挖掘,得到一组能够反映目标重要特征典型轮廓尺寸的数值,称之为鉴别性粒度。在此基础上,特征信息挖掘模块利用注意力图计算出重要特征的中心坐标,遍历计算训练集所有重要特征的中心坐标,以获得目标重要特征的位置分布规律,并以此来判断鉴别性特征区域和非鉴别性特征区域。在第二阶段,根据鉴别性粒度可以将图像划分成不同粒度的拼图,根据特征分布规律,可以将拼图块大致区分为鉴别性特征拼图块和非鉴别性特征拼图块,概率掩码生成器对非鉴别性特征拼图块进行遮挡,并随训练迭代次数的增加而衰减遮挡概率,引导模型在训练前期优先关注鉴别性特征,在训练后期学习非鉴别性特征中有助于分类的信息。随后将拼图块的顺序进行混淆完成输入图像的最后转换,以破坏图像边界的语义信息,引导模型学习拼图块内对应粒度的特征信息^[20-21]。在第三阶段,将原始图像和转换后的多粒度掩码混淆拼图作为下游模型的输入,进行渐进式多粒度特征引导

学习,利用图像细粒度的细节纹理特征信息来引导模型学习粗粒度特征的高级语义信息,最后融合多粒度特征信息以完成分类。

1.2 注意力图计算

计算注意力图,是为了更有解释性地去监督模型对于图像特征的学习情况。通过计算梯度加权类激活映射关系来获得图像的注意力图,根据注意力图来挖掘有效特征的尺寸和位置信息,为后续进行鉴别性粒度自适应设定和衰退掩码提供依据。具体计算步骤如下:

如附录图 A2 所示,为了获得梯度加权类激活映射关系,首先将训练集的所有输入样本的尺寸调整为 $R \times R$, 随后将所有样本输入深度残差网络 ResNet^[22]; 对于每个样本,计算 ResNet 对当前输入样本的预测类别 y^c , c 为某一类别的编号;并提取该样本在深度残差网络 ResNet 正向传播过程中最后一个特征提取层输出的特征图 A_{ij}^k , k 为特征图 A_{ij}^k 的通道数, i, j 分别为特征图 A_{ij}^k 在行和列上的元素索引, z 为特征图 A_{ij}^k 的宽、高尺寸;在深度残差网络 ResNet 反向传播过程中,计算当前输入样本的特征图 A_{ij}^k 对其预测类别 y^c 的梯度 $\partial y^c / \partial A_{ij}^k$; 对梯度 $\partial y^c / \partial A_{ij}^k$ 进行全局平均池化,得到该样本第 k 个通道特征图的重要程度值^[23],用权重 a_k^c 表示:

$$a_k^c = \frac{1}{z^2} \sum_i \sum_j \frac{\partial y^c}{\partial A_{ij}^k} \quad (1)$$

通过该权重 a_k^c 对特征图不同通道上的值进行线性组合,得到注意力图的初步表示 A_{pre} :

$$A_{pre} = \sum_k a_k^c A_{ij}^k \quad (2)$$

ReLU 函数对注意力图中的元素值进行非线性激活,以消除负值的影响^[23],得到注意力图的最终表示 A_{final} :

$$A_{final} = \text{ReLU}(A_{pre}) \quad (3)$$

1.3 鉴别性粒度自适应设定

目前,如何根据数据集特点来自适应设定拼图的划分粒度缺少相关研究。大部分方法在粒度上是按照实验结果进行设定^[20-21]。

以屏幕故障的智能电表图像为例,如附录图 A3 所示,将图像划分为不同粒度的拼图后,观察屏幕关键区域的特征(红色线框区域),如果粒度设定太小(如 5×5),屏幕显示区域的基本信息不完整,有效特征难以完整保留。但一味地将粒度设定较大(如 2×2),虽然屏幕的信息相对完整,但也会导致拼图内其他冗余信息较多。而粒度设定合理的

情况下(如 3×3),屏幕的特征相对完整且占据拼图的主要空间,没有过多的其他信息,更利于模型学习对应故障类别的特征。

不同数据集的有效特征有各自的分布特点,需要根据数据集的特征尺寸特点来自动学习有效特征的粒度范围,以此设定一组合理的粒度引导模型学习对应粒度的特征。方法步骤如下:

每个样本的注意力图 A_{final} 可视作尺寸为 $z \times z$ 的矩阵,将其尺寸调整为 $R \times R$, 与输入样本相同;采用最小最大归一化方法对注意力图 A_{final} 进行归一化处理,并转换为灰度矩阵 M_{gray} ; 灰度矩阵 M_{gray} 的计算公式如下:

$$M_{gray} = \frac{A_{final} - \min(A_{final})}{\max(A_{final}) - \min(A_{final})} \times 255 \quad (4)$$

对灰度矩阵 M_{gray} 进行二值化处理,设定灰度阈值 T_{gray} ,将灰度矩阵 M_{gray} 中低于阈值 T_{gray} 的灰度值设为 0,将高于阈值 T_{gray} 的灰度值设为 255,得到二值矩阵 M_{binary} ; 采用 OpenCV 中的 minEnclosingCircle 算法,计算二值矩阵 M_{binary} 中特征轮廓的最小外接圆 c_i ,并得到圆的直径 d_i ,通过公式 R/d_i 得到特征的等效粒度 g_i ; 遍历训练集的所有样本得到特征等效粒度组 $G_{equivalent} = [g_1, \dots, g_m]$, m 为遍历训练集所有样本后计算所得特征轮廓的总数;参考箱型图算法^[24],基于公式(5)在等效粒度组 $G_{equivalent}$ 中过滤掉边界外的粒度 $g_{outlier}$,得到有效粒度组 G_{effect} 。

$$\begin{cases} q_3 = \text{round}[\frac{3 \times (m+1)}{4}] \\ q_1 = \text{round}[\frac{1 \times (m+1)}{4}] \\ Q_3 = g_{q_3}, Q_1 = g_{q_1} \\ D_{IQR} = Q_3 - Q_1 \\ B_{upper} = Q_3 + \frac{3}{2} D_{IQR} \\ B_{lower} = Q_1 - \frac{3}{2} D_{IQR} \\ g_i = \begin{cases} g_{effect}, & g_i \in [B_{lower}, B_{upper}] \\ g_{outlier}, & \text{其他} \end{cases} \end{cases} \quad (5)$$

式中: q_3 为上四分位数索引; q_1 分别为下四分位数索引; Q_3 为上四分位数; Q_1 为下四分位数; D_{IQR} 为四分位距; B_{upper} 为上界; B_{lower} 为下界。

采用 k-means^[25]聚类算法对有效粒度组 G_{effect} 进行聚类,根据聚类中心取整得到鉴别性粒度组 $G_{discriminative} = [g_1, \dots, g_n]$; 训练集中的每张电表图像

都将被划分成多种粒度的拼图,即图像被分成 $g_i \times g_i$ 个图像块, $i \in [1, n]$, 鉴别性粒度组中包含 n 种粒度。

1.4 衰退掩码

根据 1.3 节得到的鉴别性粒度将图像划分成对应粒度的拼图,意味着每个拼图块包含了不同的特征。在训练初期,鉴别性特征是帮助模型分类的主要因素,而非鉴别性特征可能是冗余的,导致模型关注过多无关信息,如附录图 A4 所示,鉴别性特征区域占比整体图像的 30% 左右。若不经处理直接对拼图进行混淆,冗余特征信息过多,不利于模型高效定位关键特征区域。而对输入图像的非鉴别性特征进行遮挡后再进行混淆,包含鉴别性特征的拼图块占比提高至 60% 左右,这更利于模型快速关注到目标的鉴别性特征。

在模型训练的初始阶段,对非鉴别性特征信息进行一定概率的遮挡,引导模型学习鉴别性特征信息,有助于模型向正确的方向收敛。与此同时,考虑到部分数据集的非鉴别性特征信息对于分类可能存在一定辅助作用,因此不希望全程遮挡非鉴别性特征信息,而是在训练初期对鉴别性特征信息学习充分的情况下,再去引入非鉴别性特征信息带来的辅助作用,而不是在训练初期就受到这些信息的干扰。

如附录图 A5 所示,考虑根据数据集的重要特征位置分布来设计衰退掩码机制,具体步骤如下:

采用 OpenCV 中的 minEnclosingCircle 算法对训练集每个样本的二值矩阵 M_{binary} 计算特征轮廓的最小外接圆 c_i 的圆心坐标 (x_i, y_i) ; 在遍历训练集的所有样本后,得到一系列特征轮廓的中心位置 $P = [(x_1, y_1), (x_2, y_2), \dots, (x_m, y_m)]$, m 为遍历训练集所有样本后计算所得特征轮廓的总数,与等效粒度的数量一致;以坐标 x, y 这 2 个维度,采用 matplotlib.pyplot 中的库函数 hist2d 对 P 进行二维直方图统计,得到二维直方图矩阵 M_{hist} , 二维直方图矩阵 M_{hist} 的行数和列数皆设定为鉴别性粒度组 $G_{\text{discriminative}}$ 中的粒度值,根据不同粒度值可以得到多个二维直方图矩阵;以其中一个二维直方图矩阵 M_{hist} 为例,基于公式(6)计算拼图块的衰退概率矩阵 M_{fading} , 其中, M_{normal} 为标准化矩阵; $T_{\text{threshold}}$ 为阈值; $M_{\text{discriminative}}$ 为鉴别性矩阵; $M_{\text{complementary}}$ 为辅助性矩阵; δ 为偏置系数; $F_{\text{fading}}(x)$ 为衰减函数; β_{fading} 为初始衰减概率; e_{poch} 为回合数; M_{fading} 为衰退概率矩阵。

$$\begin{cases} M_{\text{normal}} = \frac{M_{\text{hist}} - \min(M_{\text{hist}})}{\max(M_{\text{hist}}) - \min(M_{\text{hist}})} \\ T_{\text{threshold}} = \text{mean}(M_{\text{normal}}) \\ M_{\text{discriminative}} = \begin{cases} 1, & M_{\text{normal}} \geq T_{\text{threshold}} \\ M_{\text{normal}}, & M_{\text{normal}} < T_{\text{threshold}} \end{cases} \\ M_{\text{complementary}} = 1 - M_{\text{discriminative}} \\ F_{\text{fading}}(x) = (x - \delta) \frac{\beta_{\text{fading}}}{\sqrt[3]{e_{\text{poch}}}} \\ M_{\text{fading}} = F_{\text{fading}}(M_{\text{complementary}}) \end{cases} \quad (6)$$

式(6)中,对 M_{hist} 行最大最小归一化后得到的 M_{normal} , M_{normal} 对应非鉴别性区域的值更接近 0, 鉴别性特征区域的值更接近 1, 因此将 M_{normal} 中均值以上的元素值置 1 得到 $M_{\text{discriminative}}$, 能够使得 $M_{\text{discriminative}}$ 中鉴别性特征区域的值为 1, 非鉴别性特征区域的值接近 0。对 $M_{\text{discriminative}}$ 取反得到 $M_{\text{complementary}}$, 则 $M_{\text{complementary}}$ 中鉴别性特征区域的值为 0, 乘上任何的衰减系数都不发生改变。因此,以上处理能够使得鉴别性特征区域不会被遮挡。而 $M_{\text{complementary}}$ 中的非鉴别性特征区域的值接近 1, 此区域的被遮挡的概率较高,且能够通过衰减函数 $F_{\text{fading}}(x)$ 对其概率进行衰减。由于 $M_{\text{complementary}}$ 中非鉴别性特征区域的部分相邻元素值差异较小,直接根据训练轮次 e_{poch} 的增加而进行衰减,各区域的遮挡程度缺少区分度,因此减去偏置系数 δ , 再乘上初始衰减概率 β_{fading} 使得不同非鉴别性特征区域的遮挡程度更有层次。同时通过三次方根的指数衰减方式有助于在模型训练初期对非鉴别性特征区域能够保持较高的遮挡,而在训练后期对非鉴别性特征区域能够保持较低的遮挡率。最终计算得到各拼图块的衰退概率矩阵 M_{fading} , 其尺寸为 $g_i \times g_i$, 元素值记录了对应位置拼图块所施加掩码的概率。

根据衰退概率矩阵 M_{fading} 中不同位置的概率,对相应位置的拼图块进行遮挡。如附录图 A6 所示,随着训练不断迭代,遮挡程度逐渐下降。最后,将遮挡后的拼图进行随机打乱,得到掩码混淆拼图。

1.5 渐进式多粒度特征引导学习框架

如附录图 A7 所示,通过鉴别性粒度自适应设定和衰退掩码方法得到多粒度的掩码混淆拼图后,与原始图像一同作为智能电表可视故障分类模型的输入数据,其训练过程如下:

采用渐进式多粒度特征引导学习框架^[20],将故障分类模型训练分为多个阶段:首先利用最细粒度的拼图输入 ResNet^[22]构建的故障分类模型,引导分

类模型优先关注细粒度拼图中的特征信息。ResNet 包含了 5 个特征提取层，在此阶段冻结了最后 2 个特征提取层的权重参数，由前 3 个特征提取层完成对细粒度拼图特征信息的学习，通过权值共享将这 3 个特征提取层的参数传递到下一阶段；其次，解冻下一特征提取层的权重参数，向分类模型输入更粗粒度的拼图，引导模型逐步学习拼图中粗粒度的特征信息。最后，将前面所有特征提取层的参数传递到最后阶段，向分类模型输入原始图像，引导分类模型学习原始图像的全局结构。

在不同粒度的特征学习阶段分别使用不同的分类器进行训练，优化分类模型对相应粒度的特征学习能力；在不同特征学习阶段 s 计算交叉熵损失 L_{ce}^s ，其结果为

$$L_{ce}^s(\mathbf{t}, \mathbf{y}^s) = -\sum_{c=1}^{C-1} t_c \ln(y_c^s) \quad (7)$$

式中： \mathbf{t} 为真实标签分布； \mathbf{y}^s 为不同特征学习阶段预测概率分布； i 为当前特征学习阶段； C 为总类别数； c 为某一类别的编号； y_c^s 为概率分布 \mathbf{y}^s 中的元素，表示该阶段分类器将输入图像预测为第 c 类的预测概率。当图像的真实类别为 c 时，则真实标签分布 \mathbf{t} 中的第 c 个元素 t_c 为 1，否则为 0。

最后，将分类模型中后 3 个特征提取层输出的特征融合为全局特征进行分类，其预测概率分布用 \mathbf{y}^{con} 表示；分类损失的计算同上，预测结果如下：

$$P_{\text{pre}} = \text{argmax}(\sum_{s=1}^3 \mathbf{y}^s + \mathbf{y}^{\text{con}}) \quad (8)$$

式中 $\text{argmax}()$ 函数的作用是取向量中最大元素值的索引，即预测概率分布 \mathbf{y}^s 中包含对每个类别的预测概率，将预测概率最高值的索引编码作为最终的预测类别。

2 算例分析

由于本文是从细粒度图像分类的角度来解决智能电表可视故障分类问题，由于不同故障类型的智能电表可视故障之间具有高度一致的结构布局，从整体上观测，视觉差异较小，其鉴别性特征差异（例如封印、屏幕等）往往存在于局部区域，呈现类间方差小的特点。此特点也是细粒度图像分类领域所研究的共性问题，同样地，细粒度图像分类方法可以广泛应用于许多不同领域，尽管各领域数据集的显示特征存在较大差异，但细粒度图像分类模型能够发挥识别作用的本质在于，模型能够在高度相似的结构布局中挖掘出具有鉴别性的细粒度特征。因此，公开数据集的典型特征与电力仪表外貌和显

示特征并不相同，但公开数据集的样本种类和数量更丰富，包含了分布情况更为广泛的细粒度特征，因此能更加全面地验证模型对于鉴别性细粒度特征的挖掘能力，而此能力正是能否检测出不同智能电表可视故障的关键。

2.1 公开数据集介绍

本文在 3 个权威公开的细粒度图像分类数据集上进行了充分的实验，以充分验证模型对于鉴别性特征的挖掘能力。数据集为 CUB-200-2011^[26]、Stanford-Cars^[27]和 FGVC-Aircraft^[28]，分别对应鸟类品种识别、汽车型号识别以及飞机机型识别任务。

2.2 参数设置

实验环境：在 Ubuntu 20.04.4 操作系统下进行实验，显卡为 NVIDIA RTX 3090，使用了 3.8.3 版本的 Python，1.7.0 版本的 Pytorch。

预处理：在训练阶段，将输入图像调整成 550×550 的尺寸，并随机裁剪成 448×448 的尺寸，并采用了标准化和随机水平翻转作为数据增强的手段。在测试阶段，将输入图像调整成 550×550 的尺寸，并中心裁剪成 448×448 的尺寸。

主干网络：采用了在 ImageNet 上预训练的 ResNet-50^[22]作为所提方法的主干网络。

方法参数：在特征轮廓阈值的设置上，选择图像灰度值归一化后的上四分位数 191(255×75%)作为阈值，即激活值高于 75% 的区域视为重要特征区域，认为该比重能较好地反映该特征区域的重要程度。参考了有关粒度消融实验的最优参数^[20]，在鉴别性粒度自适应设定方法中，k-means^[25]的 k 值选为 3，即选择建立 3 种不同粒度的特征拼图，它能基本涵盖特征轮廓尺寸的分布范围，同时对聚类中心进行四舍五入取整得到整数的鉴别性粒度以指导多粒度拼图的划分。在衰退掩码中， \mathbf{M}_{hist} 是通过 matplotlib.pyplot 中的库函数 hist2d 进行统计，关键参数 bin 设置成计算所得的鉴别性粒度值。概率偏置系数 δ 设置为 0.9，初始衰退系数 β_{fading} 设置为 10，这样设计是为了使得在第一个 e_{poch} 中，最高概率的非鉴别性特征区域在初始阶段能够被完全遮挡，同时扩大不同非鉴别性特征区域被遮挡的概率差异，使得衰退掩码更有层次感。通过三次方根的指数衰减方式有助于在模型训练初期对非鉴别性特征区域能够保持较高的遮挡，而在训练后期对非鉴别性特征区域能够保持较低的遮挡率。

训练参数：采用随机梯度下降(stochastic gradient descent, SGD)优化器和批量正则化(batch normalization, BN)进行训练，卷积层和全连接层的

初始学习率设置为 0.002, 并在训练过程中遵循退火余弦计划逐渐降低。训练轮数为 100~300, 批训练尺寸(batch size)为 16, 重量衰减为 0.0005, 动量为 0.9。

2.3 评价指标

在公开数据集实验中, 实验采用准确率 A_{accuracy} 作为评价指标。在智能电表可视故障数据集实验中, 为了展示模型对不同故障类别的分类效果, 采用召回率 R_{recall} 和精确率 P_{recision} 作为评价指标。以当前关注的类为正类, 其他类作为负类, 则定义 T_p 表示被正确预测的正样本数, F_N 为被错误分类的正样本数, F_p 表示被错误分类的负样本数, T_N 表示被正确分类的负样本数。

相关指标的计算公式为

$$\begin{cases} A_{\text{accuracy}} = \frac{T_p + T_N}{T_p + T_N + F_p + F_N} \\ R_{\text{recall}} = \frac{T_p}{T_p + F_N} \\ P_{\text{recision}} = \frac{T_p}{T_p + F_p} \end{cases} \quad (9)$$

2.4 消融实验与可视化分析

为了分析所提方法中不同模块的影响, 本节进行了消融实验。以渐进式多粒度特征引导学习框架作为基准模型(Base)^[20], 分别验证了鉴别性粒度自适应设定(discriminative granularity adaptive setting, DGAS)和衰退掩码(fading mask, FM)的有效性, 同时也探究了各模块结合的效果。

首先, 为了验证鉴别性粒度自适应设定模块的有效性, 设计实验来对比多粒度手动设定和鉴别性粒度自适应设定下的识别效果。例如 9-6-3 指图像被划分成粒度为 9×9、6×6 和 3×3 的拼图。基准模型采用 8-4-2 的粒度设置。

如附录表 B1 所示, 设置了 6 组粒度参数进行了实验对比, 加粗了不同粒度设置下的最优实验结果。在 CUB-200-2011^[26]数据集下, 鉴别性粒度自适应设定实验结果和手动最优设定一致, 在 Stanford-Cars^[27]和 FGVC-Aircraft^[28]数据集下, 鉴别性粒度自适应设定实验结果和手动最优设定相差了 0.2%, 鉴别性粒度自适应设定取得了与手动最优设定下十分接近的实验结果。分析分类准确率的变化趋势发现, 三大公开数据集的鉴别性粒度虽有所不同, 但大多集中在 2 到 5 之间。

其次, 为了验证衰退掩码模块的有效性, 设计实验来对比在训练过程中对非鉴别性特征区域进行恒定遮挡的普通掩码(normal mask, NM)和衰退

掩码(fading mask, FM)的效果。如附录表 B2 所示, 对比了在鉴别性粒度自适应设定模块加入前后, 普通掩码和衰退掩码对模型分类效果的影响, 表格中加粗了同等情况下对比的最优结果。可以发现, 无论是否加入鉴别性粒度自适应设定模块, 采用衰退掩码的模型分类效果都优于恒定遮挡的普通掩码。

为了验证衰退掩码对非鉴别性特征的遮挡效果, 本文进行了可视化分析。如附录图 A8 所示, 在施加了衰退掩码后, 模型适当降低了对非鉴别性特征的注意力, 而将更多的注意力集中在了鸟类本体身上, 但也没有完全舍弃对其他信息的学习。

通过消融实验验证各模块的贡献, 如附录表 B3 所示, 加粗了相较基准模型更好的实验结果。在加入了鉴别性粒度自适应设定模块后, 在 3 个公开数据集上的实验效果都得到了提升。在加入衰退掩码后, 在 Stanford-Cars^[27]、FGVC-Aircraft^[28]这 2 个数据集上识别效果得到了提升, 而在 CUB-200-2011^[26]数据上识别效果无明显变化, 因为模型对于鸟这类自然生物进行分类时, 不只关注于鸟本身的特征信息, 还有可能将其生存环境因素考虑进去。因此在模型训练前期对非鉴别性特征信息进行遮挡的时候, 丢弃了一部分有助于加深模型对主体理解的生存环境信息, 随着训练轮次的增加, 逐步减低对生存环境信息的遮挡, 又使得模型恢复学习此类有用的信息, 因此准确率没有明显变化。而像 Stanford-Cars^[27]、FGVC-Aircraft^[28]这 2 个数据集, 像道路等背景环境特征信息下带来的影响更多是干扰, 因此在训练前期遮挡此类特征后, 能引导模型在接下来的训练阶段更关注主体本身。

2.5 公开数据集实验结果对比

为了验证所提方法的先进性, 在 3 个细粒度图像分类数据集上对比了一些典型的基于弱监督学习的细粒度图像分类方法, 其中包括基于模型微调的方法(FT ResNet^[29]), 基于区域定位的方法(S3N^[16]、AP-CNN^[30]、SAM^[31])和基于特征编码的方法(B-CNN^[17]、MA-CNN^[15]、DCL^[18]、MC-Loss^[19]、PMG^[20]、ELP-SR^[32])。为了与附录表 B1—B3 中的消融实验结果保持一致, 附录表 B4 中 PMG(Base)引用了消融实验结果, 其余 9 种对比方法均引用了原文提供的实验结果。如附录表 B4 所示, 所提方法在 3 个细粒度图像分类数据集下皆取得了第一的排名, 实验结果展现了本文所提方法的优越性。

2.6 智能电表可视故障数据集实验结果

将所提方法在智能电表可视故障数据集进行测试, 数据集收集了共计 5 种类型的智能电表图像

数据，其中包含正常电表和 4 类故障电表图像，如图 1 所示。鉴别性故障特征由红色虚线框标示，如封印缺失故障，电表左上角的封印是完整的，但电表的右上角封印缺失，导致螺丝钉暴露；烧表故障的主要特征在电表的条码区域附近有大片熏黑的痕迹；显示故障的主要特征表现为显示屏区域没有字符显示；表盘破损的主要特征表现为显示屏区域存在破损裂纹。




图 1 不同类型的智能电表可视故障

Fig. 1 Visual faults of different types of smart electricity meters

由于采集过程中的人为因素和环境因素的影响，所采集图像存在特征缺失、标签错误等情况，如直接使用，会造成模型难以正确学习目标特征。经数据清洗后，获得共计 720 条可靠样本数据，各类别的样本数量如附录表 B5 所示，数据集采用 6:4 的比例划分为训练集和测试集。

为了验证所提方法的有效性，本文同样在智能电表可视故障分类数据集展开了消融实验和可视化分析，消融实验采用准确率来评价模型分类效果的整体变化水平。

如表 1 所示，本文同样设置了 6 组粒度参数进行了实验对比。在手动设置粒度的实验结果中，6-4-2 组和 5-3-2 组取得了最优的实验结果，所提的鉴别性粒度自适应设定方法取得了同样高的准确率。智能电表可视故障分类数据集的鉴别性特征粒度集中在 2~6 之间。

表 1 智能电表可视故障数据集的消融实验结果			
Table 1 Accuracy results of ablation of visual fault datasets for smart electricity meter			
粒度	准确率/%	模块	准确率/%
9-6-3	95.5	Base	94.8
8-5-3	94.8	Base+NM	94.5
7-4-3	94.8	Base+FM	96.2
6-4-2	95.9	—	—
5-3-2	95.9	DGAS	95.9
4-3-2	94.8	DGAS+NM	94.8
—	—	DGAS+FM	97.9

在基准模型下，本文对比了加入普通掩码或衰退掩码的分类效果。加入普通掩码后，分类准确率下降 0.3%；而加入衰退掩码后，分类准确率提升 1.4%。在加入了鉴别性粒度自适应设定模块后，基

准模型的分类准确率提升 1.1%。在加入该模块的基础上，本文仍对比了加入普通掩码或衰退掩码的分类效果。加入普通掩码后，分类准确率下降 1.1%；而加入衰退掩码后，分类准确率提升 2%。

综合上述实验结果分析可知，鉴别性粒度自适应设定模块能够挖掘智能电表可视故障特征的鉴别性粒度，并引导模型学习对应粒度下的鉴别性特征，从而提升分类准确率。此外，普通掩码遮挡了许多原本有助于分类的特征信息，反而造成了分类效果的下降；而衰退掩码引导模型优先学习鉴别性特征，再补充其他信息作为决策依据，有效提升了分类准确率。

为了直观演示加入衰退掩码所产生的效果，本文进行了可视化分析。如附录图 A9 所示，以表盘破损故障为例，从左到右展示了在不同粒度的特征学习阶段，模型对电表特征的学习情况有所不同。在细粒度的特征学习阶段中，模型更多关注细节，且关注区域较为分散；而在更粗粒度的特征学习阶段中，模型关注更加集中。在加入衰退掩码前，这种情况更明显。在细粒度阶段中，模型的注意力相当分散，不仅关注了屏幕的裂纹区域，也关注了尾盖的特征；而在中粒度和粗粒度阶段中，模型还额外关注了条码区域的特征。但施加了衰退掩码后，这种情况得到了缓解，在细粒度阶段中，模型主要关注屏幕裂纹，较少关注其他特征；而在中粒度和粗粒度阶段，模型的关注点基本集中在了屏幕的裂纹区域，没有受到其他特征的干扰，更有利于引导模型学习鉴别性特征。

为验证所提方法的先进性，实验对比了 10 种典型的细粒度图像分类方法。同时，为了深入分析各类故障的分类效果，实验采用各类别的召回率和精确率指标来评价各方法的性能，其值越大，表示模型对该类的分类效果越好。

所提方法和典型细粒度图像分类方法在召回率指标上的实验结果如表 2 所示，所提方法在 5 个类别上均取得了第一的排名。在精确率指标上的实验结果如表 3 所示，所提方法除了在封印缺失类别下取得了第二的排名，在其余类别上均取得了第一的排名。分析得知，所提方法容易将其他类别预测为封印缺失类别，导致该类的召回率很高，但精确率不高。综合其他故障类别的指标结果分析，相较于其他典型的细粒度图像分类方法，所提方法对于智能电表可视故障的检测效果更好，获得了更具竞争力的分类精确率与召回率。表 2 和表 3 中加粗数据表示所提方法在分类指标上排名第一的结果。

表 2 所提方法与典型方法在召回率指标上的实验结果
Table 2 Recall results of the proposed method and typical methods

方法	召回率/%				
	正常	封印缺失	烧表	显示故障	表盘破损
B-CNN	89.2	81.3	100	84.3	78.9
MA-CNN	95.0	90.6	100	91.4	92.1
FT ResNet	94.2	90.6	100	90.0	94.7
DCL	91.7	87.5	100	88.6	86.8
S3N	94.2	81.3	100	90.0	81.6
MC-Loss	92.5	84.4	100	88.6	84.2
PMG	97.5	90.6	100	85.7	100
AP-CNN	97.5	90.6	100	97.1	100
SAM	94.2	93.8	100	94.3	92.1
ELP-SR	95.8	93.8	100	95.7	97.4
所提方法	97.5	100	100	97.1	100
平均值	94.5	89.5	100	91.2	91.6

表 3 所提方法与典型方法在精确率指标上的实验结果
Table 3 Precision results of the proposed method and typical methods

方法	精确率/%				
	正常	封印缺失	烧表	显示故障	表盘破损
B-CNN	85.6	76.5	95.2	92.2	83.3
MA-CNN	90.5	93.5	100	95.5	97.2
FT ResNet	90.4	93.5	100	94.0	97.3
DCL	88.0	87.5	100	93.9	89.2
S3N	85.6	83.9	95.2	98.4	96.9
MC-Loss	86.7	81.8	100	96.9	91.4
PMG	92.1	93.5	100	98.4	100
AP-CNN	95.9	93.5	100	98.6	100
SAM	92.6	88.2	100	98.5	94.6
ELP-SR	95.8	96.8	100	97.1	92.5
所提方法	98.3	94.1	100	98.6	100
平均值	91.0	89.3	99.1	96.6	94.8

实验对各类故障分类指标的平均值进行了统计(表 2 和表 3 按列取平均),烧表类别的平均召回率和平均精确率是最高的,这是因为烧表故障的特征占据图像区域的面积较大,具有较为明显的特征差异,因此模型更容易学习此类特征,分类效果更佳。但也可能由于烧表故障发生的概率更低,样本数量和多样性不足,导致模型存在过拟合的风险。封印缺失故障的平均召回率和平均精确率均最低,其原因如下:封印特征在采集图像中的占比面积最小,不如其他故障的视觉特征明显。同时,此类电表故障存在左封印缺失、右封印缺失或左右封印同时缺失的情况。缺失程度不一增大了模型对该类电表故障的学习难度,导致模型对该类故障的总体检测效果不如其他类别。除此之外,还可以发现,在正常类别的平均召回率较高的情况下,平均精确率却不高,这是由于样本数量不均衡,故障类别样本数量较少,而正常类别样本数量较多,导致分类模型的决策偏向于多数类,即偏向于正常类别。因此,对于智能电表可视故障分类问题,也需要考虑样本

数量不均衡对检测效果造成的影响。

3 总结与展望

本文提出了一种基于鉴别性粒度自适应设定和衰退掩码的智能电表可视故障分类方法。通过鉴别性粒度自适应设定技术,有效避免划分多粒度拼图时,由于粒度设定不当导致拼图块内更易出现特征冗余或不完整的问题。通过衰退掩码技术,有效避免模型训练前期非鉴别性特征中冗余信息的消极干扰,合理利用其中有助于分类的辅助信息。本文在 3 个公开细粒度图像分类数据集上将所提方法与 10 种典型细粒度图像分类方法进行了对比,结果表明所提方法更有利于挖掘目标的鉴别性特征,在准确率指标取得最佳。在智能电表可视故障数据集上将所提方法与 10 种典型的细粒度图像分类方法进行了对比,结果表明所提方法在召回率和精确率指标上有显著优势,更有利于检测各类电表可视故障。未来工作可进一步研究更精细化的训练策略,根据不同粒度特征的重要性对决策结果进行优化,进一步提升方法的性能。

附录见本刊网络版(<http://www.dwjs.com.cn/CN/1000-3673/current.shtml>)。

参考文献

[1] 李富盛,陈伟松,钱斌,等.面向低压配电网智能电表误差监测的 LightGBM-EM-EC 多变量缺失数据高效重建[J].中国电机工程学报,2022,42(S1):95-105.
LI Fusheng, CHEN Weisong, QIAN Bin, et al. Efficient reconstruction of multivariate missing data for smart meter error monitoring in low voltage distribution network based on Light GBM-EM-EC[J]. Proceedings of the CSEE, 2022, 42(S1): 95-105(in Chinese).
[2] 周润,向月,王杨,等.基于智能电表集总数据的家庭电动汽车充电行为非侵入式辨识与负荷预测[J].电网技术,2022,46(5):1897-1906.
ZHOU Run, XIANG Yue, WANG Yang, et al. Non-intrusive identification and load forecasting of household electric vehicle charging behavior based on smart meter data[J]. Power System Technology, 2022, 46(5): 1897-1906(in Chinese).
[3] 刘海莹,莫文昊,谈元鹏,等.基于方向自适应检测器的输电线路设备检测方法[J].电网技术,2021,45(12):4888-4895.
LIU Haiying, MO Wenhao, TAN Yuanpeng, et al. Oriented object detector for transmission line equipment detection[J]. Power System Technology, 2021, 45(12): 4888-4895(in Chinese).
[4] 梁伟建,洪涛,林笃盛,等.基于机器视觉的智能电表外观缺陷检测系统设计[J].电测与仪表,2013,50(10):64-68.
LIANG Jianwei, HONG Tao, LI Dusheng, et al. Design of smart meter visual inspection system based on machine vision[J]. Electrical Measurement & Instrumentation, 2013, 50(10): 64-68(in Chinese).
[5] 张昭.基于机器视觉的智能电表显示器缺陷的自动检测[D].北京:华北电力大学(北京),2018.
[6] 王胜.智能电表显示缺陷质量检测系统设计与实现[D].成都:电

- 子科技大学, 2019.
- [7] 孙凯, 翟晓卉, 赵吉福, 等. 基于深度学习的智能电表 HPLC 通信模块外观划痕检测[J]. 哈尔滨理工大学学报, 2022, 27(3): 66-72.
SUN Kai, ZHAI Xiaohui, ZHAO Jifu. Scratch detection on the appearance of smart meter HPLC communication module based on deep learning[J]. Journal of Harbin University of Science and Technology, 2022, 27(3): 66-72(in Chinese).
 - [8] 崔昊杨, 张雨阁, 张驯, 等. 基于边缘轻量级网络的电力仪表设备检测方法[J]. 电网技术, 2022, 46(3): 1186-1193.
CUI Haoyang, ZHANG Yuge, ZHANG Xun, et al. Detection of power instruments equipment based on edge lightweight network[J]. Power System Technology, 2022, 46(3): 1186-1193(in Chinese).
 - [9] XIAO Tianjun, XU Yichong, YANG Kuiyuan, et al. The application of two-level attention models in deep convolutional neural network for fine-grained image classification[C]//Proceedings of 2015 IEEE Conference on Computer Vision and Pattern Recognition. Boston: IEEE, 2015: 842-850.
 - [10] VAN HORN G, BRANSON S, FARRELL R, et al. Building a bird recognition app and large scale dataset with citizen scientists: the fine print in fine-grained dataset collection[C]//Proceedings of 2015 IEEE Conference on Computer Vision and Pattern Recognition. Boston: IEEE, 2015: 595-604.
 - [11] KARLINSKY L, SHTOK J, TZUR Y, et al. Fine-grained recognition of thousands of object categories with single-example training [C]//Proceedings of 2017 IEEE Conference on Computer Vision and Pattern Recognition. Honolulu: IEEE, 2017: 965-974.
 - [12] KHAN S D, ULLAH H. A survey of advances in vision-based vehicle re-identification[J]. Computer Vision and Image Understanding, 2019, 182: 50-63.
 - [13] CHAI Yuning, LEMPITSKY V, ZISSERMAN A. Symbiotic segmentation and part localization for fine-grained categorization [C]//Proceedings of 2013 IEEE International Conference on Computer Vision. Sydney: IEEE, 2013: 321-328.
 - [14] WEI Xiushen, SONG Yizhe, AODHA O M, et al. Fine-grained image analysis with deep learning: a survey[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2022, 44(12): 8927-8948.
 - [15] ZHENG Heliang, FU Jianlong, MEI Tao, et al. Learning multi-attention convolutional neural network for fine-grained image recognition[C]//Proceedings of 2017 IEEE International Conference on Computer Vision. Venice: IEEE, 2017: 5219-5227.
 - [16] DING Yao, ZHOU Yanzhao, ZHU Yi, et al. Selective sparse sampling for fine-grained image recognition[C]//Proceedings of 2019 IEEE/CVF International Conference on Computer Vision. Seoul: IEEE, 2019: 6598-6607.
 - [17] LIN T Y, ROYCHOWDHURY A, MAJI S. Bilinear CNN models for fine-grained visual recognition[C]//Proceedings of 2015 IEEE International Conference on Computer Vision. Santiago: IEEE, 2015: 1449-1457.
 - [18] CHEN Yue, BAI Yalong, ZHANG Wei, et al. Destruction and construction learning for fine-grained image recognition[C]//Proceedings of 2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Long Beach: IEEE, 2019: 5152-5161.
 - [19] CHANG Dongliang, DING Yifeng, XIE Jiyang, et al. The devil is in the channels: mutual-channel loss for fine-grained image classification[J]. IEEE Transactions on Image Processing, 2020, 29: 4683-4695.
 - [20] DU Ruoyi, CHANG Dongliang, BHUNIA A K, et al. Fine-grained visual classification via progressive multi-granularity training of jigsaw patches[C]//Proceedings of the 16th European Conference on Computer Vision. Glasgow: Springer, 2020: 153-168.
 - [21] ZHANG Yan, SUN Yongsheng, WANG Nian, et al. MSEC: multi-scale erasure and confusion for fine-grained image classification[J]. Neurocomputing, 2021, 449: 1-14.
 - [22] HE Kaiming, ZHANG Xiangyu, REN Shaoqing, et al. Deep residual learning for image recognition[C]//Proceedings of 2016 IEEE Conference on Computer Vision and Pattern Recognition. Las Vegas: IEEE, 2016: 770-778.
 - [23] SELVARAJU R R, COGSWELL M, DAS A, et al. Grad-CAM: visual explanations from deep networks via gradient-based localization[C]//Proceedings of 2017 IEEE International Conference on Computer Vision. Venice: IEEE, 2017: 618-626.
 - [24] TUKEY J W. Exploratory data analysis[M]. Reading: Addison-Wesley, 1977.
 - [25] MACQUEEN J. Some methods for classification and analysis of multivariate observations[C]//Proceedings of the Fifth Berkeley Symposium on Mathematical Statistics and Probability. Berkeley: the Fifth Berkeley Symposium on Mathematical Statistics and Probability, 1967: 281-297.
 - [26] WAH C, BRANSON S, WELINDER P, et al. The caltech-UCSD birds-200-2011 dataset[R]. Pasadena: California Institute of Technology, 2011.
 - [27] KRAUSE J, STARK M, DENG Jia, et al. 3D object representations for fine-grained categorization[C]//Proceedings of 2013 IEEE International Conference on Computer Vision Workshops. Sydney: IEEE, 2013: 554-561.
 - [28] MAJI S, RAHTU E, KANNALA J, et al. Fine-grained visual classification of aircraft[EB/OL]. [2023-2-28]. <https://arxiv.org/abs/1306.5151>.
 - [29] WANG Yaming, MORARIU V I, DAVIS L S. Learning a discriminative filter bank within a CNN for fine-grained recognition [C]//Proceedings of 2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Salt Lake City: IEEE, 2018: 4148-4157.
 - [30] DING Yifeng, MA Zhanyu, WEN Shaoguo, et al. AP-CNN: weakly supervised attention pyramid convolutional neural network for fine-grained visual classification[J]. IEEE Transactions on Image Processing, 2021, 30: 2826-2836.
 - [31] SHU Yangyang, YU Baosheng, XU Haiming, et al. Improving fine-grained visual recognition in low data regimes via self-boosting attention mechanism[C]//Proceedings of the 17th European Conference. Tel Aviv: Springer, 2022: 449-465.
 - [32] LIANG Yuanzhi, ZHU Linchao, WANG Xiaohan, et al. A simple episodic linear probe improves visual recognition in the wild [C]//Proceedings of 2022 IEEE/CVF Conference on Computer Vision and Pattern Recognition. New Orleans: IEEE, 2022: 9549-9559.



黄旭

在线出版日期: 2023-07-13.

收稿日期: 2023-02-28.

作者简介:

黄旭(1997), 男, 硕士研究生, 研究方向为电力系统自动化, E-mail: heliox1997@bupt.edu.cn;

高欣(1974), 男, 通信作者, 副教授, 博士生导师, 研究方向为电力系统自动化, E-mail: xlhhh74@bupt.edu.cn.

(责任编辑 徐梅)

附录 A

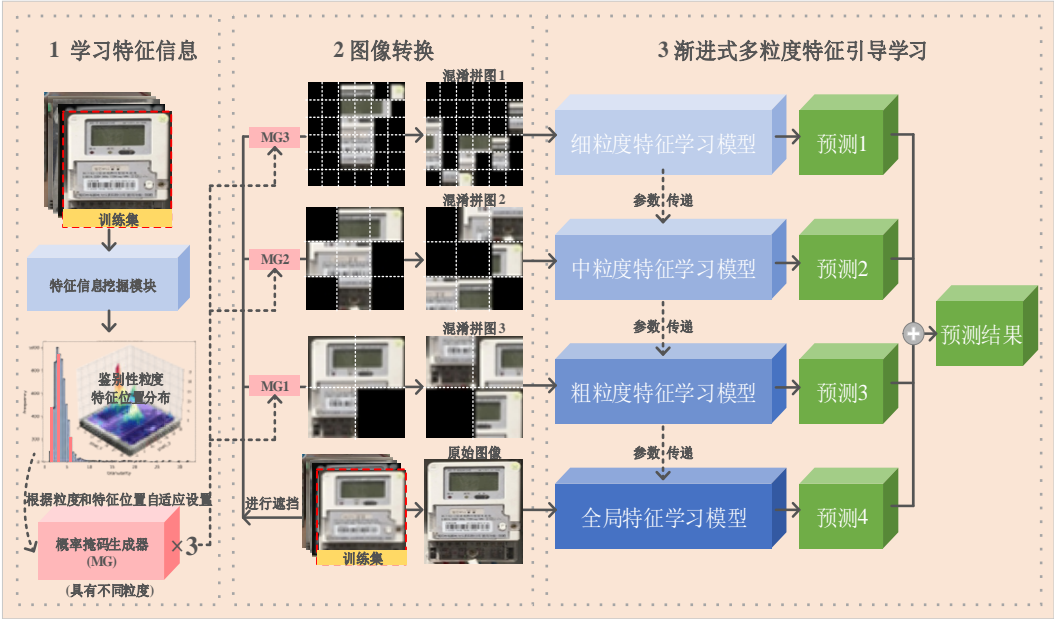


图 A1 所提方法训练流程

Fig. A1 Training process of the proposed method

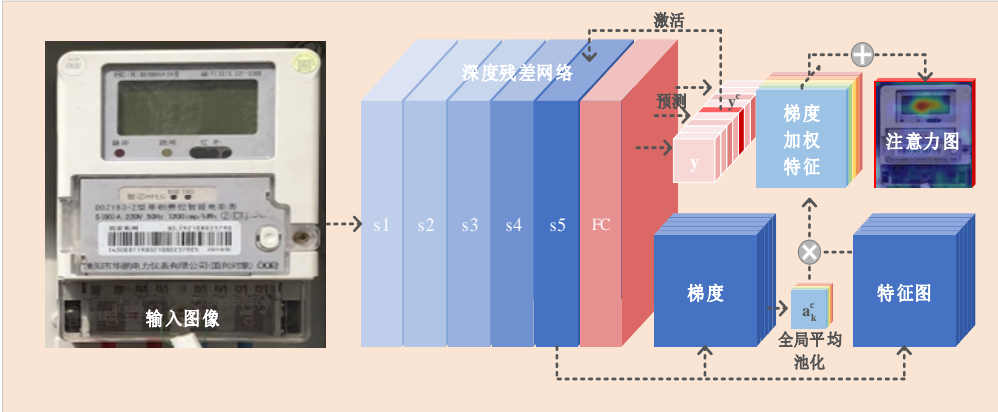


图 A2 梯度加权类激活映射

Fig. A2 Gradient weighted class activation map



图 A3 不同粒度拼图块内特征对比

Fig. A3 Comparisons of features in jigsaw patches with different granularities



图 A4 掩码在混淆拼图中的效果
Fig. A4 Effect of masks in the confused jigsaw

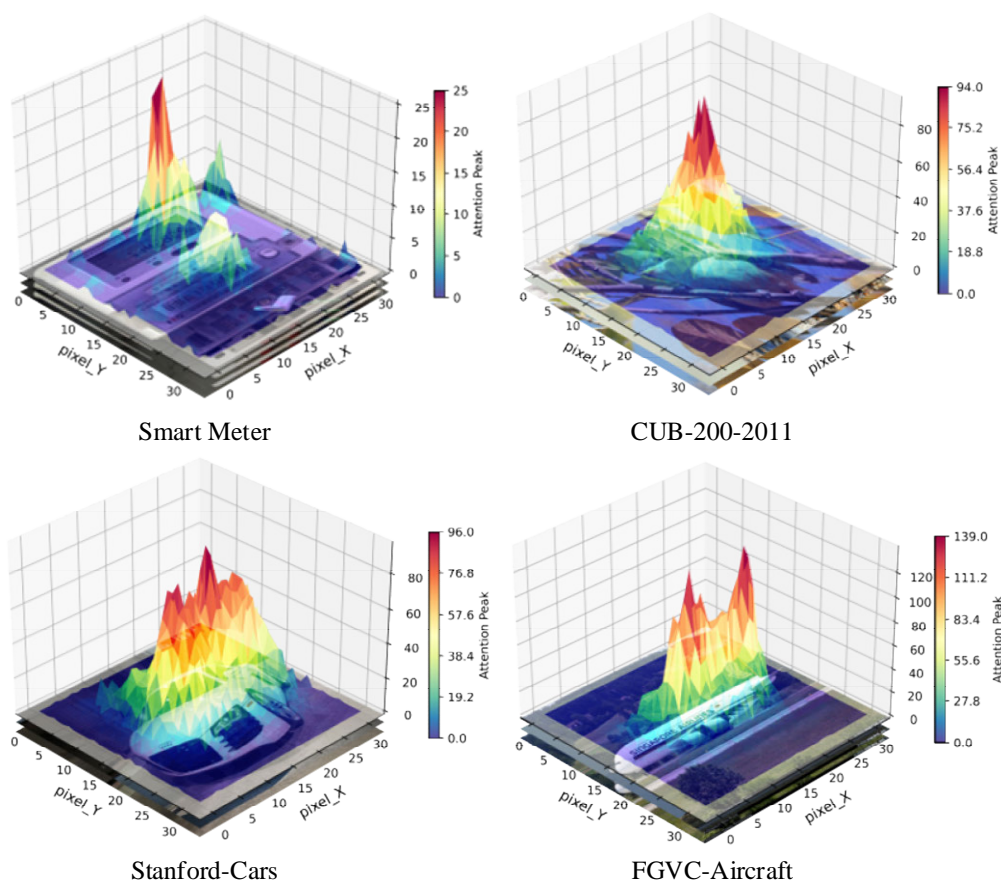


图 A5 数据集的重要特征位置分布(红色区域代表重要程度更高的鉴别性特征区域)
Fig. A5 Location distribution of important features in different datasets (red region represents the discriminative feature region with higher importance)




图 A6 掩码的衰退过程
Fig. A6 Process of the mask fading

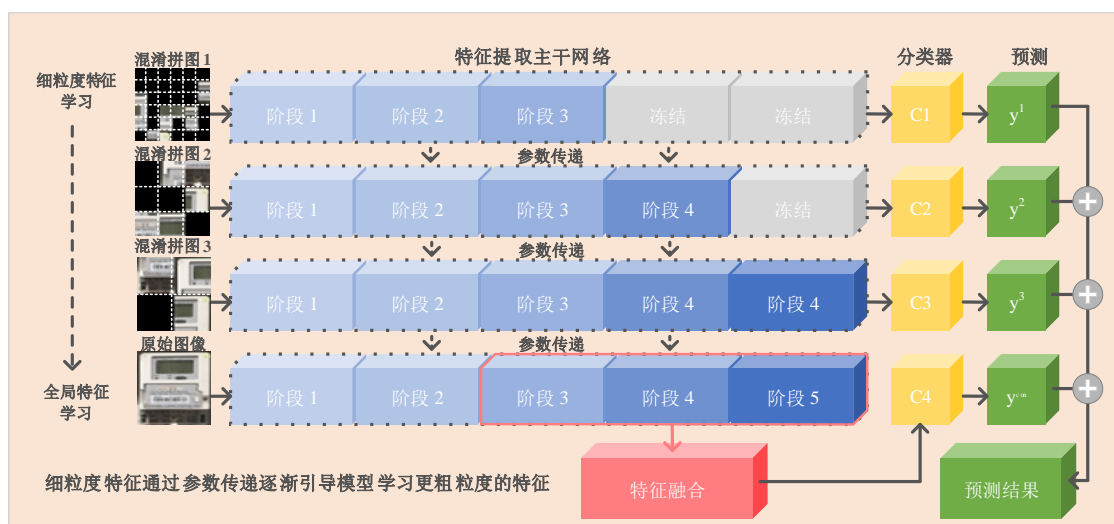


图 A7 渐进式多粒度特征引导学习的训练过程

Fig. A7 Training process of progressive multi-granularity feature-guided learning




图 A8 加入衰退掩码前后的效果对比

Fig. A8 Comparison of effects before and after adding the fading mask




图 A9 加入衰退掩码前后的效果对比

Fig. A9 Comparison of effects before and after adding the fading mask

附录 B

表 B1 手动设定粒度和鉴别性粒度自适应设定的实验结果

Table B1 Accuracy results of granularity manual setting and discriminative granularity adaptive setting				%
粒度	CUB-200-2011	Stanford-Cars	FGVC-Aircraft	
9-6-3	89.3	94.7	92.2	
8-5-3	89.4	94.7	92.6	
7-4-3	89.5	94.7	92.6	
6-4-2	89.6	94.8	92.8	
5-3-2	89.7	95.0	93.0	
4-3-2	89.7	94.9	93.2	
Base	89.4	94.7	92.6	
DGAS	89.7	94.8	93.0	

表 B2 普通掩码和衰退掩码的实验结果

Table B2 Accuracy results of NM and FM				
模块	CUB-200-2011	Stanford-Cars	FGVC-Aircraft	
Base+NM	89.1	94.5	92.0	
Base+FM	89.4	94.7	92.9	
DGAS+NM	89.3	94.5	92.2	
DGAS+FM	89.5	95.0	93.2	

表 B3 各模块的消融实验结果

Table B3 Accuracy results of ablation experiments for each module				%
模块	CUB-200-2011	Stanford-Cars	FGVC-Aircraft	
Base	89.4	94.7	92.6	
DGAS	89.7	94.8	93.0	
FM	89.4	94.7	92.9	
DGAS+FM	89.5	95.0	93.2	

表 B4 所提方法与典型方法在准确率指标上的实验结果

Table B4 Accuracy results of the proposed method and typical methods						%
方法	年份	主干网络	CUB-200-2011	Stanford-Cars	FGVC-Aircraft	
B-CNN	2015	VGG-16	84.1	84.1	91.3	
MA-CNN	2017	VGG-19	86.6	92.8	89.9	
FT ResNet	2018	ResNet-50	84.1	91.7	88.5	
DCL	2019	ResNet-50	87.8	94.5	93.0	
S3N	2019	ResNet-50	88.5	94.7	92.8	
MC-Loss	2020	ResNet-50	87.3	94.5	93.0	
PMG(Base)	2020	ResNet-50	89.4	94.7	92.6	
AP-CNN	2021	VGG-19	86.7	94.6	92.9	
SAM	2022	DBTNet-50	87.3	94.3	91.2	
ELP-SR	2022	ResNet-50	88.8	94.2	92.7	
所提方法	-	ResNet-50	89.7	95.0	93.2	

表 B5 智能电表可视故障数据集

Table B5 Smart electricity meter visual fault dataset					
编号	类 1	类 2	类 3	类 4	类 5
样本数目	329	81	53	158	99
样本类型	正常	封印缺失	烧表	显示故障	表盘破损

Classification of Smart Meter Visual Faults Based on Discriminative Granularity Adaptive Setting and Fading Mask

HUANG Xu¹, GAO Xin¹, LI Baofeng², ZHAI Feng², QIN Yu², LIANG Xiaobing²

(1. School of Artificial Intelligence, Beijing University of Posts and Telecommunications, Haidian District, Beijing 100876, China;

2. China Electric Power Research Institute, Haidian District, Beijing 100192, China)

KEY WORDS: visual fault detection of smart meters; fine-grained image classification; discriminative granularity adaptive setting; fading mask mechanism

Accurate detection of visual faults of smart meters is crucial to the efficient operation and maintenance of power grid metering sites. The layout structure of different faulty meters is highly similar, and their characteristics exhibit a small inter-class variance, which poses a challenge for the accurate classification of visual faults in smart meters. In mainstream research to solve the above problems, the confusion jigsaw mechanism guides models to learn fixed granularity features. Still, it can easily lead to redundant or incomplete features within the jigsaw patch. The masking tool highlights discriminative features by constantly masking non-discriminative feature regions but neglects the information helpful for classification.

To solve the above problems, a visual fault classification method for smart meters based on discriminative granularity adaptive setting and fading mask is proposed. Firstly, an attention map is constructed for the training image to present the required distribution

of target features. The contour size of essential elements in the map is converted into equivalent granularity values, and cluster mining is performed to obtain discriminative granularity values. Based on this, the division granularity of the jigsaw is adaptively set, effectively preserving the integrity of semantic features within the jigsaw patch while reducing redundant information. On this basis, non-discriminative feature regions are mined based on the distribution of target feature importance, and masks are applied to them. The mask probability is attenuated during iterative training, gradually reducing the degree of occlusion of the region and guiding the model to learn feature information helpful for classification in this region. Finally, a progressive multi-granularity feature-guided learning framework is combined to fuse feature information of different granularities to complete the sort. The training flowchart of the proposed method is shown in Fig. 1.

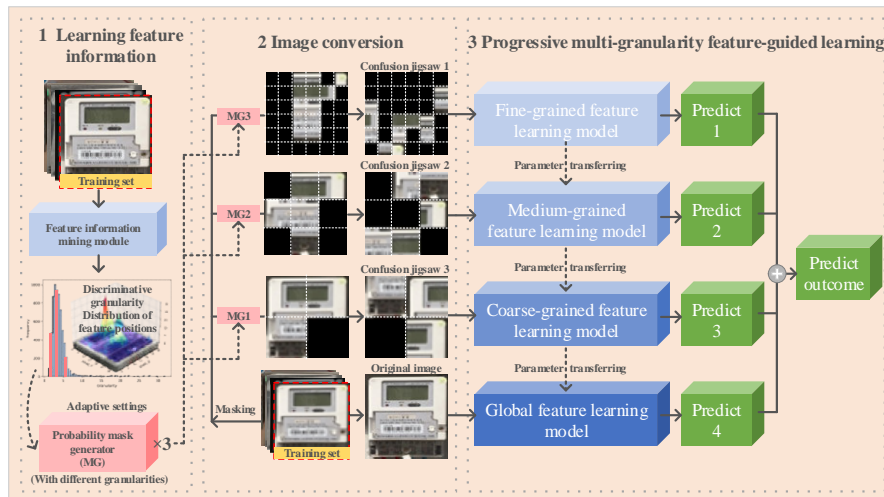


Fig. 1 The training flowchart of the proposed method

Compared with 10 typical fine-grained image classification methods on the smart meter visual fault dataset, the proposed method has significant advantages in Recall and Precision. The proposed method is more conducive to mining the discriminative features of the

meter image and detecting various visual faults. In the future, more advanced training strategies can be further investigated to optimize the decision results based on the importance of different granularity features and improve the method's performance.